
정보기하학을 위한 수학적 기초

미적분 · 선형대수 · 미분기하학 · 확률론

정보기하학 기초 시리즈

2026년 6월 16일

차 례

서문	3
1 미적분과 해석학	4
1.1 C^k 함수와 편미분	4
1.2 다변수 Taylor 전개와 발산도	4
1.3 점근 표기법 O	6
2 선형대수	7
2.1 이중선형 형식과 이차형식	7
2.2 양의 정치행렬	7
2.3 Hessian 행렬	8
2.4 좌표 변환과 합동 변환	8
3 미분기하학 기초	10
3.1 열린 집합	10
3.2 매니폴드: 정의와 예시	10
3.3 접공간 $T_p M$ 과 여접공간 $T_p^* M$	11
3.4 $(0, 2)$ -텐서와 좌표 변환 법칙	11
3.5 리만 계량	12
4 확률론과 수리통계	13
4.1 확률공간 $(\Omega, \mathcal{F}, P)$	13
4.2 확률분포 — pmf와 pdf	13
4.3 통계적 모델	14
4.4 이산 분포 모델과 확률 단체	14
4.5 로그가능도와 Score 함수	16
4.6 Fisher 정보행렬	16
4.7 Cramér–Rao 부등식	18
4.8 KL 발산 — 발산도의 원형	20

5 연결 — 통계적 매니폴드로	22
A 적분 부호 아래 미분	23
B 볼록함수와 Legendre 변환	23
C 참고문헌	24


서문

정보기하학은 확률분포들의 집합에 기하학적 구조를 부여하는 분야다. 분포들을 매개변수로 기술하면 매개변수 공간이 자연스럽게 좌표계 역할을 하고, 그 좌표계 위에 거리 감각, 방향 감각, 곡률 감각을 심을 수 있다. 그 결과가 "확률분포들의 리만 매니폴드"다.

이 노트는 그 구조가 어디서 오는지 추적하기 위한 네 가지 수학적 언어를 다룬다.

- 제1장 미적분과 해석학. 발산도(divergence)의 Taylor 전개가 리만 계량을 끌어내는 메커니즘.
- 제2장 선형대수. 계량 텐서의 핵심 성질인 양의정치(positive definite)성과 이차형식.
- 제3장 미분기하학. 매니폴드와 리만 계량의 언어.
- 제4장 확률론과 수리통계. Fisher 정보행렬이 리만 계량으로 등장하는 과정.

제5장에서 이 네 흐름은 하나로 수렴한다. 통계적 매니폴드 위에서 KL 발산의 Hessian이 Fisher 정보행렬과 일치하며, 이것이 Fisher-Rao 계량을 정의한다.



1 미적분과 해석학

강의에서 가장 직접적으로 쓰이는 해석학적 도구는 두 가지다. 다변수 Taylor 전개와 점근 표기법이다. 발산도 $D[\theta_P : \theta_P + d\theta]$ 의 전개식을 해석하려면 이 두 도구가 필수적이다.

1.1 C^k 함수와 편미분

정의 1.1 C^k 함수

열린 집합 $U \subseteq \mathbb{R}^n$ 에서 $\mathbb{R}$ 로 가는 함수 f 가 k 번 연속 미분가능($f \in C^k(U)$)이라 함은, f 의 모든 k 차 이하 편미분이 U 에서 존재하고 연속임을 뜻한다. $k = \infty$ 인 경우 $f \in C^\infty(U)$ 로 표기한다.

편미분 표기는 다음 두 가지를 혼용한다.

$$\partial_i f := \frac{\partial f}{\partial \theta^i}, \quad \partial_i \partial_j f := \frac{\partial^2 f}{\partial \theta^i \partial \theta^j}.$$

C^2 이상의 함수에서는 편미분 순서를 바꾸어도 결과가 같다.

정리 1.1 Schwarz — 편미분 순서 교환

$f \in C^2(U)$ 이면, 모든 i, j 에 대해

$$\partial_i \partial_j f = \partial_j \partial_i f.$$

증명 스케치. $\mathbf{x} \in U$ 와 표준기저 e_i, e_j 에 대해 혼합 차분

$$\Delta_{h,k} f(\mathbf{x}) := f(\mathbf{x} + he_i + ke_j) - f(\mathbf{x} + he_i) - f(\mathbf{x} + ke_j) + f(\mathbf{x})$$

을 정의한다. 평균값 정리를 i 방향 먼저 적용하면 $\Delta = hk \partial_i \partial_j f(\xi_1)$, j 방향 먼저 적용하면 $\Delta = hk \partial_j \partial_i f(\xi_2)$ 가 된다 (ξ_1, ξ_2 : 중간값). $h, k \rightarrow 0$ 에서 C^2 연속성에 의해 두 표현이 같은 극한으로 수렴한다. $\square$

정보기하학 연결 — § 1.1

강의 이미지 4에서 $g_{ij} = \partial_i \partial_j D[\cdot]$ 가 등장한다. Schwarz 정리에 의해 $g_{ij} = g_{ji}$ 가 자동으로 성립하고, 이것이 계량 행렬 $G = (g_{ij})$ 가 대칭행렬임을 보장한다. 대칭성은 리만 계량의 정의에 내장된 조건이기도 하다.

1.2 다변수 Taylor 전개와 발산도

발산도의 정의를 먼저 놓고, Taylor 전개가 그로부터 계량을 끌어내는 메커니즘을 이어서 설명한다.

정의 1.2 발산도 (Divergence)

함수 $D[P : Q]$ 가 발산도라 함은 다음 세 조건을 만족함을 뜻한다.

- (1) $D[P : Q] \geq 0$
- (2) $D[P : Q] = 0 \iff P = Q$
- (3) P 와 Q 가 충분히 가까울 때, 좌표 $\theta_P, \theta_Q = \theta_P + d\theta$ 로 나타내면

$$D[\theta_P : \theta_P + d\theta] = \frac{1}{2} \sum_{i,j} g_{ij}(\theta_P) d\theta_i d\theta_j + O(|d\theta|^3)$$

이고, 행렬 $G = (g_{ij})$ 는 θ_P 에 의존하는 양의 정치행렬이다. 계량 계수의 명시적 정의:

$$g_{ij}(\theta_P) := \frac{\partial^2}{\partial s_i \partial s_j} D[\theta_P : s] \Big|_{s=\theta_P}.$$

$D[P : Q] := D[\theta_P : \theta_Q]$ 는 좌표 θ 선택에 무관하다.

조건 (1)(2)는 D 가 두 점의 "분리 정도"를 측정함을 말한다. 조건 (3)이 핵심이다. D 의 Taylor 전개 2차 항이 이차형식을 이루고, 그 계수 행렬 (g_{ij}) 가 양의 정치이면 이것이 리만 계량을 정의한다. 발산도는 거리가 아님에 유의하라. $D[P : Q] \neq D[Q : P]$ 이고 삼각부등식도 성립하지 않는다. 거리의 제공에 해당하는 차원을 가진다.

정의 1.3 다변수 2차 Taylor 전개

$f \in C^3(U)$, $\mathbf{x} \in U$, $\mathbf{h} \in \mathbb{R}^n$ 에 대해

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \sum_i \partial_i f(\mathbf{x}) h^i + \frac{1}{2} \sum_{i,j} \partial_i \partial_j f(\mathbf{x}) h^i h^j + O(|\mathbf{h}|^3). \quad (1)$$

$\nabla f := (\partial_i f)_i$ (기울기 벡터), $H_f := (\partial_i \partial_j f)_{i,j}$ (Hessian 행렬)로 쓰면:

$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top H_f(\mathbf{x}) \mathbf{h} + O(|\mathbf{h}|^3).$$

증명 스케치. 방향 $\mathbf{h}$ 를 고정하고 $\phi(t) := f(\mathbf{x} + t\mathbf{h})$ 로 놓으면 $\phi \in C^3[0, 1]$ 이다. 1변수 Taylor 정리($t = 0$ 근방)로부터

$$\phi(1) = \phi(0) + \phi'(0) + \frac{1}{2}\phi''(0) + \frac{1}{6}\phi'''(\xi), \quad \xi \in (0, 1)$$

을 얻는다. 연쇄법칙으로 $\phi'(0) = \sum_i \partial_i f h^i$, $\phi''(0) = \sum_{i,j} \partial_i \partial_j f h^i h^j$ 임을 확인하면 (1)이 얻어진다. 나머지 항은 $\phi''' = O(|\mathbf{h}|^3)$ 이므로 $O(|\mathbf{h}|^3)$ 으로 처리된다. $\square$

예시 1.1 발산도의 Taylor 전개

발산도 $D[\theta : \theta']$ 를 $\theta' = \theta_P + d\theta$ 근방에서 전개한다. $D[\theta_P : \theta'] \in C^3$ 으로 가정하자.

0차 항: $D[\theta_P : \theta_P] = 0$ (조건 2).

1차 항: $\partial_{j'} D[\theta_P : \theta']|_{\theta'=\theta_P}$. 조건 2에 의해 $D[\theta_P : \cdot]$ 는 $\theta' = \theta_P$ 에서 최솟값 0을 달성하므로, θ' 에 대한 1차 편미분이 0이 된다.

2차 항: 1차까지 모두 소거되고 남는 최하차 항이 계량을 결정한다.

$$D[\theta_P : \theta_P + d\theta] = \frac{1}{2} \sum_{i,j} g_{ij}(\theta_P) d\theta_i d\theta_j + O(|d\theta|^3), \quad (2)$$

계량 계수는 두 번째 인수(Q 의 좌표)에 대한 Hessian으로 정의된다. 더미 변수 s 를 써서 명시적으로 표현하면:

$$g_{ij}(\theta_P) := \frac{\partial^2}{\partial s_i \partial s_j} D[\theta_P : s] \Big|_{s=\theta_P}.$$

이 정의로부터 $D[P : Q] := D[\theta_P : \theta_Q]$ 가 좌표 θ 선택에 무관함도 따른다. 즉 발산도는 좌표에 의존하지 않는 기하학적 양이다.

1.3 점근 표기법 O

정의 1.4 Big- O 표기

$h \rightarrow 0$ 일 때 $f(h) = O(g(h))$ 라 함은, 상수 $C > 0$ 과 $\delta > 0$ 이 존재하여 $|h| < \delta$ 이면 $|f(h)| \leq C |g(h)|$ 임을 뜻한다.

전개식 (2)에서 $O(|d\theta|^3)$ 는 $|d\theta| \rightarrow 0$ 일 때 나머지의 크기가 $|d\theta|^3$ 에 비례하여 줄어든다는 뜻이다. $d\theta$ 가 충분히 작으면 2차 항 $\frac{1}{2} \sum_{i,j} g_{ij} d\theta_i d\theta_j$ 이 나머지를 압도한다. 이것이 계량 계수 g_{ij} 를 Taylor 전개 2차 항에서 추출할 수 있는 이유다.

2 선형대수

Taylor 전개에 2차 항 $\frac{1}{2} \sum_{i,j} g_{ij} d\theta_i d\theta_j$ 는 이차형식이다. 이것이 거리의 제곱 역할을 하려면 행렬 $G = (g_{ij})$ 가 양의 정치(positive definite)여야 한다. 이 장은 그 조건이 무엇인지, 왜 자연스러운지를 다룬다.

2.1 이중선형 형식과 이차형식

정의 2.1 대칭 이중선형 형식

$\mathbb{R}^n$ 위의 대칭 이중선형 형식은 함수 $B : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ 로,

- (쌍선형성) $B(\alpha u + \beta v, w) = \alpha B(u, w) + \beta B(v, w)$ (두 번째 인수에 대해서도 동일)
- (대칭성) $B(u, v) = B(v, u)$

를 만족한다. 표준기저 $\{e_i\}$ 하에서 $g_{ij} := B(e_i, e_j)$ 로 정의하면 $B(u, v) = u^\top G v$ ($G = (g_{ij})$, 대칭행렬).

정의 2.2 이차형식

대칭 이중선형 형식 B 에 대응하는 이차형식은

$$Q(v) := B(v, v) = v^\top G v = \sum_{i,j} g_{ij} v^i v^j.$$

발산도 Taylor 전개에 2차 항 $\sum_{i,j} g_{ij} d\theta_i d\theta_j$ 는 정확히 이 이차형식이다. 이것이 "거리의 제곱"처럼 작동하려면 $Q(v) \geq 0$ 이어야 하고, 등호가 $v = 0$ 에서만 성립해야 한다.

2.2 양의 정치행렬

정의 2.3 양의 정치행렬 (Positive Definite)

대칭행렬 $G \in \mathbb{R}^{n \times n}$ 이 양의 정치($G \succ 0$)라 함은

$$\forall v \neq 0: \quad v^\top G v > 0.$$

정리 2.1 양의 정치의 동치 조건

대칭행렬 $G \in \mathbb{R}^{n \times n}$ 에 대해 다음은 동치다.

- $G \succ 0$ (정의)
- G 의 모든 고유값이 양수

- (iii) G 의 모든 주소행렬식(leading principal minor)이 양수 (Sylvester 기준)
- (iv) $G = LL^\top$ 인 하삼각행렬 L 이 존재 (Cholesky 분해)

증명 스케치 (i) $\Leftrightarrow$ (ii). G 는 대칭이므로 스펙트럼 정리에 의해 $G = Q\Lambda Q^\top$ (Q : 직교행렬, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$). 임의의 $\mathbf{v} \neq 0$ 에 대해 $\mathbf{w} := Q^\top \mathbf{v} \neq 0$ 이고

$$\mathbf{v}^\top G \mathbf{v} = \mathbf{w}^\top \Lambda \mathbf{w} = \sum_{i=1}^n \lambda_i (w^i)^2.$$

이 값이 모든 $\mathbf{w} \neq 0$ 에서 양수이려면 $\lambda_i > 0$ ($\forall i$)이어야 하며, 역도 성립한다. $\square$

예시 2.1 2×2 경우와 Fisher 행렬 미리보기

$G = \begin{pmatrix} a & b \\ b & d \end{pmatrix}$ 에 대해 Sylvester 기준:

$$G \succ 0 \iff a > 0 \text{ 이고 } \det G = ad - b^2 > 0.$$

후에 계산할 가우시안의 Fisher 행렬 $I(\mu, \sigma) = \begin{pmatrix} 1/\sigma^2 & 0 \\ 0 & 2/\sigma^2 \end{pmatrix}$ 는 $1/\sigma^2 > 0$ 이고 $\det I = 2/\sigma^4 > 0$ ($\sigma > 0$)이므로 양의 정치다.

2.3 Hessian 행렬

정의 2.4 Hessian 행렬

$f \in C^2(U)$ 에서 점 $\mathbf{x}$ 의 Hessian 행렬은

$$H_f(\mathbf{x}) := (\partial_i \partial_j f(\mathbf{x}))_{1 \leq i, j \leq n}.$$

Schwarz 정리(정리 1.1)에 의해 $H_f(\mathbf{x})$ 는 대칭행렬이다.

명제 2.2 2차 판정법

$f \in C^2(U)$ 이고 $\nabla f(\mathbf{x}_0) = 0$, $H_f(\mathbf{x}_0) \succ 0$ 이면 $\mathbf{x}_0$ 은 f 의 엄격한 극솟값이다.

정보기하학에서 이 명제의 역방향이 중요하다. 발산도 $D[\theta : \theta']$ 는 $\theta' = \theta$ 에서 최솟값 0을 달성한다(조건 2). 그 Hessian이 양의 정치라는 것이 조건 (3)이며, 이것이 계량 텐서 (g_{ij}) 의 존재를 보장한다.

2.4 좌표 변환과 합동 변환

좌표를 $\theta \rightarrow \tilde{\theta}(\theta)$ 로 바꿀 때, 이차형식의 계수 행렬은 어떻게 변하는가?

Jacobian $J = (\partial \tilde{\theta}^i / \partial \theta^j)_{i,j}$ 로 정의하면, 연쇄법칙에 의해 $\tilde{G} = J^{-\top} G J^{-1}$ 이 성립한다. 이것을 **합동 변환**이라 한다.

명제 2.3 합동 변환의 양의 정치 보존

$G \succ 0$ 이고 J 가 가역이면 $J^{-\top} G J^{-1} \succ 0$.

증명. 임의의 $\mathbf{v} \neq 0$ 에 대해 $\mathbf{w} := J^{-1}\mathbf{v} \neq 0$ 이므로 $\mathbf{v}^\top (J^{-\top} G J^{-1}) \mathbf{v} = \mathbf{w}^\top G \mathbf{w} > 0$. $\square$

리만 계량의 양의 정치성은 이 명제에 의해 좌표 선택에 무관하게 보존된다.

3 미분기하학 기초

정보기하학의 주객체는 "확률분포들의 매니폴드"다. 이 장은 매니폴드라는 개념이 무엇인지, 그리고 그 위에 거리 구조인 리만 계량을 어떻게 엮는지를 다룬다.

3.1 열린 집합

정의 3.1 열린 집합

$U \subseteq \mathbb{R}^n$ 이 열린 집합이라 함은, 모든 $\mathbf{x} \in U$ 에 대해 $\varepsilon > 0$ 이 존재하여

$$B(\mathbf{x}, \varepsilon) := \{\mathbf{y} \in \mathbb{R}^n : \|\mathbf{y} - \mathbf{x}\| < \varepsilon\} \subseteq U.$$

즉, 모든 점이 경계에 붙지 않고 약간의 여유를 가진다.

강의 이미지 1에서 $\Theta \subseteq \mathbb{R}^n$ 이 열린 집합이라는 조건이 등장한다. 가우시안 모델의 매개변수 공간 $\mathbb{R} \times \mathbb{R}_{>0}$ 에서 $\sigma > 0$ 이라는 조건이 바로 이 열린 조건이다. $\sigma = 0$ 은 유효한 분포를 정의하지 않으므로 포함될 수 없다.

3.2 매니폴드: 정의와 예시

정의 3.2 n -차원 C^∞ 매니폴드

위상공간 M 이 n -차원 C^∞ 매니폴드라 함은:

- (i) 차트(chart): 각 $p \in M$ 마다 열린 집합 $U \ni p$ 와 위상동형 $\varphi : U \rightarrow V \subseteq \mathbb{R}^n$ 인 쌍 (U, φ) 가 존재.
- (ii) 아틀라스(atlas): 차트들의 모임이 M 전체를 덮음.
- (iii) C^∞ 호환성: 두 차트 $(U_\alpha, \varphi_\alpha), (U_\beta, \varphi_\beta)$ 가 겹칠 때, 전환 사상 $\varphi_\beta \circ \varphi_\alpha^{-1}$ 이 C^∞ 함수.

차트는 구부러진 공간의 작은 조각을 유클리드 공간으로 "펼치는" 지도다. 지구의 한 지역을 평면 지도로 그릴 때 왜곡이 생기듯, 매니폴드의 전체 구조는 여러 장의 지도(아틀라스)로 기술된다.

예시 3.1 구면 S^2

$S^2 = \{(x, y, z) \in \mathbb{R}^3 : x^2 + y^2 + z^2 = 1\}$ 은 2차원 매니폴드다. 하나의 차트로 S^2 전체를 덮는 것은 불가능하다. 북극과 남극을 각각 제거한 입체투영 차트 두 장으로 전체 아틀라스를 구성한다.

예시 3.2 가우시안 매니폴드

$\mathbb{R} \times \mathbb{R}_{>0} \subseteq \mathbb{R}^2$ 는 $\mathbb{R}^2$ 의 열린 부분집합이다. 열린 부분집합은 항등 사상 $\text{id} : \mathbb{R} \times \mathbb{R}_{>0} \rightarrow \mathbb{R}^2$ 가 이미 위상동형이므로, 하나의 차트만으로 덮이는 2차원 매니폴드다. 강의 이미지 2의 "2-dim. mfld (covered by one patch)"가 바로 이 사실이다.

3.3 접공간 $T_p M$ 과 여접공간 $T_p^* M$

매니폴드의 각 점에는 그 점에서 가능한 "방향들의 공간"인 접공간이 존재한다.

정의 3.3 접공간

$p \in M$ 에서의 접공간 $T_p M$ 은, p 를 지나는 매끄러운 곡선들의 속도벡터 전체로 이루어진 n -차원 벡터공간이다. 좌표 $(\theta^1, \dots, \theta^n)$ 하에서

$$T_p M = \text{span} \left\{ \left. \frac{\partial}{\partial \theta^1} \right|_p, \dots, \left. \frac{\partial}{\partial \theta^n} \right|_p \right\}.$$

정의 3.4 여접공간

$T_p^* M := (T_p M)^*$ 은 $T_p M$ 의 쌍대 벡터공간이다. 좌표함수 θ^i 의 미분 $d\theta^i|_p \in T_p^* M$ 은

$$d\theta^i \left(\left. \frac{\partial}{\partial \theta^j} \right|_p \right) = \delta_j^i \quad (\text{Kronecker delta})$$

를 만족하며, $\{d\theta^i|_p\}$ 는 $T_p^* M$ 의 기저다.

발산도 전개식에서 등장하는 $d\theta_i d\theta_j$ 는 $d\theta^i \otimes d\theta^j \in T_p^* M \otimes T_p^* M$, 즉 두 여접벡터의 텐서 곱이다. 이것은 두 접벡터를 입력받아 실수를 돌려주는 이중선형 형식을 기술한다.

3.4 $(0, 2)$ -텐서와 좌표 변환 법칙

정의 3.5 공변 2-텐서

$p \in M$ 에서의 $(0, 2)$ -텐서는 이중선형 형식 $g : T_p M \times T_p M \rightarrow \mathbb{R}$ 이다. 좌표 $\{\theta^i\}$ 하에서

$$g = g_{ij} d\theta^i \otimes d\theta^j, \quad g_{ij} := g(\partial_i, \partial_j)$$

(Einstein 합산 규약: 위아래 반복 첨자는 합산).

명제 3.1 $(0, 2)$ -텐서의 좌표 변환 법칙

좌표 $\theta \rightarrow \tilde{\theta}$ 로 바꿀 때, 새 좌표에서의 성분 $\tilde{g}_{kl}$ 과 원래 성분 g_{ij} 사이에는

$$g_{ij} = \tilde{g}_{kl} \frac{\partial \tilde{\theta}^k}{\partial \theta^i} \frac{\partial \tilde{\theta}^l}{\partial \theta^j}.$$

증명 스케치. 접기저 변환 $\partial_i = \frac{\partial \tilde{\theta}^k}{\partial \theta^i} \tilde{\partial}_k$ 를 $g_{ij} = g(\partial_i, \partial_j)$ 에 대입하면 이중선형성에 의해 성립한다.

□

이 변환 법칙 덕분에 $g(v, w)$ 라는 값은 어떤 좌표계에서 계산해도 동일하다. 발산도의 Hessian 에서 추출한 계량 계수 (g_{ij}) 가 텐서로 변환된다는 것은, 그것이 진정으로 좌표에 무관한 기하학적 객체임을 뜻한다.

3.5 리만 계량

정의 3.6 리만 계량

매니폴드 M 위의 리만 계량은 각 점 p 마다 정의된 $(0, 2)$ -텐서장 $g_p : T_p M \times T_p M \rightarrow \mathbb{R}$ 로,

- (대칭성) $g_p(u, v) = g_p(v, u)$
- (양의정치성) $g_p(v, v) > 0 \quad (v \neq 0)$
- (매끄러움) 좌표 성분 $g_{ij}(\theta)$ 가 θ 에 대해 C^∞

를 만족한다. 리만 계량이 주어진 매니폴드를 리만 매니폴드라 한다.

예시 3.3 표준 유클리드 계량

$\mathbb{R}^n$ 위에서 $g_{ij} = \delta_{ij}$. 이차형식은 $\sum_i (dx^i)^2 = |dx|^2$, 즉 유클리드 거리의 제곱이다.

강의 이미지 4의 조건 (3)은 정확히 이것이다. 발산도의 Hessian (g_{ij}) 가 양의정치이고 θ 에 대해 매끄럽다면, 이 데이터가 리만 계량을 정의한다.

4 확률론과 수리통계

이 장은 확률분포를 수학적으로 기술하는 언어와, 그 언어로부터 Fisher 정보행렬이 어떻게 도출되는지를 다룬다. Fisher 정보행렬은 KL 발산의 Hessian과 일치하며, 결국 통계적 매니폴드 위의 리만 계량이 된다.

4.1 확률공간 $(\Omega, \mathcal{F}, P)$

정의 4.1 확률공간

확률공간은 트리플 $(\Omega, \mathcal{F}, P)$ 로 구성된다.

- Ω : 표본공간 — 가능한 모든 결과의 집합
- $\mathcal{F}$: σ -대수 — 사건(event)들의 집합족
- $P: \mathcal{F} \rightarrow [0, 1]$: 확률측도 ($P(\Omega) = 1$, 가산 가법성)

예시 4.1 주사위

강의 이미지 1의 예시. $\Omega = \{1, 2, 3, 4, 5, 6\}$, $\mathcal{F} = 2^\Omega$, 공정한 주사위라면 $P(\{k\}) = 1/6$ ($k = 1, \dots, 6$). 이 공간은 유한하고 이산적이어서 기하학적 구조가 당장 보이지 않는다. 연속 분포족을 다룰 때 비로소 기하학이 등장한다.

4.2 확률분포 — pmf와 pdf

정의 4.2 pmf와 pdf

- 확률질량함수(pmf, 이산): $p: \Omega \rightarrow [0, 1]$, $\sum_{x \in \Omega} p(x) = 1$.
- 확률밀도함수(pdf, 연속): $p: \mathbb{R} \rightarrow [0, \infty)$, $\int_{-\infty}^{\infty} p(x) dx = 1$.

두 경우를 통합하는 언어는 Radon–Nikodym 표현이다. 기준 측도 μ (이산: 계수 측도, 연속: Lebesgue 측도)에 대해 $dP = p d\mu$ 인 밀도 p 가 존재한다.

예시 4.2 가우시안 pdf

$\mathcal{N}(\mu, \sigma^2)$ 의 확률밀도함수:

$$p(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad x \in \mathbb{R}.$$

이것이 강의 이미지 2 하단에 등장하는 식이다.

4.3 통계적 모델

정의 4.3 통계적 모델

통계적 모델 S 는 같은 표본공간 위의 확률분포 집합으로,

$$S = \{p(x; \theta) : \theta = (\theta^1, \dots, \theta^n) \in \Theta\}, \quad \Theta \subseteq \mathbb{R}^n \text{ (열린 집합)}.$$

동일화 조건: $\theta \neq \theta' \Rightarrow p(\cdot; \theta) \neq p(\cdot; \theta')$.

동일화 조건은 매개변수가 분포를 일대일로 결정하게 한다. 이 조건이 없으면 매개변수 공간을 좌표계로 쓸 수 없고, 따라서 매니폴드 구조가 성립하지 않는다.

예시 4.3 가우시안 모델

$S_G = \{\mathcal{N}(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma > 0\}$. 매개변수 $\theta = (\mu, \sigma) \in \mathbb{R} \times \mathbb{R}_{>0}$. $(\mu_1, \sigma_1) \neq (\mu_2, \sigma_2)$ 이면 두 가우시안은 다른 분포이므로 동일화 조건이 성립한다. 이 모델이 § 3.2의 "하나의 차트로 덮이는 2차원 매니폴드"다.

교수 노트 — Wasserstein 거리와 Fisher 정보 계량

가우시안 분포족에는 두 가지 자연스러운 거리 구조가 공존한다.

- Wasserstein 2-거리: $\mathcal{N}(\mu_1, \sigma_1^2)$ 과 $\mathcal{N}(\mu_2, \sigma_2^2)$ 사이의 Wasserstein 2-거리는 매개변수 공간 $\mathbb{R}^2$ 위의 유클리드 거리와 일치한다.

$$W_2(\mathcal{N}(\mu_1, \sigma_1^2), \mathcal{N}(\mu_2, \sigma_2^2)) = \sqrt{(\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2}.$$

- Fisher-Rao 거리 (이 노트의 주제): 가우시안 분포족 위의 Fisher 정보 계량은 쌍곡 계량을 유도한다 (단면 곡률 $K = -\frac{1}{2}$).

같은 분포족에 대해 어떤 거리를 채택하느냐에 따라 완전히 다른 기하학이 펼쳐진다.

4.4 이산 분포 모델과 확률 단체

연속 분포뿐 아니라 이산 확률분포의 집합도 매니폴드 구조를 가진다. 이 경우 매개변수 공간은 단체(simplex)라는 구체적인 기하학적 형태로 나타난다.

정의 4.4 이산 통계적 모델

유한 표본공간 $X = \{0, 1, \dots, n\}$ 위의 확률분포는 $n+1$ 개의 확률값

$$P_i = \text{Prob}\{x = i\}, \quad i = 0, 1, \dots, n$$

으로 결정된다. 이를 확률 벡터 $\vec{p} = (p_0, p_1, \dots, p_n)$ 으로 나타내며, $\sum_{i=0}^n p_i = 1, p_i > 0$ 을 만족한다.

$p_0 = 1 - \sum_{i=1}^n p_i$ 로 결정되므로 자유 매개변수는 $\theta = (p_1, \dots, p_n)$ 이고,

$$p(x; \theta) = \begin{cases} p_x & x = 1, \dots, n, \\ 1 - \sum_{i=1}^n p_i & x = 0. \end{cases}$$

매개변수 공간:


$$\Theta_n = \left\{ (p_1, \dots, p_n) : p_i > 0, \sum_{i=1}^n p_i < 1 \right\} \subseteq \mathbb{R}^n.$$

Θ_n 은 $\mathbb{R}^n$ 의 열린 부분집합이므로 n -차원 매니폴드다.

예시 4.5 $n = 1$: Bernoulli 분포와 1-단체

$X = \{0, 1\}$. 매개변수 $\theta = p_1$ 하나로 분포가 결정된다.

$$\begin{aligned} S &= \{(p_0, p_1) : p_0 = 1 - p_1, p_i > 0\} = \{(1 - p_1, p_1) : 0 < p_1 < 1\} \\ &\longleftrightarrow \Theta_1 = (0, 1) \subset \mathbb{R}. \end{aligned}$$




$\Theta_1 = (0, 1)$ 은 1차원 열린 구간, 즉 1-단체의 내부다. 1차원 매니폴드.

예시 4.6 $n = 2$: 3값 이산 분포와 2-단체

$X = \{0, 1, 2\}$. 매개변수 $\theta = (p_1, p_2)$.

$$\begin{aligned} S &= \{(p_0, p_1, p_2) : p_0 = 1 - p_1 - p_2, p_i > 0\} \\ &\longleftrightarrow \Theta_2 = \{(p_1, p_2) : p_1 > 0, p_2 > 0, p_1 + p_2 < 1\}. \end{aligned}$$



Θ_2 은 $\mathbb{R}^2$ 의 열린 삼각형 내부, 즉 2-단체의 내부다. 삼각형의 꼭짓점·변은 어떤 확률이 0이 되는 경계인데, $p_i > 0$ 조건이 이 경계를 제외하여 Θ_2 를 열린 집합으로 만든다. 2차원 매니폴드.

일반적으로 $X = \{0, 1, \dots, n\}$ 위의 이산 분포족은 n -단체의 내부 Θ_n 과 대응하는 n -차원 매니폴드를 이룬다. 이 구조는 정보기하학에서 지수족(exponential family)의 원형적 예시가 된다.

4.5 로그가능도와 Score 함수

정의 4.5 로그가능도와 Score

$\ell(\theta; x) := \log p(x; \theta)$ 를 로그가능도라 한다.

매개변수 θ^i 방향의 Score 함수:

$$s_i(\theta; x) := \partial_i \ell(\theta; x) = \frac{\partial \log p(x; \theta)}{\partial \theta^i} = \frac{\partial_i p(x; \theta)}{p(x; \theta)}.$$

Score의 기댓값이 0이라는 사실이 뒤따르는 모든 계산의 기반이다.

명제 4.1 Score의 기댓값

정규성 조건(적분과 미분의 교환 — 부록 A)이 성립하면,

$$\mathbb{E}_\theta[s_i(\theta; X)] = 0 \quad \forall i.$$

증명 스케치. $\int p(x; \theta) dx = 1$ 을 θ^i 로 미분한다.

$$0 = \partial_i \int p(x; \theta) dx = \int \partial_i p(x; \theta) dx = \int p(x; \theta) \cdot \frac{\partial_i p}{p} dx = \mathbb{E}_\theta[s_i]. \quad \square \quad (3)$$

4.6 Fisher 정보행렬

정의 4.6 Fisher 정보행렬

통계적 모델 $S = \{p(x; \theta)\}$ 에서 Fisher 정보행렬은

$$I_{ij}(\theta) := \mathbb{E}_\theta[s_i(\theta; X) s_j(\theta; X)] = \mathbb{E}_\theta \left[\frac{\partial \log p}{\partial \theta^i} \cdot \frac{\partial \log p}{\partial \theta^j} \right].$$

정리 4.2 Fisher 정보의 동치 표현

정규성 조건 하에서

$$I_{ij}(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2 \log p(X; \theta)}{\partial \theta^i \partial \theta^j} \right].$$

증명 스케치. 명제 4.1의 결과 $\mathbb{E}_\theta[s_j] = 0$ 을 θ^i 로 미분한다.

$$\begin{aligned}
 0 &= \partial_i \int p(x; \theta) s_j \, dx \\
 &= \int [(\partial_i p) s_j + p (\partial_i s_j)] \, dx \\
 &= \int p s_i s_j \, dx + \int p \partial_i \partial_j \log p \, dx \\
 &= I_{ij}(\theta) + \mathbb{E}_\theta[\partial_i \partial_j \log p].
 \end{aligned} \tag{4}$$

따라서 $I_{ij}(\theta) = -\mathbb{E}_\theta[\partial_i \partial_j \log p]$. □

명제 4.3 Fisher 행렬의 양의정치성

동일화 조건이 성립하는 모델에서 $I(\theta) \succ 0$.

증명 스케치. 임의의 $\mathbf{v} \in \mathbb{R}^n$ 에 대해

$$\mathbf{v}^\top I(\theta) \mathbf{v} = \mathbb{E}_\theta \left[\left(\sum_i v^i s_i \right)^2 \right] = \text{Var}_\theta \left[\sum_i v^i s_i(\theta; X) \right] \geq 0.$$

등호 조건: $\sum_i v^i \partial_i \log p = 0$ (a.s.). 동일화 조건 하에서 이는 $\mathbf{v} = \mathbf{0}$ 만 가능하다. □

예시 4.4 가우시안의 Fisher 행렬

$p(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$ 에서

$$\log p = -\log(\sqrt{2\pi}\sigma) - \frac{(x-\mu)^2}{2\sigma^2}, \tag{5}$$

$$\partial_\mu \log p = \frac{x-\mu}{\sigma^2}, \tag{6}$$

$$\partial_\sigma \log p = -\frac{1}{\sigma} + \frac{(x-\mu)^2}{\sigma^3}. \tag{7}$$

$X \sim \mathcal{N}(\mu, \sigma^2)$ 에서 $\mathbb{E}[(X-\mu)^2] = \sigma^2$, $\mathbb{E}[(X-\mu)^3] = 0$, $\mathbb{E}[(X-\mu)^4] = 3\sigma^4$ 를 이용하면:

$$I_{\mu\mu} = \mathbb{E} \left[\frac{(X-\mu)^2}{\sigma^4} \right] = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}, \tag{8}$$

$$I_{\mu\sigma} = \mathbb{E} \left[\frac{X-\mu}{\sigma^2} \left(-\frac{1}{\sigma} + \frac{(X-\mu)^2}{\sigma^3} \right) \right] = -\frac{\mathbb{E}[X-\mu]}{\sigma^3} + \frac{\mathbb{E}[(X-\mu)^3]}{\sigma^5} = 0, \tag{9}$$

$$I_{\sigma\sigma} = \mathbb{E} \left[\left(-\frac{1}{\sigma} + \frac{(X-\mu)^2}{\sigma^3} \right)^2 \right] = \frac{1}{\sigma^2} - \frac{2}{\sigma^2} + \frac{3}{\sigma^2} = \frac{2}{\sigma^2}. \tag{10}$$

따라서

$$I(\mu, \sigma) = \begin{pmatrix} 1/\sigma^2 & 0 \\ 0 & 2/\sigma^2 \end{pmatrix}.$$

$I_{\mu\mu} = 1/\sigma^2$: σ 가 클수록 분포가 넓어지고 μ 에 대한 정보가 줄어든다. $I_{\sigma\sigma} = 2/\sigma^2$: 유

사하게 σ 에 대한 정보량. 두 행이 $I_{\mu\sigma} = 0$ 으로 직교하는 것은 μ 와 σ 가 독립적으로 추정 가능함을 시사한다.

4.7 Cramér–Rao 부등식

Fisher 정보행렬이 추정량의 분산에 하한을 부과한다는 것이 Cramér–Rao 부등식의 핵심이다. 이것은 통계적 추론의 근본 한계를 기하학적으로 해석하는 출발점이 된다.

정의 4.7 비편향 추정량

$T(X)$ 가 θ^i 의 비편향 추정량(unbiased estimator)이라 함은

$$\mathbb{E}_\theta[T(X)] = \theta^i \quad \forall \theta.$$

n 개의 독립 관측값 $(X_1, \dots, X_n)$ 에 대한 추정량인 경우 $T = T(X_1, \dots, X_n)$ 으로 쓴다.

정리 4.5 Cramér–Rao 부등식 (스칼라 버전)

$T(X)$ 가 θ (스칼라)의 비편향 추정량이고 정규성 조건이 성립하면,

$$\text{Var}_\theta[T(X)] \geq \frac{1}{I(\theta)}.$$

등호 조건: $T(X) - \theta = c(\theta) \cdot s(\theta; X)$ 인 함수 $c(\theta)$ 가 존재할 때 (Score의 선형 함수일 때).

증명 스케치 (Cauchy–Schwarz 이용).

Step 1. 공분산 $\text{Cov}_\theta(T, s)$ 를 계산한다. 비편향 조건 $\mathbb{E}_\theta[T] = \theta$ 를 θ 로 미분하면 (정규성 조건 하에서):

$$1 = \partial_\theta \mathbb{E}_\theta[T] = \partial_\theta \int T(x) p(x; \theta) dx = \int T(x) \partial_\theta p(x; \theta) dx = \mathbb{E}_\theta[T(X) s(\theta; X)]. \quad (11)$$

$\mathbb{E}_\theta[s] = 0$ (명제 4.1)이므로

$$\text{Cov}_\theta(T, s) = \mathbb{E}_\theta[T \cdot s] - \mathbb{E}_\theta[T] \cdot \mathbb{E}_\theta[s] = 1 - \theta \cdot 0 = 1.$$

Step 2. Cauchy–Schwarz 부등식을 적용한다.

$$[\text{Cov}_\theta(T, s)]^2 \leq \text{Var}_\theta[T] \cdot \text{Var}_\theta[s].$$

$\text{Var}_\theta[s] = I(\theta)$ (Fisher 정보의 정의)이므로

$$1 \leq \text{Var}_\theta[T] \cdot I(\theta) \implies \text{Var}_\theta[T] \geq \frac{1}{I(\theta)}. \quad \square$$

정리 4.6 Cramér–Rao 부등식 (행렬 버전)

$T(X) = (T^1(X), \dots, T^n(X))$ 가 $\theta = (\theta^1, \dots, \theta^n)$ 의 비편향 추정량이면,

$$\text{Cov}_\theta[T] \succeq I(\theta)^{-1},$$

즉 $\text{Cov}_\theta[T] - I(\theta)^{-1}$ 가 양의 반정치행렬이다.

증명 스케치. 임의의 벡터 $\mathbf{a} \in \mathbb{R}^n$ 에 대해 스칼라 추정량 $U := \mathbf{a}^\top T$, $V := \mathbf{a}^\top \theta$ 를 정의하면 U 는 V 의 비편향 추정량이 된다. 스칼라 Cramér–Rao (정리 4.5)를 적용하면 $\text{Var}[U] \geq 1/I_V$ 이고, 이를 모든 $\mathbf{a}$ 에 대해 정리하면 행렬 부등식이 얻어진다. $\square$

예시 4.7 가우시안 모델에서의 효율성

$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$, σ^2 알려짐. μ 를 추정한다.

n 개 관측값의 결합 Fisher 정보량: $I_n(\mu) = n \cdot I_{\mu\mu} = n/\sigma^2$.

Cramér–Rao 하한:

$$\text{Var}_\mu[T] \geq \frac{1}{I_n(\mu)} = \frac{\sigma^2}{n}.$$

표본평균 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ 의 성질:

- 비편향: $\mathbb{E}_\mu[\bar{X}] = \mu$ ✓
- 분산: $\text{Var}_\mu[\bar{X}] = \sigma^2/n$ (하한 정확히 달성)

$\bar{X}$ 는 하한을 달성한다. 이를 효율적 추정량(efficient estimator)이라 한다.

σ 에 대한 Cramér–Rao 하한 (μ 알려짐): $I_{\sigma\sigma} = 2/\sigma^2$ 이므로 $\text{Var}[T] \geq \sigma^2/2$. MLE $\hat{\sigma} = \sqrt{\frac{1}{n} \sum_k (X_k - \mu)^2}$ 는 $n \rightarrow \infty$ 에서 이 하한에 수렴한다.

기하학적 해석

Fisher–Rao 계량 $g_{ij}(\theta) = I_{ij}(\theta)$ 의 관점에서 Cramér–Rao 부등식이 말하는 것은 다음과 같다.

θ 근방에서 리만 계량이 크다 $\Leftrightarrow$ 인접한 분포들이 기하학적으로 멀다 $\Leftrightarrow$ 작은 매개변수 변화도 분포를 크게 바꾼다 $\Leftrightarrow$ 그 방향의 매개변수를 정밀하게 추정할 수 있다 $\Leftrightarrow$ 추정량의 분산 하한 $I(\theta)^{-1}$ 이 작다.

즉 Fisher 정보행렬은 통계적 매니폴드의 곡률이 클수록 추정이 쉬워진다는 기하학적 직관을 수치로 표현한 것이다.

4.8 KL 발산 — 발산도의 원형

정의 4.8 Kullback–Leibler 발산

두 분포 P, Q (밀도 p, q)에 대해

$$D_{\text{KL}}[P : Q] := \int p(x) \log \frac{p(x)}{q(x)} dx.$$

KL 발산이 강의 이미지 4의 발산도 정의를 만족하는지 확인한다.

조건 (1) : $D_{\text{KL}}[P : Q] \geq 0$. $-\log$ 가 볼록함수이므로 Jensen 부등식에 의해

$$D_{\text{KL}}[P : Q] = \mathbb{E}_P \left[-\log \frac{q(X)}{p(X)} \right] \geq -\log \mathbb{E}_P \left[\frac{q(X)}{p(X)} \right] = -\log 1 = 0.$$

조건 (2) : $D_{\text{KL}}[P : Q] = 0 \Leftrightarrow P = Q$. $-\log$ 의 엄격한 볼록성에 의해 등호 조건은 $q(X)/p(X) = 1$ (a.s.), 즉 $p = q$.

조건 (3) : Hessian이 Fisher 행렬.

정리 4.4 KL 발산의 Hessian = Fisher 행렬

$D_{\text{KL}}[\theta : \theta'] := D_{\text{KL}}[p(\cdot; \theta) : p(\cdot; \theta')]$ 로 쓰면,

$$\frac{\partial^2}{\partial \theta'^i \partial \theta'^j} D_{\text{KL}}[\theta : \theta'] \Big|_{\theta'=\theta} = I_{ij}(\theta).$$

증명 스케치. θ 를 고정하고 θ' 에 대해 두 번 미분한다.

$$\begin{aligned} D_{\text{KL}}[\theta : \theta'] &= \int p(x; \theta) [\log p(x; \theta) - \log p(x; \theta')] dx, \\ \frac{\partial}{\partial \theta'^j} D_{\text{KL}}[\theta : \theta'] &= - \int p(x; \theta) \partial_{j'} \log p(x; \theta') dx, \\ \frac{\partial^2}{\partial \theta'^i \partial \theta'^j} D_{\text{KL}}[\theta : \theta'] &= - \int p(x; \theta) \partial_i \partial_{j'} \log p(x; \theta') dx. \end{aligned} \quad (12)$$

$\theta' = \theta$ 로 놓으면 $= -\mathbb{E}_\theta[\partial_i \partial_j \log p(X; \theta)] = I_{ij}(\theta)$. $\square$

KL 발산의 세 조건이 모두 성립하므로, 그로부터 유도되는 리만 계량은 Fisher 정보행렬이다.

비대칭성과 삼각부등식의 부재

강의 이미지 6의 핵심 주석: $D_{\text{KL}}[P : Q] \neq D_{\text{KL}}[Q : P]$ (일반적으로), 삼각부등식 불성립. 즉 KL 발산은 거리가 아니다.


가우시안 예시:

$$D_{\text{KL}}[\mathcal{N}(\mu, \sigma^2) : \mathcal{N}(\mu', \sigma'^2)] = \log \frac{\sigma'}{\sigma} + \frac{\sigma^2 + (\mu - \mu')^2}{2\sigma'^2} - \frac{1}{2}.$$

$P \leftrightarrow Q$ 를 교환하면 값이 달라진다. 그러나 $P = Q$ 근방에서 Taylor 전개를 하면 2차항에서 대칭성이 회복되며 ($g_{ij} = g_{ji}$), 그것이 바로 리만 계량의 대칭성으로 연결된다.

5 연결 — 통계적 매니폴드로

앞의 네 장이 독립적으로 보였다면, 여기서 모두 수렴한다.



흐름을 단계별로 정리하면 다음과 같다.

1단계 (§ 3.2, § 4.3). $S = \{p(x; \theta) : \theta \in \Theta\}$ 에서 Θ 가 $\mathbb{R}^n$ 의 열린 집합이므로, S 는 자연스럽게 n -차원 매니폴드의 구조를 가진다.

2단계 (§ 4.8). KL 발산 D_{KL} 은 발산도의 세 조건(이미지 4-5)을 모두 만족한다.

3단계 (§ 1.2, § 4.6, § 4.8). 발산도의 Taylor 전개 2차 항 계수

$$g_{ij}(\theta) = \partial_i \partial_j D_{\text{KL}}[\theta : \theta']|_{\theta'=\theta} = I_{ij}(\theta)$$

가 리만 계량을 정의한다. 이것이 Fisher-Rao 계량이다.

4단계 — 가우시안 매니폴드의 구체적 계량. $(\mu, \sigma) \in \mathbb{R} \times \mathbb{R}_{>0}$ 위에서 Fisher-Rao 계량은

$$ds^2 = \frac{1}{\sigma^2} d\mu^2 + \frac{2}{\sigma^2} d\sigma^2.$$

$\eta = \sqrt{2}\sigma$ 로 치환하면

$$ds^2 = \frac{2}{\eta^2} (d\mu^2 + d\eta^2),$$

즉 표준 Poincaré 계량의 2배다. 이 공간의 단면 곡률은 상수 $K = -\frac{1}{2}$ 이며, 척도 조정 하에서 쌍곡 평면(Poincaré 상반평면)과 등거리동형이다.

다음 단계. 강의 이미지 3의 [???] connection과 Dually flat structure는 Fisher-Rao 계량 위에 올려질 두 가지 구조다. Amari의 α -접속 $\nabla^{(\alpha)}$, 특히 e -접속($\alpha = 1$)과 m -접속($\alpha = -1$)의 쌍대 구조, 그리고 지수족에서 Legendre 변환을 통해 실현되는 쌍대 평탄 구조가 그것이다.

A 적분 부호 아래 미분

Fisher 행렬의 동치 표현(정리 4.2)과 Score의 기댓값(명제 4.1)의 증명에서는 적분과 편미분의 순서 교환이 핵심이다.

정리 A.1 Leibniz 적분법칙 (우세 수렴)

$f(x, \theta)$ 가 (x, θ) 에 연속이고, $|\partial_i f(x, \theta)| \leq g(x)$ 이며 $\int g(x) dx < \infty$ 인 우세함수 g 가 존재하면,

$$\partial_i \int f(x, \theta) dx = \int \partial_i f(x, \theta) dx.$$

이 조건을 정규성 조건(regularity condition)이라 부른다. 가우시안을 포함하는 지수족(exponential family)에서는 이 조건이 항상 성립한다.

B 볼록함수와 Legendre 변환

쌍대 평탄 구조의 핵심에는 Legendre 변환이 있다. 이것은 지수족과 Bregman 발산을 잇는 연결고리다.

정의 B.1 볼록함수

$\psi : \mathbb{R}^n \rightarrow \mathbb{R}$ 이 볼록이라 함은 모든 $x, y \in \mathbb{R}^n$, $t \in [0, 1]$ 에 대해

$$\psi(tx + (1-t)y) \leq t\psi(x) + (1-t)\psi(y).$$

$\psi \in C^2$ 이면 이것은 $H_\psi(\mathbf{x}) \succeq 0$ (양의 반정치)와 동치다.

정의 B.2 Legendre – Fenchel 변환 (켈레 함수)

볼록함수 $\psi : \mathbb{R}^n \rightarrow \mathbb{R}$ 의 켈레 함수는

$$\psi^*(\eta) := \sup_{\theta \in \mathbb{R}^n} [\langle \eta, \theta \rangle - \psi(\theta)].$$

지수족에서는 $\psi(\theta) = \log Z(\theta)$ (로그 분배함수)가 볼록함수이고, 그 Legendre 변환 $\psi^*(\eta)$ 가 쌍대 좌표계 η 를 정의한다. 이 (θ, η) 좌표 쌍이 쌍대 평탄 구조를 이루고, 두 좌표 사이의 거리 함수가 Bregman 발산이 된다.

$$D_\psi[\theta : \theta'] = \psi(\theta) - \psi(\theta') - \langle \nabla \psi(\theta'), \theta - \theta' \rangle.$$

KL 발산은 가우시안 모형에서 이 Bregman 발산의 특수한 경우다.

이후 학습 방향

- 지수족: $p(x; \theta) = h(x) \exp[\langle \theta, T(x) \rangle - \psi(\theta)]$ 의 구조 와 Fisher 행렬 $I_{ij} = \partial_i \partial_j \psi$
- α -접속: $\nabla^{(\alpha)}$, e -접속($\alpha = 1$), m -접속($\alpha = -1$)
- Bregman 발산: 쌍대 평탄 구조 위에서의 "거리"

Cramér – Rao 부등식과 그 기하학적 해석은 § 4.7에서 다루었다.

C 참고문헌

-
- [1] Amari, S. (2016). Information Geometry and Its Applications. Springer.
— 이 노트가 준비하는 강의의 표준 교재.
 - [2] Amari, S. & Nagaoka, H. (2000). Methods of Information Geometry. AMS / Oxford.
— 보다 수학적으로 엄밀한 접근.
 - [3] Lee, J. M. (2013). Introduction to Smooth Manifolds, 2nd ed. Springer.
— 제3장 미분기하학 기초의 참고문헌.
 - [4] Rao, C. R. (1945). Information and the accuracy attainable in the estimation of statistical parameters. Bull. Calcutta Math. Soc., 37, 81 – 91.
— Fisher – Rao 계량의 기원.
 - [5] Kullback, S. & Leibler, R. A. (1951). On information and sufficiency. Ann. Math. Statist., 22(1), 79 – 86.
— KL 발산의 원 논문.
 - [6] Nielsen, F. (2020). An elementary introduction to information geometry. Entropy, 22(10), 1100.
— 무료 공개 입문 논문.