
미적분과 해석학

실수 · 연속성 · 미분 · 적분 · 불록 해석학

정보기하학 기초 시리즈 Vol.1

2026년 6월 16일

차 례

서문	2
1 실수와 $\mathbb{R}^n$ 의 구조	3
1.1 실수의 완비성	3
1.2 $\mathbb{R}^n$ 의 노름과 내적	3
1.3 열린 집합·닫힌 집합·경계	4
1.4 수열의 수렴	5
2 연속성	6
2.1 연속 함수	6
2.2 합성함수의 연속성	6
2.3 최대·최소값 정리	7
2.4 중간값 정리	7
3 1변수 미분	8
3.1 도함수의 정의	8
3.2 미분 법칙	8
3.3 평균값 정리	9
3.4 고계 도함수와 C^k 함수	9
3.5 1변수 Taylor 정리	9
4 다변수 미분	11
4.1 편미분	11
4.2 전미분과 미분가능성	11
4.3 방향 미분과 기울기	12
4.4 Jacobian 행렬과 연쇄법칙	12
4.5 Schwarz 정리 — 편미분 순서 교환	13
4.6 Hessian 행렬	13
5 다변수 Taylor 전개	15


5.1	다변수 Taylor 정리	15
5.2	점근 표기법 O 와 o	15
5.3	다중지수 표기법 (Multi-index)	16
5.4	발산도의 계량 추출 — 정보기하학 연결	16
6	최적화	17
6.1	극값의 1차 필요조건	17
6.2	2차 충분조건 — Hessian 판정	17
6.3	안장점	18
6.4	라그랑주 승수법	18
7	역함수 정리와 음함수 정리	20
7.1	역함수 정리	20
7.2	음함수 정리	20
7.3	응용: 매니폴드의 좌표 변환	20
8	적분론	22
8.1	Riemann 적분과 기본 정리	22
8.2	중적분과 Fubini 정리	22
8.3	변수 변환 — Jacobian 행렬식	23
8.4	적분 부호 아래 미분 — Leibniz 규칙	23
9	볼록 해석학	25
9.1	볼록 집합과 볼록 함수	25
9.2	볼록 함수의 미분 조건	25
9.3	Jensen 부등식	26
9.4	Legendre – Fenchel 변환	26
A	기본 극한 공식 모음	28
B	참고문헌	28

서문

미적분학은 변화를 수학적으로 기술하는 언어다. 어떤 양이 얼마나 빠르게 변하는지, 변화가 쌓이면 무엇이 되는지, 아주 작은 변화는 어떻게 근사되는지 — 이 모든 질문이 미적분학의 영역에 속한다.

정보기하학은 이 언어 없이는 한 페이지도 읽히지 않는다. 통계적 모델이 매니폴드를 이루고, 그 위에 리만 계량이 놓이고, 발산도의 Taylor 전개에서 Fisher 정보가 솟아나는 과정 — 이 모든 단계가 미적분학의 핵심 도구에 의존한다.

이 노트는 그 도구들을 직관부터 쌓는다. 엄밀한 ε - δ 증명보다는 ”왜 이 개념이 필요한가”와 ”이것이 나중에 어디서 쓰이는가”에 무게를 둔다. 단독으로 읽혀도 충분한 자급자족 구조를 목표로 한다.



1 실수와 $\mathbb{R}^n$ 의 구조

미적분학이 살아가는 공간이 $\mathbb{R}^n$ 이다. 이 장은 그 공간의 기본 성질을 짚는다. 특히 실수의 "빈틈 없음"이 미적분학 전체를 떠받치는 기반임을 확인한다.

1.1 실수의 완비성

유리수 $\mathbb{Q}$ 에는 빈틈이 있다. $\sqrt{2}$ 는 유리수가 아니지만, 1, 1.4, 1.41, 1.414, ... 처럼 유리수만으로 이루어진 수열이 $\sqrt{2}$ 에 수렴한다. 이 수열의 "목적지"가 $\mathbb{Q}$ 안에 없다는 것이 유리수의 한계다.

실수 $\mathbb{R}$ 은 이 빈틈을 모두 채운 수 체계다. 더 정확히는 다음 성질로 특성화된다.

정의 1.1 상한 (Supremum)

집합 $A \subseteq \mathbb{R}$ 의 **상한** $\sup A$ 는 A 의 최소 상계다. 즉, (i) 모든 $a \in A$ 에 대해 $a \leq \sup A$ 이고, (ii) $s < \sup A$ 이면 $a > s$ 인 $a \in A$ 가 존재한다.

정리 1.1 상한 완비성 공리

위로 유계인 $\mathbb{R}$ 의 공집합이 아닌 부분집합 A 는 반드시 상한을 가진다.

$$A \neq \emptyset, \quad A \text{가 위로 유계} \implies \sup A \in \mathbb{R} \text{이 존재.}$$

이것이 $\mathbb{R}$ 과 $\mathbb{Q}$ 를 결정적으로 가르는 성질이다. $\mathbb{Q}$ 에서는 $A = \{q \in \mathbb{Q} : q^2 < 2\}$ 가 위로 유계이지만 $\sup A = \sqrt{2} \notin \mathbb{Q}$ 이므로 이 공리가 깨진다.

완비성은 수열의 언어로도 표현된다.

정의 1.2 Cauchy 수열

수열 $\{a_n\}$ 이 **Cauchy 수열**이라 함은, 임의의 $\varepsilon > 0$ 에 대해 $N \in \mathbb{N}$ 이 존재하여 $m, n > N$ 이면 $|a_m - a_n| < \varepsilon$ 임을 뜻한다.

정리 1.2 Cauchy 기준

$\mathbb{R}$ 에서 수열이 수렴할 조건과 Cauchy 수열일 조건은 동치다.

직관: Cauchy 수열은 "항들이 서로 점점 가까워지는" 수열이다. $\mathbb{R}$ 의 완비성은 이런 수열이 반드시 $\mathbb{R}$ 안에서 수렴함을 보장한다.

1.2 $\mathbb{R}^n$ 의 노름과 내적

1차원 실수 $\mathbb{R}$ 을 n 개 복사하면 n 차원 유클리드 공간 $\mathbb{R}^n$ 이 된다. 벡터 $\mathbf{x} = (x_1, \dots, x_n)$ 으로 표현하며, 거리 구조는 내적으로부터 온다.

정의 1.3 유클리드 내적과 노름

$\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 에 대해

$$\text{내적: } \langle \mathbf{x}, \mathbf{y} \rangle := \sum_{i=1}^n x_i y_i,$$

$$\text{노름: } \|\mathbf{x}\| := \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} = \sqrt{\sum_{i=1}^n x_i^2},$$

$$\text{거리: } d(\mathbf{x}, \mathbf{y}) := \|\mathbf{x} - \mathbf{y}\|.$$

노름은 세 가지 핵심 성질을 만족한다: $\|\mathbf{x}\| \geq 0$ (등호는 $\mathbf{x} = \mathbf{0}$), $\|c\mathbf{x}\| = |c| \|\mathbf{x}\|$, $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$ (삼각 부등식).

정리 1.3 Cauchy-Schwarz 부등식

임의의 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 에 대해

$$|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{x}\| \|\mathbf{y}\|.$$

등호는 $\mathbf{x}$ 와 $\mathbf{y}$ 가 평행할 때 성립한다.

Cauchy-Schwarz 부등식은 이 노트 전반에 걸쳐 반복해서 등장하는 도구다. Fisher 정보행렬에서 유도되는 Cramér-Rao 부등식도 본질적으로 이것의 응용이다.

1.3 열린 집합·닫힌 집합·경계

$\mathbb{R}^n$ 위에서 미적분을 하려면 "어느 점 근방"이라는 개념이 필요하다. 그 근방을 수학적으로 포착하는 것이 열린 집합이다.

정의 1.4 열린 공과 열린 집합

점 $\mathbf{a} \in \mathbb{R}^n$ 을 중심으로 반지름 $r > 0$ 의 열린 공:

$$B(\mathbf{a}, r) := \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x} - \mathbf{a}\| < r\}.$$

집합 $U \subseteq \mathbb{R}^n$ 이 열린 집합이라 함은, 모든 $\mathbf{a} \in U$ 에 대해 $B(\mathbf{a}, r) \subseteq U$ 인 $r > 0$ 이 존재함을 뜻한다.

직관: 열린 집합 안의 모든 점은 경계에서 조금 떨어져 있다.

정의 1.5 닫힌 집합·경계·내부

- F 가 닫힌 집합 $\Leftrightarrow F^c = \mathbb{R}^n \setminus F$ 가 열린 집합
- $\mathbf{a}$ 가 A 의 경계점 $\Leftrightarrow$ 임의의 $r > 0$ 에 대해 $B(\mathbf{a}, r)$ 이 A 의 점과 A^c 의 점을 동시에 포함
- A 의 내부 $\mathring{A} := A$ 에 포함되는 열린 집합들의 합집합

예시 1.1 열린 집합과 닫힌 집합의 차이

$\mathbb{R}$ 에서 구간 $(0, 1)$ 은 열린 집합이고 $[0, 1]$ 은 닫힌 집합이다. $[0, 1)$ 은 열리지도 닫히지도 않은 집합이다.

$\mathbb{R}^n$ 에서 통계 모델의 매개변수 공간 $\Theta \subseteq \mathbb{R}^n$ 이 열린 집합이어야 하는 이유: $\sigma > 0$ 이라는 가우시안 모델의 조건처럼, 경계점은 유효한 분포를 정의하지 않는다.

1.4 수열의 수렴

정의 1.6 $\mathbb{R}^n$ 에서의 수열 수렴

수열 $\{\mathbf{x}_k\} \subseteq \mathbb{R}^n$ 이 $\mathbf{a}$ 로 수렴한다 ($\mathbf{x}_k \rightarrow \mathbf{a}$)는 것은, 임의의 $\varepsilon > 0$ 에 대해 $N \in \mathbb{N}$ 이 존재하여 $k > N$ 이면 $\|\mathbf{x}_k - \mathbf{a}\| < \varepsilon$ 임을 뜻한다.

$\mathbb{R}^n$ 에서의 수렴은 각 성분별 수렴과 동치다: $\mathbf{x}_k \rightarrow \mathbf{a} \Leftrightarrow (x_k)_i \rightarrow a_i$ for all i .

정리 1.4 Bolzano – Weierstrass

유계인 $\mathbb{R}^n$ 의 수열은 수렴하는 부분수열을 가진다.

이 정리는 최적화 이론의 기반이다. 함수의 최솟값을 달성하는 점이 존재하는지를 보장할 때 핵심적으로 쓰인다.

2 연속성

연속 함수는 입력의 작은 변화가 출력의 작은 변화로 이어지는 함수다. 이 직관을 수학적으로 포착하면 이후의 모든 미분 이론이 따라온다.

2.1 연속 함수

정의 2.1 연속성 (ε - δ 정의)

함수 $f : U \rightarrow \mathbb{R}^m$ ($U \subseteq \mathbb{R}^n$ 열린 집합)이 점 $\mathbf{a} \in U$ 에서 연속이라 함은, 임의의 $\varepsilon > 0$ 에 대해 $\delta > 0$ 이 존재하여

$$\|\mathbf{x} - \mathbf{a}\| < \delta \implies \|f(\mathbf{x}) - f(\mathbf{a})\| < \varepsilon.$$

f 가 U 위의 모든 점에서 연속이면 f 를 U 위에서 연속이라 한다.

ε - δ 정의의 핵심은 순서다. 먼저 "출력의 오차 한도" ε 이 정해지면, 그 후에 "입력의 허용 범위" δ 를 찾는 것이다. δ 는 ε 과 $\mathbf{a}$ 모두에 의존할 수 있다.

위상적 관점에서는 더 우아하게 표현된다.

정리 2.1 연속성의 위상적 동치

$f : U \rightarrow \mathbb{R}^m$ 이 연속 $\Leftrightarrow \mathbb{R}^m$ 의 임의의 열린 집합 V 에 대해 $f^{-1}(V) := \{\mathbf{x} \in U : f(\mathbf{x}) \in V\}$ 가 U 에서 열린 집합.

예시 2.1 연속 함수의 예

- 다항식 $p(x_1, \dots, x_n)$ 은 $\mathbb{R}^n$ 전체에서 연속이다.
- $f(x, y) = \frac{xy}{x^2 + y^2}$ ($x^2 + y^2 \neq 0$)는 원점을 제외하면 연속이지만, 원점에서는 방향에 따라 극한값이 달라 불연속이다.
- 지수 함수 e^x , 삼각 함수 $\sin x, \cos x$ 는 $\mathbb{R}$ 전체에서 연속이다.

2.2 합성함수의 연속성

명제 2.2 합성의 연속성

$g : U \rightarrow V$ 가 $\mathbf{a}$ 에서 연속이고 $f : V \rightarrow W$ 가 $g(\mathbf{a})$ 에서 연속이면, $f \circ g : U \rightarrow W$ 가 $\mathbf{a}$ 에서 연속이다.

이 명제는 미분의 연쇄법칙 (§ 4.4)의 연속성 버전이다. 복잡한 함수도 단순한 연속 함수들의 합성으로 표현되면 자동으로 연속임을 보장한다.

2.3 최대·최소값 정리

최적화 이론에서 가장 먼저 던지는 질문은 "최소값이 존재하는가"다. 이것을 보장하는 핵심 조건이 콤팩트성이다.

정의 2.2 콤팩트 집합

$K \subseteq \mathbb{R}^n$ 이 콤팩트라 함은 유계이고 닫힌 집합임을 뜻한다. (Heine – Borel 정리에 의해 이것은 "임의의 열린 덮개에서 유한 부분 덮개를 추출 가능"과 동치다.)

정리 2.3 최대·최소값 정리 (Weierstrass)

$K \subseteq \mathbb{R}^n$ 이 콤팩트이고 $f : K \rightarrow \mathbb{R}$ 이 연속이면, f 는 K 위에서 최댓값과 최솟값을 달성한다. 즉 $f(x^*) = \max_K f$ 인 $x^* \in K$ 가 존재한다.

증명 아이디어. $\{f(x_k)\}$ 가 $\sup_K f$ 로 수렴하는 수열을 잡는다. K 가 유계이므로 Bolzano – Weierstrass로 수렴 부분수열 $x_{k_j} \rightarrow x^*$ 을 얻는다. K 가 닫혀 있으므로 $x^* \in K$ 이고, f 의 연속성에 의해 $f(x^*) = \sup_K f$. $\square$

2.4 중간값 정리

정리 2.4 중간값 정리

$f : [a, b] \rightarrow \mathbb{R}$ 이 연속이고 $f(a) \neq f(b)$ 이면, $f(a)$ 와 $f(b)$ 사이의 모든 값 c 에 대해 $f(t^*) = c$ 인 $t^* \in (a, b)$ 가 존재한다.

직관: 연속 함수의 그래프는 끊기지 않으므로, $f(a)$ 에서 $f(b)$ 로 가려면 반드시 중간 높이를 모두 통과해야 한다.

중간값 정리는 방정식의 해 존재를 보장하는 데 자주 쓰인다. $f(a) < 0 < f(b)$ 이면 $f(t^*) = 0$ 인 근이 (a, b) 에 존재한다는 형태로 응용된다.

3 1변수 미분

미분은 함수의 순간 변화율이다. 이 장은 1변수 미분의 핵심 도구를 정리하고, 다변수로 가기 전에 Taylor 정리까지 다룬다.

3.1 도함수의 정의

정의 3.1 도함수

함수 $f : (a, b) \rightarrow \mathbb{R}$ 이 점 x_0 에서 미분가능하다는 것은 다음 극한이 존재함을 뜻한다.

$$f'(x_0) := \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h}.$$

이 극한값을 f 의 x_0 에서의 도함수 또는 미분계수라 한다.

기하학적 의미: 도함수는 $x = x_0$ 에서 함수 그래프의 접선 기울기다. 또는 x_0 근방에서의 순간 변화율로도 해석된다.

미분가능하면 연속이다. 역은 성립하지 않는다. ($f(x) = |x|$ 은 $x = 0$ 에서 연속이지만 미분불가능하다.)

3.2 미분 법칙

정리 3.1 기본 미분 법칙

f, g 가 미분가능하면 다음이 성립한다.

- (i) 선형성: $(af + bg)' = af' + bg'$
- (ii) 곱법칙 (Leibniz): $(fg)' = f'g + fg'$
- (iii) 몫법칙: $\left(\frac{f}{g}\right)' = \frac{f'g - fg'}{g^2} \quad (g \neq 0)$
- (iv) 연쇄법칙: $(f \circ g)'(x) = f'(g(x)) \cdot g'(x)$

이 중 연쇄법칙이 가장 중요하다. "겉미분 $\times$ 속미분"이라는 형태로, 합성함수의 미분을 분해한다.

예시 3.1 연쇄법칙 활용

$h(x) = \log(\sin(x^2))$ 이면, $u = x^2$, $v = \sin u$, $h = \log v$ 로 분해하면:

$$h'(x) = \frac{1}{v} \cdot \cos u \cdot 2x = \frac{2x \cos(x^2)}{\sin(x^2)}.$$

연쇄법칙은 다변수 편미분의 연쇄법칙 (§ 4.4)으로 자연스럽게 확장된다.

3.3 평균값 정리

평균값 정리는 함수값과 도함수를 잇는 가장 기본적인 다리다.

정리 3.2 평균값 정리 (MVT)

$f : [a, b] \rightarrow \mathbb{R}$ 이 $[a, b]$ 에서 연속이고 (a, b) 에서 미분가능하면,

$$f'(c) = \frac{f(b) - f(a)}{b - a}$$

인 $c \in (a, b)$ 가 존재한다.

기하학적 의미: 두 끝점을 잇는 할선(□□)과 같은 기울기를 갖는 접선이 반드시 중간 어딘가에 존재한다.

평균값 정리의 대표적 응용: $f' \equiv 0$ 이면 f 는 상수다. 또한 $|f'(x)| \leq M$ 이면 $|f(b) - f(a)| \leq M|b - a|$ (Lipschitz 조건).

3.4 고계 도함수와 C^k 함수

정의 3.2 고계 도함수와 C^k

f 의 n 차 도함수 $f^{(n)}$ 을 재귀적으로 $(f^{(n)})' = f^{(n+1)}$ 로 정의한다. 함수 f 가 k 번 연속 미분가능($f \in C^k$)이라 함은, f 의 k 차까지의 모든 도함수가 존재하고 연속임을 뜻한다. C^∞ 는 모든 차수의 도함수가 존재하는 경우다.

C^k 의 계층 구조: $C^\infty \subsetneq \dots \subsetneq C^2 \subsetneq C^1 \subsetneq C^0$. 미분기하학에서 매니폴드의 구조를 정의할 때 C^∞ 조건을 요구하는 이유는, 모든 차수의 편미분이 존재해야 기하학적 구조가 매끄럽게 작동하기 때문이다.

3.5 1변수 Taylor 정리

Taylor 정리는 C^n 함수를 다항식으로 근사하는 공식이다.

정리 3.3 Taylor 정리 (1변수)

$f \in C^{n+1}([a, a+h])$ 이면

$$f(a+h) = \sum_{k=0}^n \frac{f^{(k)}(a)}{k!} h^k + R_n(h),$$

나머지 항은 두 가지 형식으로 표현된다.

- Lagrange 형식: $R_n(h) = \frac{f^{(n+1)}(\xi)}{(n+1)!} h^{n+1}$ (ξ : a 와 $a+h$ 사이)
- Peano 형식: $R_n(h) = o(h^n)$, 즉 $R_n(h)/h^n \rightarrow 0$ ($h \rightarrow 0$)

$n = 1$ 이면 $f(a + h) = f(a) + f'(a)h + O(h^2)$ — 선형 근사다. $n = 2$ 이면 $f(a + h) = f(a) + f'(a)h + \frac{1}{2}f''(a)h^2 + O(h^3)$ — 이차 근사다.

Peano 형식의 나머지 $o(h^n)$ 는 $h \rightarrow 0$ 일 때 h^n 보다 빠르게 0으로 간다는 의미로, 근사의 정밀도를 표현한다.

4 다변수 미분

다변수로 넘어오면 "방향"이라는 새로운 차원이 생긴다. 함수값이 변하는 속도는 어느 방향으로 움직이느냐에 따라 달라진다. 이 장은 그 다양한 변화율 개념과 이들의 관계를 다룬다.

4.1 편미분

정의 4.1 편미분

$f: U \rightarrow \mathbb{R}$ ($U \subseteq \mathbb{R}^n$ 열린 집합)에서 i 번째 변수에 대한 편미분은, 나머지 변수를 고정하고 x_i 만 변화시킨 변화율이다.

$$\partial_i f(\mathbf{x}) := \frac{\partial f}{\partial x_i}(\mathbf{x}) := \lim_{h \rightarrow 0} \frac{f(\mathbf{x} + h\mathbf{e}_i) - f(\mathbf{x})}{h},$$

여기서 $\mathbf{e}_i$ 는 i 번째 표준기저 벡터다.

기하학적 의미: $\partial_i f(\mathbf{x})$ 는 x_i 방향으로 자른 단면 곡선의 기울기다.

예시 4.1 편미분 계산

$f(x, y) = x^2y + e^{xy}$ 에서:

$$\begin{aligned}\partial_x f &= 2xy + ye^{xy}, \\ \partial_y f &= x^2 + xe^{xy}.\end{aligned}$$

각각 y 를 상수로 보고 x 에 대해, 또는 x 를 상수로 보고 y 에 대해 미분한다.

주의: 모든 편미분이 존재해도 함수가 연속이 아닐 수 있다. 함수의 "방향별 변화율"이 존재하는 것과, 함수가 전체적으로 매끄럽게 근사되는 것은 별개의 문제다.

4.2 전미분과 미분가능성

편미분은 좌표축 방향의 변화율만 본다. 전미분은 모든 방향을 동시에 고려한 최선의 선형 근사다.

정의 4.2 전미분과 미분가능성

$f: U \rightarrow \mathbb{R}$ 이 $\mathbf{a} \in U$ 에서 미분가능하다는 것은, 선형 사상 $L: \mathbb{R}^n \rightarrow \mathbb{R}$ 이 존재하여

$$\lim_{\mathbf{h} \rightarrow 0} \frac{f(\mathbf{a} + \mathbf{h}) - f(\mathbf{a}) - L(\mathbf{h})}{\|\mathbf{h}\|} = 0$$

임을 뜻한다. 이때 L 을 f 의 $\mathbf{a}$ 에서의 전미분(total derivative)이라 하고 $Df(\mathbf{a})$ 또는 $df_{\mathbf{a}}$ 로 표기한다.

직관: 전미분은 f 를 a 근방에서 선형 함수로 가장 잘 근사한 것이다.

명제 4.1 전미분과 편미분의 관계

f 가 a 에서 미분가능하면:

- (i) f 는 a 에서 연속이다.
- (ii) 모든 $\partial_i f(a)$ 가 존재하고, $df_a(h) = \sum_{i=1}^n \partial_i f(a) h_i = \nabla f(a) \cdot h$.
- (iii) (역방향) 모든 $\partial_i f$ 가 a 근방에서 존재하고 연속이면 f 가 미분가능하다.

$\nabla f(a) = (\partial_1 f(a), \dots, \partial_n f(a))$ 를 f 의 기울기 벡터(gradient)라 한다.

4.3 방향 미분과 기울기

정의 4.3 방향 미분

단위벡터 $v \in \mathbb{R}^n$ ($\|v\| = 1$) 방향으로의 방향 미분:


$$D_v f(a) := \lim_{t \rightarrow 0} \frac{f(a + tv) - f(a)}{t}.$$

f 가 미분가능하면 $D_v f(a) = \nabla f(a) \cdot v$.

Cauchy – Schwarz 부등식에 의해:

$$D_v f = \nabla f \cdot v \leq \|\nabla f\| \|v\| = \|\nabla f\|.$$

등호는 $v = \frac{\nabla f}{\|\nabla f\|}$ 일 때 성립한다. 따라서 기울기 방향이 함수가 가장 빠르게 증가하는 방향이다.



등위선 $f(x) = c$ 와 기울기 ∇f 의 관계

기울기 ∇f 는 등위선에 수직이다. 경사하강법 (gradient descent)은 $-\nabla f$ 방향으로 반복 이동하여 최솟값을 찾는 알고리즘이다.

4.4 Jacobian 행렬과 연쇄법칙

$f: U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^m$ 이 벡터값 함수일 때, 전미분은 행렬로 표현된다.

정의 4.4 Jacobian 행렬

$f = (f_1, \dots, f_m) : U \rightarrow \mathbb{R}^m$ 의 Jacobian 행렬은

$$J_f(\mathbf{x}) := \left(\frac{\partial f_i}{\partial x_j}(\mathbf{x}) \right)_{\substack{1 \leq i \leq m \\ 1 \leq j \leq n}} \in \mathbb{R}^{m \times n}.$$

Jacobian은 모든 편미분을 하나의 행렬로 조직한다. $n = m = 1$ 이면 Jacobian은 1×1 행렬, 즉 스칼라 $f'(x)$ 다.

정리 4.2 다변수 연쇄법칙

$g : U \rightarrow V, f : V \rightarrow W$ 가 모두 미분가능하면 $f \circ g$ 도 미분가능하고,

$$J_{f \circ g}(\mathbf{x}) = J_f(g(\mathbf{x})) \cdot J_g(\mathbf{x}).$$

행렬 곱 형태의 연쇄법칙은 "겉미분 $\times$ 속미분"을 행렬 언어로 표현한 것이다. 정보기하학에서 좌표 변환 시 텐서 성분이 어떻게 변하는지는 이 연쇄법칙의 직접 응용이다.

4.5 Schwarz 정리 — 편미분 순서 교환

정리 4.3 Schwarz (클레로)

$f \in C^2(U)$ 이면, 모든 i, j 에 대해

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}.$$

증명 아이디어. 혼합 차분 $\Delta_{h,k} f = f(\mathbf{x} + h\mathbf{e}_i + k\mathbf{e}_j) - f(\mathbf{x} + h\mathbf{e}_i) - f(\mathbf{x} + k\mathbf{e}_j) + f(\mathbf{x})$ 를 i 방향 먼저, 또는 j 방향 먼저 평균값 정리를 적용하면 같은 극한을 준다. $\square$

C^2 조건이 핵심이다. 편미분이 두 번 존재하기만 해서는 순서 교환이 보장되지 않는다. 정보기하학에서 계량 텐서 $g_{ij} = \partial_i \partial_j D$ 가 대칭행렬인 이유가 정확히 이 정리 때문이다.

4.6 Hessian 행렬

정의 4.5 Hessian 행렬

$f \in C^2(U)$ 에서 점 $\mathbf{a}$ 의 Hessian 행렬은

$$H_f(\mathbf{a}) := (\partial_i \partial_j f(\mathbf{a}))_{1 \leq i, j \leq n} \in \mathbb{R}^{n \times n}.$$

Schwarz 정리에 의해 $H_f(\mathbf{a})$ 는 대칭행렬이다.

Hessian은 함수의 2차 미분 정보를 모두 담는 행렬이다. 함수의 "굽음새(curvature)"를 모든 방향에 대해 동시에 기술한다.

예시 4.2 Hessian 계산

$f(x, y) = x^3 + 2xy + y^2$ 에서:

$$H_f(x, y) = \begin{pmatrix} \partial_x^2 f & \partial_x \partial_y f \\ \partial_y \partial_x f & \partial_y^2 f \end{pmatrix} = \begin{pmatrix} 6x & 2 \\ 2 & 2 \end{pmatrix}.$$

Hessian은 점마다 다른 행렬값을 가질 수 있다. $H_f(0, 0) = \begin{pmatrix} 0 & 2 \\ 2 & 2 \end{pmatrix}$ 이고, $H_f(1, 0) = \begin{pmatrix} 6 & 2 \\ 2 & 2 \end{pmatrix}$ 이다.

5 다변수 Taylor 전개

Taylor 전개는 정보기하학에서 계량 텐서를 "추출"하는 핵심 도구다. 발산도의 Taylor 전개 2차 항 계수가 리만 계량을 정의한다는 사실이 이 장의 내용으로 이해된다.

5.1 다변수 Taylor 정리

정리 5.1 다변수 2차 Taylor 전개

$f \in C^3(U)$, $\mathbf{a} \in U$, $\mathbf{h} \in \mathbb{R}^n$ 에 대해

$$f(\mathbf{a} + \mathbf{h}) = f(\mathbf{a}) + \nabla f(\mathbf{a})^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top H_f(\mathbf{a}) \mathbf{h} + O(\|\mathbf{h}\|^3).$$

증명 아이디어. $\phi(t) := f(\mathbf{a} + t\mathbf{h})$ 로 정의하면 $\phi \in C^3[0, 1]$ 이다. 1변수 Taylor 정리를 $t = 0$ 근방에서 적용한다. 연쇄법칙으로 $\phi'(0) = \nabla f \cdot \mathbf{h}$, $\phi''(0) = \mathbf{h}^\top H_f \mathbf{h}$ 를 확인하면 위 전개식이 얻어진다. $\square$

이 전개식의 세 항은 각각:

- 상수 항 $f(\mathbf{a})$: $\mathbf{a}$ 에서의 함수값
- 1차 항 $\nabla f^\top \mathbf{h}$: $\mathbf{a}$ 근방의 선형 근사
- 2차 항 $\frac{1}{2} \mathbf{h}^\top H_f \mathbf{h}$: 이차 보정항

5.2 점근 표기법 O 와 o

정의 5.1 Big- O 와 little- o

$h \rightarrow 0$ 일 때:

- $f(h) = O(g(h))$: $\|f\| \leq C \|g\|$ 인 상수 $C > 0$ 이 존재. (" f 의 크기는 g 의 상수 배 이하다")
- $f(h) = o(g(h))$: $f(h)/g(h) \rightarrow 0$. (" f 는 g 보다 훨씬 빠르게 0으로 간다")

예시 5.1 Big- O 와 little- o 의 차이

$h \rightarrow 0$ 일 때:

- $h^2 = O(h)$? 아니다. $h^2/h = h \rightarrow 0$ 이므로 오히려 $h^2 = o(h)$.
- $h^2 = O(h^2)$? 그렇다. $h^2/h^2 = 1$.
- $3h + 5h^2 = O(h)$: $|3h + 5h^2|/|h| \rightarrow 3$ (유계).
- $\sin h = h + o(h^2)$: Taylor 전개 $\sin h = h - h^3/6 + \dots$.

Taylor 전개에서 $O(\|h\|^3)$ 는 "3차 이상의 항들의 합"이라는 의미다. $\|h\|$ 가 충분히 작으면 이 항은 2차 항보다 훨씬 작다.

5.3 다중지수 표기법 (Multi-index)

고차 Taylor 전개를 간결하게 쓰려면 다중지수 표기가 편리하다.

정의 5.2 다중지수

$\alpha = (\alpha_1, \dots, \alpha_n) \in \mathbb{N}_0^n$ 을 다중지수라 한다.

- $|\alpha| := \alpha_1 + \dots + \alpha_n$ (차수)
- $\alpha! := \alpha_1! \cdots \alpha_n!$
- $\mathbf{x}^\alpha := x_1^{\alpha_1} \cdots x_n^{\alpha_n}$
- $\partial^\alpha f := \frac{\partial^{|\alpha|} f}{\partial x_1^{\alpha_1} \cdots \partial x_n^{\alpha_n}}$

이 표기로 n 차 Taylor 전개를 쓰면:

$$f(\mathbf{a} + \mathbf{h}) = \sum_{|\alpha| \leq n} \frac{\partial^\alpha f(\mathbf{a})}{\alpha!} \mathbf{h}^\alpha + O(\|h\|^{n+1}).$$

5.4 발산도의 계량 추출 — 정보기하학 연결

발산도에서 리만 계량이 나오는 과정

발산도 $D[P : Q]$ 를 $Q = P + \delta$ 근방에서 Taylor 전개한다.

조건 (1)(2)에서:

$$D[P : P] = 0, \quad \nabla_Q D[P : Q]|_{Q=P} = 0.$$

(두 번째 등식은 $Q = P$ 가 최솟값이므로.)

따라서 최하차 비소거 항이 2차 항이다. 매개변수 좌표 $\theta_P, \theta_Q = \theta_P + d\theta$ 로 표현하면:

$$D[\theta_P : \theta_P + d\theta] = \frac{1}{2} \sum_{i,j} g_{ij}(\theta_P) d\theta_i d\theta_j + O(\|d\theta\|^3),$$

여기서 Hessian이 계량 계수를 정의한다:

$$g_{ij}(\theta_P) = \frac{\partial^2}{\partial s_i \partial s_j} D[\theta_P : s] \Big|_{s=\theta_P}.$$

이것이 Vol.2에서 자세히 다루는 리만 계량의 기원이다.

6 최적화

미적분학의 가장 중요한 응용 중 하나가 최적화다. 어디서 함수가 극값을 가지는가, 그 극값이 극소인가 극대인가, 제약이 있을 때는 어떻게 하는가 — 이 질문들을 다룬다.

6.1 극값의 1차 필요조건

정의 6.1 극값과 임계점

$f : U \rightarrow \mathbb{R}$ 에서 a 가 극솟값(local minimum)이라 함은, a 근방의 x 에 대해 $f(x) \geq f(a)$ 임을 뜻한다. $\nabla f(a) = 0$ 인 점 a 를 임계점(critical point)이라 한다.

정리 6.1 페르마의 정리 (1차 필요조건)

f 가 미분가능하고 a 가 극값점이면, $\nabla f(a) = 0$.

증명. a 가 극솟값이면, 임의의 방향 v 에 대해 $D_v f(a) \geq 0$ 이고 $D_{-v} f(a) \geq 0$. 그런데 $D_{-v} f = -D_v f$ 이므로 $D_v f(a) = 0$ for all v . 따라서 $\nabla f(a) = 0$. $\square$

주의: 역은 성립하지 않는다. 임계점이 극값이 아닐 수 있다 (안장점).

6.2 2차 충분조건 — Hessian 판정

정리 6.2 2차 충분조건

$f \in C^2(U)$ 이고 $\nabla f(a) = 0$ 인 임계점 a 에서:

- $H_f(a) \succ 0$ (양의 정치) $\Rightarrow a$ 는 엄격한 극솟값.
- $H_f(a) \prec 0$ (음의 정치) $\Rightarrow a$ 는 엄격한 극댓값.
- $H_f(a)$ 의 고유값이 양수와 음수를 모두 가지면 a 는 안장점.

직관. Taylor 전개에서 임계점 근방의 함수값은 2차 항이 지배한다.

$$f(a + h) - f(a) \approx \frac{1}{2} h^\top H_f(a) h.$$

이 이차형식이 양이면($H_f \succ 0$) 모든 방향으로 함수값이 증가하므로 극소다.

6.3 안장점


정의 6.2 안장점

임계점 a 에서 Hessian $H_f(a)$ 가 양수와 음수 고유값을 모두 가지면 a 를 안장점(saddle point)이라 한다.

예시 6.1 안장점

$f(x, y) = x^2 - y^2$ 에서 임계점은 원점 $(0, 0)$. $H_f(0, 0) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$.
 x 방향으로서는 극소 (x^2), y 방향으로서는 극대 ($-y^2$). 원점은 안장점이다.

$$f(x, y) = x^2 - y^2$$



안장점은 최적화에서 핵심적으로 등장한다. 딥러닝의 손실 함수 최솟값 탐색에서 안장점은 수렴을 방해하는 주요 장애물이다.

6.4 라그랑주 승수법

제약 조건이 있을 때의 최적화는 라그랑주 승수법으로 체계화된다.

정리 6.3 라그랑주 승수법

$f, g : U \rightarrow \mathbb{R}$ 이 C^1 이고 a 가 $g(x) = 0$ 이라는 제약 하에서 f 의 극값점이며 $\nabla g(a) \neq 0$ 이면,

$$\nabla f(a) = \lambda \nabla g(a)$$

인 $\lambda \in \mathbb{R}$ (라그랑주 승수)가 존재한다.

기하학적 직관. 제약 조건 $g = 0$ 은 $\mathbb{R}^n$ 의 곡면이다. 이 곡면 위에서 f 가 극값을 가지려면, f 의 등위면이 곡면 $g = 0$ 에 접해야 한다. 두 면이 접한다는 것은 법선 벡터 ∇f 와 ∇g 가 평행하다는 뜻이다.

예시 6.2 라그랑주 승수법

단위원 $x^2 + y^2 = 1$ 위에서 $f(x, y) = xy$ 의 최솟값을 구한다.

조건: $\nabla(xy) = \lambda \nabla(x^2 + y^2 - 1)$, 즉 $(y, x) = \lambda(2x, 2y)$.

$y = 2\lambda x$, $x = 2\lambda y$ 이므로 $x = 4\lambda^2 x$. $x \neq 0$ 이면 $\lambda = \pm 1/2$.

$\lambda = 1/2$ 이면 $(x, y) = (1/\sqrt{2}, 1/\sqrt{2})$ 또는 $(-1/\sqrt{2}, -1/\sqrt{2})$, $f = 1/2$. $\lambda = -1/2$ 이면

$(x, y) = (1/\sqrt{2}, -1/\sqrt{2})$ 또는 반대, $f = -1/2$. 최솟값은 $-1/2$.

7 역함수 정리와 음함수 정리

이 장의 두 정리는 미분기하학의 핵심 도구다. 매니폴드의 좌표 변환이 국소적으로 가역임을 보장하는 것이 역함수 정리이고, 제약 조건이 주어진 집합을 매개변수화하는 것이 음함수 정리다.

7.1 역함수 정리

정리 7.1 역함수 정리

$f : U \rightarrow \mathbb{R}^n$ ($U \subseteq \mathbb{R}^n$ 열린 집합)이 C^1 이고 $J_f(a)$ 가 가역이면, a 를 포함하는 열린 집합 $V \subseteq U$ 와 $f(a)$ 를 포함하는 열린 집합 W 가 존재하여 $f|_V : V \rightarrow W$ 가 C^1 -미분동형이다. 즉 f 는 V 위에서 전단사이고, 역함수 $f^{-1} : W \rightarrow V$ 도 C^1 이다.

핵심 메시지: 선형화(Jacobian)가 가역이면 원래 함수도 국소적으로 가역이다.

Jacobian 행렬은 함수의 최선 선형 근사다. 이 근사가 역함수를 가지면($\det J_f \neq 0$), 원래 비선형 함수도 충분히 작은 근방에서는 역함수를 가진다.

통계 모델과의 연결

통계적 모델 $S = \{p(x; \theta)\}$ 에서 동일화 조건 ($\theta \neq \theta' \Rightarrow p(\cdot; \theta) \neq p(\cdot; \theta')$)은 매개변수 사상이 단사임을 말한다. 역함수 정리는 이 사상이 국소적으로 역을 가짐을 $J_\theta \neq 0$ 으로 보장한다. Fisher 정보행렬 $I(\theta) \succ 0$ 이면 이 조건이 충족된다.

7.2 음함수 정리

정리 7.2 음함수 정리

$F : U \times V \rightarrow \mathbb{R}^m$ ($U \subseteq \mathbb{R}^n$, $V \subseteq \mathbb{R}^m$)이 C^1 이고, (a, b) 에서 $F(a, b) = 0$ 이며 $\partial_y F(a, b)$ (y 에 관한 편Jacobian)가 가역이면, a 의 근방 W 와 C^1 함수 $g : W \rightarrow V$ 가 존재하여

$$g(a) = b, \quad F(x, g(x)) = 0 \quad \forall x \in W.$$

직관: 방정식 $F(x, y) = 0$ 이 y 를 x 의 함수로 국소적으로 결정한다. $\partial_y F \neq 0$ 은 F 가 y 방향으로 비퇴화적임을 보장한다.

미분 공식:

$$\frac{\partial g}{\partial x_i} = -(\partial_y F)^{-1} \cdot \partial_{x_i} F.$$

7.3 응용: 매니폴드의 좌표 변환

n -차원 매니폴드의 두 좌표계 θ 와 $\tilde{\theta}$ 의 전환 사상은 $\tilde{\theta} = \psi(\theta)$ 형태다. 이것이 C^∞ -미분동형이어야 한다는 조건이 역함수 정리에 의해 J_ψ 가역으로 귀결된다.

통계 모델에서 두 다른 매개변수화 $\theta = (\mu, \sigma)$ 와 $\tilde{\theta} = (\mu, \sigma^2)$ 의 전환:

$$\psi(\mu, \sigma) = (\mu, \sigma^2), \quad J_\psi = \begin{pmatrix} 1 & 0 \\ 0 & 2\sigma \end{pmatrix}.$$

$\sigma > 0$ 이면 $\det J_\psi = 2\sigma \neq 0$ 이므로 역함수 정리가 적용된다.

8 적분론

적분은 미분의 역연산이자, 합산의 극한이다. 이 장에서는 정보기하학에서 직접 쓰이는 두 도구 — Fubini 정리와 Leibniz 규칙 — 에 집중한다.

8.1 Riemann 적분과 기본 정리

정의 8.1 Riemann 적분

$f : [a, b] \rightarrow \mathbb{R}$ 의 Riemann 적분은 구간을 잘게 분할한 직사각형 넓이의 합의 극한이다. 분할 $a = t_0 < t_1 < \cdots < t_n = b$ 에 대해

$$\int_a^b f(x) dx := \lim_{\max \Delta t_k \rightarrow 0} \sum_{k=1}^n f(t_k^*) \Delta t_k,$$

$\Delta t_k = t_k - t_{k-1}$, $t_k^* \in [t_{k-1}, t_k]$ 임의의 표본점. 이 극한이 분할과 표본점 선택에 무관하게 존재할 때 f 가 Riemann 적분가능하다고 한다.

연속 함수는 Riemann 적분가능하다. 더 넓게는 단조 함수와 유계인 불연속점이 가산 집합인 함수도 가능하다.

정리 8.1 미분·적분의 기본 정리

$f : [a, b] \rightarrow \mathbb{R}$ 이 연속이면

(i) $F(x) := \int_a^x f(t) dt$ 는 C^1 이고 $F'(x) = f(x)$.

(ii) f 의 원시함수 G ($G' = f$)가 존재하면, $\int_a^b f(x) dx = G(b) - G(a)$.

기본 정리는 미분과 적분이 역연산 관계임을 정확히 표현한다.

8.2 중적분과 Fubini 정리

정의 8.2 중적분

$f : D \rightarrow \mathbb{R}$ ($D = [a_1, b_1] \times \cdots \times [a_n, b_n] \subseteq \mathbb{R}^n$)의 중적분은 1변수 적분의 직접 일반화다:

$$\int_D f(\mathbf{x}) d\mathbf{x} = \int_{a_n}^{b_n} \cdots \int_{a_1}^{b_1} f(x_1, \dots, x_n) dx_1 \cdots dx_n.$$

정리 8.2 Fubini 정리

$f : D \rightarrow \mathbb{R}$ 이 연속이면 (또는 절댓값 적분이 유한이면), 적분 순서를 바꾸어도 값이 같다:

$$\iint_D f(x, y) \, dx \, dy = \int_a^b \left(\int_c^d f(x, y) \, dy \right) dx = \int_c^d \left(\int_a^b f(x, y) \, dx \right) dy.$$

8.3 변수 변환 — Jacobian 행렬식

정리 8.3 변수 변환 공식

$T : U \rightarrow V$ 가 C^1 -미분동형이면 ($U, V \subseteq \mathbb{R}^n$ 열린 집합),

$$\int_V f(\mathbf{x}) \, d\mathbf{x} = \int_U f(T(\mathbf{u})) |\det J_T(\mathbf{u})| \, d\mathbf{u}.$$

$|\det J_T|$ 은 Jacobian 행렬식의 절댓값으로, 좌표 변환 시 부피 원소가 어떻게 늘어나거나 줄어드는지를 표현한다.

예시 8.1 극좌표 변환

$T(r, \theta) = (r \cos \theta, r \sin \theta)$ (직교 $\rightarrow$ 극좌표)에서:

$$J_T = \begin{pmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{pmatrix}, \quad \det J_T = r.$$

따라서 $dx \, dy = r \, dr \, d\theta$. 가우시안 적분 $\int_{\mathbb{R}^2} e^{-(x^2+y^2)} \, dx \, dy = \pi$ 는 이 변환으로 계산된다.

8.4 적분 부호 아래 미분 — Leibniz 규칙

정보기하학에서 가장 자주 쓰이는 적분 정리다.

정리 8.4 Leibniz 적분법칙

$f(x, \theta)$ 가 (x, θ) 에 대해 연속이고, $|\partial_\theta f(x, \theta)| \leq g(x)$ ($\int g(x) \, dx < \infty$)인 우세함수 g 가 존재하면,

$$\frac{d}{d\theta} \int_{-\infty}^{\infty} f(x, \theta) \, dx = \int_{-\infty}^{\infty} \frac{\partial f}{\partial \theta}(x, \theta) \, dx.$$

직관: 미분과 적분의 순서를 바꿀 수 있다. 이것을 적분 부호 아래 미분이라 한다.

Fisher 정보와의 연결

확률밀도 $p(x; \theta)$ 에 대해 $\int p(x; \theta) \, dx = 1$ 을 θ 로 미분하면:

$$0 = \frac{d}{d\theta} \int p(x; \theta) \, dx = \int \frac{\partial p}{\partial \theta} \, dx = \int p \cdot \frac{\partial \log p}{\partial \theta} \, dx = \mathbb{E}_\theta \left[\frac{\partial \log p}{\partial \theta} \right].$$

Score 함수의 기댓값이 0인 이유가 바로 Leibniz 규칙에 있다. Fisher 정보행렬의 두 동치 표현 $I_{ij} = \mathbb{E}[s_i s_j] = -\mathbb{E}[\partial_i \partial_j \log p]$ 도 동일한 방식으로 증명된다.

9 볼록 해석학

볼록함수는 "현이 그래프 위에 있는" 함수다. 이 단순한 조건이 Jensen 부등식을 통해 KL 발산의 비음성을 설명하고, Legendre 변환을 통해 정보기하학의 쌍대 구조를 낳는다.

9.1 볼록 집합과 볼록 함수


정의 9.1 볼록 집합과 볼록 함수

집합 $C \subseteq \mathbb{R}^n$ 이 볼록 집합이라 함은, 임의의 $\mathbf{x}, \mathbf{y} \in C$ 와 $t \in [0, 1]$ 에 대해 $t\mathbf{x} + (1-t)\mathbf{y} \in C$ 임을 뜻한다.

함수 $f: C \rightarrow \mathbb{R}$ 이 볼록 함수라 함은

$$f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y}) \quad \forall \mathbf{x}, \mathbf{y} \in C, t \in [0, 1].$$

등호가 $\mathbf{x} = \mathbf{y}$ 일 때만 성립하면 엄격히 볼록이라 한다.



현이 그래프 위에 위치

9.2 볼록 함수의 미분 조건

정리 9.1 볼록 함수의 미분 특성

$f \in C^2(U)$ 에 대해 (볼록 열린 집합 U):

- (i) 1변수: f 가 볼록 $\Leftrightarrow f''(x) \geq 0$ ($\forall x$).
- (ii) 다변수: f 가 볼록 $\Leftrightarrow H_f(\mathbf{x}) \succeq 0$ ($\forall \mathbf{x}$). (양의 반정치 Hessian)
- (iii) 기울기 단조성: f 가 볼록 $\Leftrightarrow (\nabla f(\mathbf{x}) - \nabla f(\mathbf{y}))^\top (\mathbf{x} - \mathbf{y}) \geq 0$.

정리 9.2 볼록 함수의 1차 특성화

f 가 볼록이면, 임의의 $\mathbf{x}, \mathbf{y}$ 에 대해

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^\top (\mathbf{y} - \mathbf{x}).$$

즉 접선이 그래프 아래에 위치한다.

이 성질은 볼록 최적화에서 핵심이다. 임계점이면 전역 최솟값임을 보장하기 때문이다.

9.3 Jensen 부등식

정리 9.3 Jensen 부등식

$\varphi : \mathbb{R} \rightarrow \mathbb{R}$ 이 볼록 함수이고 X 가 확률변수이면

$$\varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)].$$

φ 가 엄격히 볼록이면, 등호는 X 가 상수($X = \mathbb{E}[X]$ a.s.)일 때만 성립한다.

증명 아이디어. 정리 9.2의 접선 부등식을 $x = \mathbb{E}[X]$ 에서 적용하면: $\varphi(X) \geq \varphi(\mathbb{E}[X]) + \varphi'(\mathbb{E}[X])(X - \mathbb{E}[X])$. 양변의 기댓값을 취하면 우변 마지막 항이 소거되어 Jensen 부등식이 얻어진다. $\square$

KL 발산의 비음성 — Jensen 부등식 응용

두 분포 P, Q (밀도 p, q)에 대해 $-\log$ 가 볼록함수이므로:

$$D_{\text{KL}}[P : Q] = \mathbb{E}_P \left[-\log \frac{q(X)}{p(X)} \right] \stackrel{\text{Jensen}}{\geq} -\log \mathbb{E}_P \left[\frac{q(X)}{p(X)} \right] = -\log \int p \cdot \frac{q}{p} dx = -\log 1 = 0.$$

등호: $q(X)/p(X) = 1$ (a.s.), 즉 $p = q$ 일 때. KL 발산의 가장 기본 성질이 볼록 해석학의 직접 귀결이다.

9.4 Legendre – Fenchel 변환

정의 9.2 Legendre – Fenchel 켤레 함수

볼록 함수 $\psi : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$ 의 켤레 함수(conjugate)는

$$\psi^*(\eta) := \sup_{\theta \in \mathbb{R}^n} [\langle \eta, \theta \rangle - \psi(\theta)].$$

$\psi^*(\eta)$ 는 "기울기가 η 인 방향에서 ψ 가 얼마나 '아래로 쳐지는가'를 측정한다.

정리 9.4 Legendre 변환의 핵심 성질

ψ 가 닫힌 볼록 함수이면:

- (i) ψ^* 도 닫힌 볼록 함수다.
- (ii) 이중성: $(\psi^*)^* = \psi$.
- (iii) Fenchel 부등식: $\langle \eta, \theta \rangle \leq \psi(\theta) + \psi^*(\eta)$.
- (iv) ψ 가 C^2 이고 $H_\psi \succ 0$ 이면, $\psi^*(\eta)$ 는 $\theta^* = \nabla \psi^{-1}(\eta)$ 에서 달성된다. 즉 $\nabla \psi^* = (\nabla \psi)^{-1}$.

예시 9.1 이차 함수의 Legendre 변환

$\psi(\theta) = \frac{1}{2}\theta^2$ 에 대해:


$$\psi^*(\eta) = \sup_{\theta} [\eta\theta - \frac{1}{2}\theta^2] = \eta \cdot \eta - \frac{1}{2}\eta^2 = \frac{1}{2}\eta^2.$$

($\frac{d}{d\theta}[\eta\theta - \frac{1}{2}\theta^2] = 0$ 에서 $\theta^* = \eta$.) 자기 자신이 켈레인 함수다.

예시 9.2 로그 분배함수와 Legendre 변환

지수족 $p(x; \theta) = h(x) \exp[\theta T(x) - \psi(\theta)]$ 에서 $\psi(\theta) = \log \int h(x) e^{\theta T(x)} dx$ (로그 분배함수)는 볼록함수다.

그 켈레 $\psi^*(\eta)$ 는 $\eta = \mathbb{E}_{\theta}[T(X)]$ 와 θ 사이의 관계를 역전한 것이다. 이 쌍대 (θ, η) 좌표 쌍이 정보기하학의 쌍대 평탄 구조를 이룬다.



이중성 $(\psi^*)^* = \psi$ 는 볼록 함수와 그 켈레가 완전히 대칭적 관계임을 말한다. 정보기하학에서 이것은 e -좌표 θ 와 m -좌표 η 사이의 쌍대성으로 나타난다.

A 기본 극한 공식 모음

자주 쓰이는 극한값들을 정리한다.

자주 쓰이는 극한

$h \rightarrow 0$ 일 때:

$$\frac{\sin h}{h} \rightarrow 1, \quad \frac{1 - \cos h}{h^2} \rightarrow \frac{1}{2}, \quad \frac{e^h - 1}{h} \rightarrow 1, \quad \frac{\log(1+h)}{h} \rightarrow 1.$$

$n \rightarrow \infty$ 일 때:

$$\left(1 + \frac{x}{n}\right)^n \rightarrow e^x, \quad \frac{\log n}{n} \rightarrow 0, \quad n^{1/n} \rightarrow 1.$$

B 참고문헌

- [1] Rudin, W. (1976). Principles of Mathematical Analysis, 3rd ed. McGraw-Hill.
— 해석학의 표준 교재. 실수의 완비성부터 다변수 미분·적분까지.
- [2] Apostol, T. M. (1974). Mathematical Analysis, 2nd ed. Addison-Wesley.
— Rudin보다 상세한 설명. 다변수 미적분에 강점.
- [3] Munkres, J. R. (1991). Analysis on Manifolds. Westview Press.
— 역함수·음함수 정리부터 미분다양체까지. Vol.2의 직접 예비.
- [4] Boyd, S. & Vandenberghe, L. (2004). Convex Optimization. Cambridge University Press.
— 볼록 해석학의 응용 중심 교재. 무료 공개. <https://web.stanford.edu/~boyd/cvxbook/>
- [5] Rockafellar, R. T. (1970). Convex Analysis. Princeton University Press.
— Legendre 변환·켈레 함수의 엄밀한 이론.