
선형대수

벡터공간 · 선형사상 · 고유값 · 이차형식 · 행렬 미분

정보기하학 기초 시리즈 Vol.2

2026년 6월 16일

차 례

서문	2
1 벡터 공간	3
1.1 벡터 공간의 정의와 예시	3
1.2 부분공간	3
1.3 선형 독립·기저·차원	4
1.4 좌표와 좌표 표현	4
2 선형 사상과 행렬	5
2.1 선형 사상의 정의	5
2.2 행렬 표현	5
2.3 핵(Kernel)과 상(Image)	6
2.4 순위-영인 정리	6
3 행렬 연산	7
3.1 행렬 곱과 역행렬	7
3.2 행렬식	7
3.3 블록 행렬	8
3.4 행렬 함수와 지수 행렬	8
4 내적 공간과 직교성	9
4.1 내적의 정의와 성질	9
4.2 Cauchy-Schwarz와 각도	9
4.3 정규직교기저와 Gram-Schmidt	10
4.4 직교 분해와 사영	10
5 고유값과 대각화	12
5.1 고유값·고유벡터의 정의	12
5.2 특성 다항식	12
5.3 대각화	13


5.4	스펙트럼 정리 — 대칭 행렬	13
6	이차형식과 양의 정치행렬	14
6.1	이차형식	14
6.2	양의 정치·반정치·부정치	14
6.3	Sylvester 기준	15
6.4	Cholesky 분해	15
7	행렬 분해	16
7.1	LU 분해	16
7.2	QR 분해	16
7.3	특이값 분해 (SVD)	16
7.4	분해들 사이의 관계	17
8	좌표 변환과 이중선형 형식	18
8.1	기저 변환과 전이 행렬	18
8.2	합동 변환 — 이차형식의 좌표 변환	18
8.3	이중선형 형식	18
8.4	텐서 곱 — $(0, 2)$ -텐서로 가는 길	19
9	행렬 미분	20
9.1	벡터 미분 — 기울기 벡터	20
9.2	행렬 미분	20
9.3	핵심 공식	21
9.4	응용: 최소제곱법과 Fisher 정보	21
A	트레이스와 유용한 행렬 등식	23
B	참고문헌	23

서문

선형대수는 선형 구조를 다루는 수학이다. "선형"이란 덧셈과 스칼라 배율에 닫혀 있다는 뜻으로, 이 단순한 조건 하나에서 놀랍도록 풍부한 이론이 펼쳐진다.

정보기하학에서 선형대수의 역할은 두 층위에서 작동한다. 첫째, 통계 모델의 매개변수 공간은 $\mathbb{R}^n$ 이고, 이 공간의 기하는 $n \times n$ 행렬인 Fisher 정보행렬로 기술된다. 둘째, 이 행렬이 양의 정치(positive definite)여야 리만 계량이 정의된다 — 이것이 이차형식과 고유값 이론이 필요한 이유다.

이 노트는 그 도구들을 직관부터 쌓는다. 벡터 공간의 추상적 정의에서 출발하여, 고유값 분해와 SVD를 거쳐 행렬 미분까지 한 흐름으로 연결한다.



1 벡터 공간

선형대수의 출발점은 벡터 공간이다. $\mathbb{R}^n$ 의 화살표 벡터만이 아니라, 행렬·다항식·함수도 모두 벡터 공간의 원소가 될 수 있다. 추상적 정의는 이 다양한 대상을 하나의 언어로 묶는다.

1.1 벡터 공간의 정의와 예시

정의 1.1 벡터 공간

체(field) $\mathbb{F}$ (보통 $\mathbb{R}$ 또는 $\mathbb{C}$) 위의 **벡터 공간** V 는 덧셈 $+: V \times V \rightarrow V$ 와 스칼라 곱 $\cdot: \mathbb{F} \times V \rightarrow V$ 가 정의된 집합으로, 다음 8개의 공리를 만족한다.

- (i) $u + v = v + u$ (덧셈 교환)
 - (ii) $(u + v) + w = u + (v + w)$ (덧셈 결합)
 - (iii) 영벡터 $0 \in V: v + 0 = v$ (덧셈 항등원)
 - (iv) $-v \in V: v + (-v) = 0$ (덧셈 역원)
 - (v) $1 \cdot v = v$ (스칼라 항등원)
 - (vi) $c(dv) = (cd)v$ (스칼라 결합)
 - (vii) $c(u + v) = cu + cv$ (분배)
 - (viii) $(c + d)v = cv + dv$ (분배)
- V 의 원소를 **벡터**라 한다.

예시 1.1 벡터 공간의 예

- $\mathbb{R}^n$: n -튜플 $(x_1, \dots, x_n)$ 의 집합. 가장 기본적인 예.
- $M_{m \times n}(\mathbb{R})$: $m \times n$ 실수 행렬 전체.
- $\mathcal{P}_n$: 차수 $\leq n$ 인 실수 다항식 전체. $\{1, x, x^2, \dots, x^n\}$ 이 자연스러운 기저.
- $C([a, b])$: $[a, b]$ 위의 연속 실수 함수 전체. 무한 차원 벡터 공간이다.

1.2 부분공간

정의 1.2 부분공간

V 의 공집합이 아닌 부분 집합 W 가 **부분공간**이라 함은:

- (i) $u, v \in W \Rightarrow u + v \in W$ (덧셈에 닫힘)
- (ii) $c \in \mathbb{F}, v \in W \Rightarrow cv \in W$ (스칼라 곱에 닫힘)

두 조건을 합쳐 쓰면: $\alpha u + \beta v \in W$ for all $u, v \in W, \alpha, \beta \in \mathbb{F}$.

예시 1.2 부분공간


- $\mathbb{R}^3$ 에서 원점을 지나는 평면: $\{(x, y, z) : ax + by + cz = 0\}$.
- 행렬 A 의 영공간(null space): $\text{null}(A) = \{x : Ax = 0\}$.
- 행렬 A 의 열공간(column space): $\text{col}(A) = \{Ax : x \in \mathbb{R}^n\}$.
- 원점을 지나지 않는 직선은 부분공간이 아니다.

1.3 선형 독립·기저·차원

정의 1.3 선형 독립·생성·기저·차원

벡터들 $v_1, \dots, v_k \in V$ 에 대해:

- 선형 독립: $c_1v_1 + \dots + c_kv_k = 0 \Rightarrow c_i = 0$ (모두).
- 생성: 모든 $v \in V$ 를 $v = \sum_i c_iv_i$ 로 표현 가능.
- 기저: 선형 독립이면서 생성하는 집합.
- 차원 $\dim V$: 임의의 기저의 크기. (기저마다 크기가 같다는 것이 비자명한 정리다.)



예시 1.3 표준 기저

$\mathbb{R}^n$ 의 표준 기저: $e_1 = (1, 0, \dots, 0)$, $e_2 = (0, 1, 0, \dots, 0)$, ..., $e_n = (0, \dots, 0, 1)$.
 $\dim \mathbb{R}^n = n$. $\dim M_{m \times n}(\mathbb{R}) = mn$. $\dim \mathcal{P}_n = n + 1$.

1.4 좌표와 좌표 표현

기저 $B = \{b_1, \dots, b_n\}$ 이 고정되면, 모든 $v \in V$ 는 유일하게 $v = c_1b_1 + \dots + c_nb_n$ 으로 표현된다.

정의 1.4 좌표 벡터

기저 B 에 대한 v 의 좌표 벡터: $[v]_B := (c_1, \dots, c_n)^\top \in \mathbb{R}^n$.

좌표는 기저 선택에 의존한다. 같은 벡터가 다른 기저에서 다른 좌표를 가진다. 기저를 바꾸면 좌표가 어떻게 바뀌는지가 § 8.1의 기저 변환 행렬이다.

2 선형 사상과 행렬

선형 사상은 벡터 공간의 구조를 보존하는 함수다. 기저를 고정하면 선형 사상과 행렬이 일대일 대응하며, 이것이 선형대수에서 행렬이 핵심인 이유다.

2.1 선형 사상의 정의

정의 2.1 선형 사상

$T: V \rightarrow W$ 가 선형 사상(linear map)이라 함은

$$T(\alpha u + \beta v) = \alpha T(u) + \beta T(v) \quad \forall u, v \in V, \alpha, \beta \in \mathbb{F}.$$

$V = W$ 이면 선형 연산자(linear operator)라 한다.

직관: 선형 사상은 "모양을 구부리지 않는다." 직선을 직선으로, 격자를 격자로 보낸다. 회전, 반사, 사영, 미분 연산자 모두 선형이다.

예시 2.1 선형 사상의 예

- $T(x) = Ax$ ($A \in M_{m \times n}$): 행렬 곱은 선형 사상.
- 회전: $R_\theta(x, y) = (x \cos \theta - y \sin \theta, x \sin \theta + y \cos \theta)$.
- 미분: $D: \mathcal{P}_n \rightarrow \mathcal{P}_{n-1}$, $D(p) = p'$. 선형.
- $f(x) = x^2$: 비선형. $f(\alpha x) = \alpha^2 x^2 \neq \alpha f(x)$.

2.2 행렬 표현

정리 2.1 선형 사상의 행렬 표현

V 의 기저 $\mathcal{B} = \{b_1, \dots, b_n\}$ 과 W 의 기저 $\mathcal{C} = \{c_1, \dots, c_m\}$ 이 고정되면, 선형 사상 $T: V \rightarrow W$ 는 유일한 행렬 $[T]_{\mathcal{B}}^{\mathcal{C}} \in M_{m \times n}$ 으로 표현된다. 이 행렬의 j 번째 열은 $[T(b_j)]_{\mathcal{C}}$ 다.

$$[T(v)]_{\mathcal{C}} = [T]_{\mathcal{B}}^{\mathcal{C}} [v]_{\mathcal{B}}.$$

선형 사상 $\leftrightarrow$ 행렬은 완전한 대응이다. 두 선형 사상의 합성은 해당 행렬의 곱에 대응한다.

2.3 핵(Kernel)과 상(Image)

정의 2.2 핵과 상

선형 사상 $T : V \rightarrow W$ 에 대해:

$$\ker(T) := \{v \in V : T(v) = 0\} \subseteq V,$$

$$\operatorname{im}(T) := \{T(v) : v \in V\} \subseteq W.$$

행렬 A 에 대해: $\ker(A) = \operatorname{null}(A)$, $\operatorname{im}(A) = \operatorname{col}(A)$.

핵과 상은 모두 부분공간이다. 핵은 "T가 어디서 정보를 잃는가"를, 상은 "T가 어디까지 도달하는가"를 기술한다.

2.4 순위-영인 정리

정리 2.2 순위-영인 정리 (Rank-Nullity)

$T : V \rightarrow W$ 가 선형 사상이고 $\dim V = n$ 이면,

$$\dim \ker(T) + \dim \operatorname{im}(T) = n.$$

$\operatorname{rank}(A) := \dim \operatorname{col}(A)$, $\operatorname{nullity}(A) := \dim \operatorname{null}(A)$ 로 쓰면: $\operatorname{rank}(A) + \operatorname{nullity}(A) = n$ (열의 수).

직관: n 차원 입력 공간 중 $\operatorname{nullity}$ 만큼은 "소멸"되고, 나머지 rank 만큼이 출력 공간에 도달한다.

예시 2.2 순위와 영인

$A = \begin{pmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \end{pmatrix}$ (2×3): 두 행이 비례하므로 $\operatorname{rank}(A) = 1$, $\operatorname{nullity}(A) = 3 - 1 = 2$.

A 의 영공간: $\{x : Ax = 0\}$ 은 2차원 부분공간이다.

3 행렬 연산

3.1 행렬 곱과 역행렬

정의 3.1 행렬 곱

$A \in M_{m \times k}$, $B \in M_{k \times n}$ 에 대해 $(AB)_{ij} = \sum_{\ell=1}^k a_{i\ell}b_{\ell j}$.
이것은 선형 사상 T_B 와 T_A 의 합성 $T_A \circ T_B$ 에 대응한다.

행렬 곱은 일반적으로 교환되지 않는다: $AB \neq BA$.

정의 3.2 역행렬

정방행렬 $A \in M_{n \times n}$ 의 역행렬 A^{-1} 은 $AA^{-1} = A^{-1}A = I_n$ 을 만족하는 행렬이다. 역행렬이 존재하면 A 를 가역(invertible)이라 한다.

명제 3.1 역행렬의 성질

- $(AB)^{-1} = B^{-1}A^{-1}$ (순서 역전)
- $(A^{-1})^T = (A^T)^{-1}$
- $(A^{-1})^{-1} = A$

3.2 행렬식

정의 3.3 행렬식 (Determinant)

정방행렬 $A \in M_{n \times n}$ 의 행렬식 $\det A$ 는 n 개의 열벡터가 이루는 n -차원 "부피"의 부호 있는 배율이다. 재귀적 정의:

$$\det A = \sum_{j=1}^n (-1)^{1+j} a_{1j} \det(M_{1j}),$$

M_{1j} : 1행 j 열을 제거한 $(n-1) \times (n-1)$ 소행렬.

정리 3.2 행렬식의 핵심 성질

- (i) $\det(AB) = \det A \cdot \det B$
- (ii) $\det A \neq 0 \Leftrightarrow A$ 가 가역
- (iii) $\det(A^T) = \det A$
- (iv) 행을 스칼라 c 배하면 $\det$ 도 c 배
- (v) 두 행을 교환하면 $\det$ 의 부호가 바뀐다

기하학적 의미: $|\det A|$ 는 A 의 열벡터들이 이루는 평행면체의 n -차원 부피이고, $\text{sign}(\det A)$ 는 방향(orientation)의 보존 여부다.

예시 3.1 $2 \times 2, 3 \times 3$ 행렬식

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc.$$

$\det \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} = 4 - 6 = -2$. 절댓값 2는 두 행벡터 $(1, 2), (3, 4)$ 가 이루는 평행사변형의 넓이다.

3.3 블록 행렬

행렬을 부분 행렬(블록)로 나누면 구조를 더 잘 볼 수 있다.

명제 3.3 블록 행렬 곱

$$A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}, B = \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix} \text{이면,}$$

$$AB = \begin{pmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{pmatrix}.$$

정의 3.4 Schur 보완

블록 행렬 $M = \begin{pmatrix} A & B \\ C & D \end{pmatrix}$ (A 가역)에 대해 Schur 보완: $M/A := D - CA^{-1}B$.

$$\det M = \det A \cdot \det(M/A).$$

Schur 보완은 통계학에서 조건부 분산 계산에, 최적 제어에서 Riccati 방정식에 등장한다.

3.4 행렬 함수와 지수 행렬

정의 3.5 행렬 지수

정방행렬 A 의 지수 행렬:

$$e^A := \sum_{k=0}^{\infty} \frac{A^k}{k!} = I + A + \frac{A^2}{2!} + \frac{A^3}{3!} + \cdots.$$

이 급수는 항상 수렴한다.

A 가 대각화가능, $A = PDP^{-1}$ 이면: $e^A = Pe^DP^{-1}$, 여기서 $e^D = \text{diag}(e^{\lambda_1}, \dots, e^{\lambda_n})$.

행렬 지수는 연립 미분방정식 $\dot{\mathbf{x}} = A\mathbf{x}$ 의 해 $\mathbf{x}(t) = e^{tA}\mathbf{x}(0)$ 에 직접 등장한다.

4 내적 공간과 직교성

내적은 벡터 사이의 "각도"와 "길이"를 정의한다. 직교성은 선형대수에서 계산을 극적으로 단순화한다.

4.1 내적의 정의와 성질

정의 4.1 내적

$\mathbb{R}$ -벡터 공간 V 위의 내적은 함수 $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$ 로,

- (i) (대칭성) $\langle u, v \rangle = \langle v, u \rangle$
- (ii) (선형성) $\langle \alpha u + \beta v, w \rangle = \alpha \langle u, w \rangle + \beta \langle v, w \rangle$
- (iii) (양의 정치) $\langle v, v \rangle \geq 0$, 등호 $\Leftrightarrow v = 0$

을 만족한다. 이 구조를 갖춘 벡터 공간을 내적 공간이라 한다.

노름: $\|v\| := \sqrt{\langle v, v \rangle}$. 거리: $d(u, v) := \|u - v\|$.

예시 4.1 다양한 내적

- 유클리드: $\langle x, y \rangle = x^T y = \sum_i x_i y_i$ (on $\mathbb{R}^n$).
- 가중: $\langle x, y \rangle_W = x^T W y$ ($W \succ 0$).
- 적분: $\langle f, g \rangle = \int_a^b f(x)g(x) dx$ (on $C([a, b])$).
- 행렬: $\langle A, B \rangle_F = \text{tr}(A^T B)$ (Frobenius 내적).

4.2 Cauchy – Schwarz와 각도

정리 4.1 Cauchy – Schwarz 부등식

내적 공간에서 임의의 u, v 에 대해

$$|\langle u, v \rangle| \leq \|u\| \|v\|.$$

등호는 u 와 v 가 선형 종속(한쪽이 다른 쪽의 스칼라 배)일 때 성립한다.

이 부등식이 코사인 공식을 의미 있게 만든다. $|\langle u, v \rangle| / (\|u\| \|v\|) \leq 1$ 이므로,

$$\cos \theta := \frac{\langle u, v \rangle}{\|u\| \|v\|}$$

가 $[-1, 1]$ 에 속한다. 두 벡터 사이의 각도 θ 가 잘 정의된다.

직교: $\langle \mathbf{u}, \mathbf{v} \rangle = 0$ 이면 $\mathbf{u} \perp \mathbf{v}$.

4.3 정규직교기저와 Gram-Schmidt

정의 4.2 정규직교기저 (ONB)

기저 $\{\mathbf{q}_1, \dots, \mathbf{q}_n\}$ 이 정규직교(orthonormal)라 함은


$$\langle \mathbf{q}_i, \mathbf{q}_j \rangle = \delta_{ij} \quad (\delta_{ij} : \text{Kronecker delta}).$$

정규직교기저가 편리한 이유: 좌표 $c_i = \langle \mathbf{v}, \mathbf{q}_i \rangle$ 로 직접 계산된다. $\mathbf{v} = \sum_i \langle \mathbf{v}, \mathbf{q}_i \rangle \mathbf{q}_i$ (Parseval 등식).

알고리즘 4.1 Gram-Schmidt 정규직교화

선형 독립인 $\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ 로부터 ONB $\{\mathbf{q}_1, \dots, \mathbf{q}_k\}$ 를 구성한다.

1. $\tilde{\mathbf{q}}_1 = \mathbf{v}_1, \quad \mathbf{q}_1 = \tilde{\mathbf{q}}_1 / \|\tilde{\mathbf{q}}_1\|.$
2. $j = 2, \dots, k$ 에 대해: $\tilde{\mathbf{q}}_j = \mathbf{v}_j - \sum_{i=1}^{j-1} \langle \mathbf{v}_j, \mathbf{q}_i \rangle \mathbf{q}_i, \quad \mathbf{q}_j = \tilde{\mathbf{q}}_j / \|\tilde{\mathbf{q}}_j\|.$



Gram-Schmidt: $\mathbf{v}_1, \mathbf{v}_2 \rightarrow \mathbf{q}_1 \perp \mathbf{q}_2$

4.4 직교 분해와 사영

정리 4.2 직교 분해

내적 공간 V 와 유한 차원 부분공간 W 에 대해, $V = W \oplus W^\perp$. 즉 임의의 $\mathbf{v} \in V$ 는 유일하게 $\mathbf{v} = \mathbf{w} + \mathbf{w}^\perp$ ($\mathbf{w} \in W, \mathbf{w}^\perp \in W^\perp$)으로 분해된다.

$\mathbf{w}$ 를 $\mathbf{v}$ 의 W 위 정사영(orthogonal projection)이라 하고 $P_W \mathbf{v}$ 로 표기한다.

정의 4.3 사영 행렬

A 의 열이 W 의 기저를 이룰 때 (A 열만계), W 로의 사영 행렬:

$$P = A(A^\top A)^{-1}A^\top.$$

$P^2 = P$ (멱등), $P^\top = P$ (대칭) 이 특징이다.

최소제곱법 (least squares): $A\mathbf{x} = \mathbf{b}$ 의 정확한 해가 없을 때, $\|A\mathbf{x} - \mathbf{b}\|^2$ 를 최소화하는 해는 $\hat{\mathbf{x}} = (A^T A)^{-1} A^T \mathbf{b}$.

5 고유값과 대각화

고유값과 고유벡터는 선형 변환의 "본질적인 방향과 크기"를 드러낸다. 스펙트럼 정리는 대칭 행렬에서 이 구조가 가장 완벽하게 드러남을 보장한다.

5.1 고유값·고유벡터의 정의

정의 5.1 고유값과 고유벡터

정방행렬 $A \in M_{n \times n}$ 에 대해,

$$Av = \lambda v, \quad v \neq 0$$

를 만족하는 스칼라 λ 를 **고유값(eigenvalue)**, v 를 대응하는 **고유벡터(eigenvector)**라 한다.

기하학적 의미: 고유벡터는 A 에 의한 선형 변환이 방향을 바꾸지 않는 벡터다. 다만 λ 배 만큼 "늘어나거나 줄어든다." $\lambda > 0$ 이면 방향 유지, $\lambda < 0$ 이면 방향 반전.

5.2 특성 다항식

명제 5.1 특성 방정식

λ 가 A 의 고유값 $\Leftrightarrow A - \lambda I$ 가 비가역 $\Leftrightarrow \det(A - \lambda I) = 0$.

$p(\lambda) := \det(A - \lambda I)$ 를 A 의 **특성 다항식**이라 한다. p 는 λ 의 n 차 다항식이고, 고유값은 p 의 근이다.

예시 5.1 2×2 고유값 계산

$$A = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}:$$

$$p(\lambda) = (3 - \lambda)^2 - 1 = \lambda^2 - 6\lambda + 8 = (\lambda - 4)(\lambda - 2).$$

고유값: $\lambda_1 = 4, \lambda_2 = 2$.

$$\lambda_1 = 4: (A - 4I)v = 0 \Rightarrow v_1 = (1, 1)^T.$$

$$\lambda_2 = 2: (A - 2I)v = 0 \Rightarrow v_2 = (1, -1)^T.$$

5.3 대각화

정의 5.2 대각화

$A \in M_{n \times n}$ 이 대각화 가능(diagonalizable)하다는 것은 가역행렬 P 와 대각행렬 $D = \text{diag}(\lambda_1, \dots, \lambda_n)$ 이 존재하여 $A = PDP^{-1}$ 임을 뜻한다. P 의 열벡터는 A 의 고유벡터, D 의 대각 원소는 대응 고유값이다.

정리 5.2 대각화 조건

A 가 대각화 가능 $\Leftrightarrow n$ 개의 선형 독립인 고유벡터가 존재.

충분 조건: n 개의 서로 다른 고유값 $\Rightarrow$ 대각화 가능.

대각화의 위력: $A^k = PD^kP^{-1}$, $e^A = Pe^DP^{-1}$ — 계산이 극도로 단순해진다.

5.4 스펙트럼 정리 — 대칭 행렬

대칭 행렬 ($A = A^T$)은 구조가 가장 좋다.

정리 5.3 스펙트럼 정리 (실수 대칭 행렬)

$A \in M_{n \times n}(\mathbb{R})$ 이 대칭 ($A = A^T$)이면:

- (i) 모든 고유값이 실수다.
- (ii) 서로 다른 고유값에 대응하는 고유벡터는 직교한다.
- (iii) 직교 대각화 가능: 직교행렬 Q ($Q^T Q = I$)와 실수 대각행렬 Λ 가 존재하여

$$A = Q\Lambda Q^T = \sum_{i=1}^n \lambda_i \mathbf{q}_i \mathbf{q}_i^T.$$

마지막 식 $A = \sum_i \lambda_i \mathbf{q}_i \mathbf{q}_i^T$ 는 스펙트럼 분해다. 행렬을 순위-1 행렬들의 가중합으로 분해한다.

Fisher 정보행렬과의 연결

Fisher 정보행렬 $I(\theta)$ 는 대칭 양의 정치 행렬이다. 스펙트럼 정리에 의해 $I(\theta) = Q\Lambda Q^T$ ($\lambda_i > 0$). 이것은 Fisher 정보가 "각 방향으로의 정보량"을 고유값 λ_i , "그 방향"을 고유벡터 $\mathbf{q}_i$ 로 분해함을 뜻한다. 정보가 가장 풍부한 방향 = 가장 큰 고유값 $\lambda_{\max}$ 에 대응하는 $\mathbf{q}_{\max}$.

6 이차형식과 양의 정치행렬

이차형식은 정보기하학의 계량 텐서가 살아 있는 공간이다. 발산도의 Taylor 전개 2차 항이 이차형식이고, 그것이 리만 계량이 되려면 양의 정치여야 한다.

6.1 이차형식

정의 6.1 이차형식

대칭행렬 $G \in M_{n \times n}$ ($G = G^T$)에 대응하는 이차형식은


$$Q_G(\mathbf{v}) := \mathbf{v}^T G \mathbf{v} = \sum_{i,j=1}^n g_{ij} v_i v_j.$$

모든 이차형식 $Q(\mathbf{v}) = \mathbf{v}^T A \mathbf{v}$ 는 대칭행렬 $G = \frac{1}{2}(A + A^T)$ 으로도 표현된다. WLOG 이차형식의 행렬은 대칭으로 잡는다.

예시 6.1 2×2 이차형식과 등고선

$G = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$ 이면 $Q(\mathbf{v}) = 2v_1^2 + 2v_1v_2 + 3v_2^2$.

등고선 $Q(\mathbf{v}) = c$ 는 타원이다 ($G \succ 0$ 일 때). 타원의 주축 방향이 G 의 고유벡터, 축 길이 비가 $1/\sqrt{\lambda_i}$ 에 비례한다.



6.2 양의 정치·반정치·부정치

정의 6.2 정치성 분류

대칭행렬 G 의 분류:

- 양의 정치(PD) $G \succ 0$: $Q_G(\mathbf{v}) > 0 \quad \forall \mathbf{v} \neq 0$
- 양의 반정치(PSD) $G \succeq 0$: $Q_G(\mathbf{v}) \geq 0 \quad \forall \mathbf{v}$
- 음의 정치(ND) $G \prec 0$: $Q_G(\mathbf{v}) < 0 \quad \forall \mathbf{v} \neq 0$
- 부정치(indefinite): Q_G 가 양수와 음수 값을 모두 취함

스펙트럼 정리로 $G = Q\Lambda Q^\top$ 이면 $Q_G(\mathbf{v}) = \mathbf{w}^\top \Lambda \mathbf{w} = \sum_i \lambda_i w_i^2$ ($\mathbf{w} = Q^\top \mathbf{v}$). 따라서:

정리 6.1 고유값에 의한 정치성 판정

대칭행렬 G 에 대해:

- $G \succ 0 \Leftrightarrow$ 모든 고유값 > 0
- $G \succeq 0 \Leftrightarrow$ 모든 고유값 ≥ 0
- G 부정지 $\Leftrightarrow$ 양수와 음수 고유값이 모두 존재

6.3 Sylvester 기준

고유값을 직접 계산하지 않고 PD 여부를 판정하는 실용적 방법이다.

정리 6.2 Sylvester 기준

대칭행렬 G 의 k -차 주소행렬식 $\Delta_k := \det(G_{1:k, 1:k})$ ($k = 1, \dots, n$).

$$G \succ 0 \iff \Delta_1 > 0, \Delta_2 > 0, \dots, \Delta_n > 0.$$

예시 6.2 Sylvester 기준 적용

$$G = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 4 \end{pmatrix}:$$

$$\Delta_1 = 2 > 0, \quad \Delta_2 = 2 \cdot 3 - 1 \cdot 1 = 5 > 0, \quad \Delta_3 = \det G = 2(12 - 1) - 1(4) + 0 = 18 > 0.$$

$$G \succ 0.$$

6.4 Cholesky 분해

정리 6.3 Cholesky 분해

$G \succ 0$ 이면 유일한 하삼각행렬 L (대각 원소 > 0)이 존재하여

$$G = LL^\top.$$

Cholesky 분해는 양의 정치 행렬의 "제공근" 분해다. 연립방정식 $G\mathbf{x} = \mathbf{b}$ 풀기, 다변량 정규분포 난수 생성, 최소제곱법의 수치적 안정 계산에 폭넓게 쓰인다.

리만 계량과 Cholesky

계량 텐서 $g_{ij}(\theta)$ 는 양의 정치이므로 Cholesky 분해를 가진다. $G(\theta) = L(\theta)L(\theta)^\top$. 이것은 점공간 $T_\theta M$ 에서 "정규직교기저"를 추출하는 데 쓰인다. Cholesky의 열벡터들이 그 기저를 이룬다.

7 행렬 분해

행렬을 구조적으로 분해하면 이해도와 계산 효율이 동시에 높아진다. 특히 SVD는 어떤 행렬에도 적용되는 가장 일반적인 분해로, 현대 데이터 과학의 핵심 도구다.

7.1 LU 분해

정의 7.1 LU 분해

정방행렬 A 를 하삼각행렬 L 과 상삼각행렬 U 의 곱으로:

$$A = LU.$$

(주소행렬식이 모두 0이 아닌 경우 항상 존재한다. 일반적으로는 행 교환 $PA = LU$.)

Gauss 소거법의 행렬 버전이다. $Ax = b$ 를 풀 때: 먼저 $Ly = b$ (전진 대입), 다음 $Ux = y$ (후진 대입). 한 번 분해하면 다른 우변 b 에도 재사용 가능하다.

7.2 QR 분해

정의 7.2 QR 분해

$A \in M_{m \times n}$ ($m \geq n$, 열이 선형 독립)에 대해

$$A = QR,$$

$Q \in M_{m \times n}$ (열이 정규직교: $Q^T Q = I_n$), $R \in M_{n \times n}$ (대각 원소가 양수인 상삼각행렬).

Gram-Schmidt 과정을 행렬 형태로 쓰면 QR 분해다. Q 의 열이 A 의 열을 정규직교화한 결과다.

QR 분해는 최소제곱법 계산에서 수치적으로 가장 안정적인 방법이다. $(A^T A)^{-1} A^T = R^{-1} Q^T$.

7.3 특이값 분해 (SVD)

SVD는 행렬 분해의 정점이다. 정방·비정방, 가역·비가역 어떤 행렬에도 적용된다.

정리 7.1 특이값 분해 (SVD)

임의의 $A \in M_{m \times n}$ 에 대해 (단 $r = \text{rank}(A)$)

$$A = U \Sigma V^T,$$

- $U \in M_{m \times m}$: 직교행렬 (좌 특이 벡터)

- $\Sigma \in M_{m \times n}$: 유사대각행렬, $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ (특이값)
- $V \in M_{n \times n}$: 직교행렬 (우 특이 벡터)

$$\begin{array}{c}
 \boxed{\begin{array}{c} A \\ m \times n \end{array}} = \boxed{\begin{array}{c} U \\ m \times m \end{array}} \boxed{\begin{array}{c} \Sigma \\ m \times n \end{array}} \boxed{\begin{array}{c} V^\top \\ n \times n \end{array}} \\
 \begin{array}{ccc} \downarrow & \downarrow & \downarrow \\ \text{열: 좌 특이벡터} & \text{대각: 특이값} & \text{행: 우 특이벡터} \end{array}
 \end{array}$$

SVD는 행렬을 순위-1 행렬들의 합으로 분해한다: $A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^\top$.

예시 7.1 SVD의 응용

- 저순위 근사: $A_k := \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^\top$ 는 $\text{rank} \leq k$ 인 행렬 중 $\|A - A_k\|_F$ 를 최소화한다 (Eckart-Young 정리). 이미지 압축·추천 시스템의 기반.
- 의사역행렬: $A^+ = V \Sigma^+ U^\top$ (Σ^+ : 비영 특이값의 역수). A^+ 는 최소제곱 해 $\hat{\mathbf{x}} = A^+ \mathbf{b}$ 를 준다.
- 조건수: $\kappa(A) = \sigma_1 / \sigma_r$. 연립방정식의 수치 안정성 지표.

7.4 분해들 사이의 관계

명제 7.2 SVD와 고유값 분해의 관계

$A = U \Sigma V^\top$ 이면:

- $A^\top A = V \Sigma^\top \Sigma V^\top$: V 의 열이 $A^\top A$ 의 고유벡터, σ_i^2 이 고유값.
- $AA^\top = U \Sigma \Sigma^\top U^\top$: U 의 열이 $AA^\top$ 의 고유벡터.

특이값 $\sigma_i = \sqrt{\lambda_i(A^\top A)}$.

분해	형태	조건	주요 용도
LU	$A = LU$	정방, 비특이	연립방정식
QR	$A = QR$	$m \geq n$, 열 독립	최소제곱, 고유값
고유값	$A = PDP^{-1}$	정방, 대각화 가능	행렬 함수
SVD	$A = U \Sigma V^\top$	임의	가장 일반적

8 좌표 변환과 이중선형 형식

기저를 바꾸면 벡터의 좌표도, 선형 사상의 행렬도 바뀐다. 이차형식과 이중선형 형식의 변환 법칙은 텐서 언어의 씨앗이다.

8.1 기저 변환과 전이 행렬

기저 $\mathcal{B}$ 에서 기저 $\mathcal{C}$ 로 바꿀 때 좌표가 어떻게 변하는가.

정의 8.1 전이 행렬

$\mathcal{B} = \{\mathbf{b}_j\}$ 에서 $\mathcal{C} = \{\mathbf{c}_i\}$ 로의 기저 전이 행렬 $P = P_{\mathcal{B} \rightarrow \mathcal{C}}$ 는 j 번째 열이 $[\mathbf{b}_j]_{\mathcal{C}}$ 인 행렬이다.

$$[\mathbf{v}]_{\mathcal{C}} = P[\mathbf{v}]_{\mathcal{B}}.$$

선형 사상 T 가 $\mathcal{B}$ 에서 행렬 A 로 표현될 때, $\mathcal{C}$ 에서의 행렬은 $\tilde{A} = P^{-1}AP$ (상사 변환).

8.2 합동 변환 — 이차형식의 좌표 변환

이차형식의 행렬은 선형 사상과 다르게 변환된다.

명제 8.1 합동 변환

이차형식 $Q(\mathbf{v}) = \mathbf{v}^T G \mathbf{v}$ 에서 $\mathbf{v} = P\tilde{\mathbf{v}}$ (기저 변환)로 쓰면:

$$Q(\mathbf{v}) = \tilde{\mathbf{v}}^T (P^T G P) \tilde{\mathbf{v}}.$$

따라서 이차형식의 행렬은 합동 변환 $G \mapsto P^T G P$ 로 변환된다.

선형 사상은 상사 변환 $A \mapsto P^{-1}AP$, 이차형식은 합동 변환 $G \mapsto P^T G P$. 두 변환은 P 가 직교행렬($P^{-1} = P^T$)일 때만 일치한다.

합동 변환은 양의 정지성을 보존한다. $G \succ 0$ 이고 P 가 가역이면 $P^T G P \succ 0$ (§ 2.4 합동 변환 보존 정리).

8.3 이중선형 형식

정의 8.2 이중선형 형식

$B : V \times V \rightarrow \mathbb{R}$ 이 이중선형 형식이라 함은 각 인수에 대해 선형인 함수다. 대칭: $B(\mathbf{u}, \mathbf{v}) = B(\mathbf{v}, \mathbf{u})$.

기저 $\{\mathbf{e}_i\}$ 하에서 $g_{ij} := B(\mathbf{e}_i, \mathbf{e}_j)$ 로 정의하면:

$$B(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top G \mathbf{v} = \sum_{i,j} g_{ij} u_i v_j.$$

이차형식 $Q_G(\mathbf{v}) = B(\mathbf{v}, \mathbf{v})$ 는 이중선형 형식의 특수한 경우다. 이중선형 형식이 대칭이고 양의 정치이면 내적이 된다.

8.4 텐서 곱 — (0,2)-텐서로 가는 길

이중선형 형식은 텐서 언어로 쓰면 (0,2)-텐서다.

정의 8.3 텐서 곱 (직관)

두 선형 범함수 $\alpha, \beta : V \rightarrow \mathbb{R}$ 의 텐서 곱:

$$(\alpha \otimes \beta)(\mathbf{u}, \mathbf{v}) := \alpha(\mathbf{u}) \cdot \beta(\mathbf{v}).$$

임의의 이중선형 형식은 $B = \sum_{i,j} g_{ij} e^i \otimes e^j$ 형태로 쓰인다. e^i : i 번째 쌍대 기저 벡터.

텐서의 핵심: 좌표를 바꾸어도 $B(\mathbf{u}, \mathbf{v})$ 의 값은 변하지 않는다. 합동 변환 $G \mapsto P^\top G P$ 가 정확히 이 좌표 불변성을 보장하는 법칙이다.

리만 매니폴드에서 리만 계량 $g = g_{ij} d\theta^i \otimes d\theta^j$ 는 각 점마다 정의된 양의 정치 대칭 이중선형 형식, 즉 (0,2)-텐서장이다.

9 행렬 미분

행렬과 벡터를 매개변수로 갖는 스칼라 함수를 미분하는 규칙이다. Fisher 정보행렬의 동치 표현과 Cramér–Rao 부등식이 이 언어로 자연스럽게 표현된다.

9.1 벡터 미분 — 기울기 벡터

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ 의 $\mathbf{x}$ 에 대한 미분은 (분모 레이아웃):

정의 9.1 벡터 미분

스칼라 함수 $f(\mathbf{x})$ 의 벡터 미분:

$$\frac{\partial f}{\partial \mathbf{x}} := \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)^\top = \nabla_{\mathbf{x}} f \in \mathbb{R}^n.$$

벡터 함수 $\mathbf{f}: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 의 미분은 Jacobian:

$$\frac{\partial \mathbf{f}}{\partial \mathbf{x}^\top} = J_{\mathbf{f}} = \left(\frac{\partial f_i}{\partial x_j} \right)_{ij} \in M_{m \times n}.$$

예시 9.1 기본 벡터 미분

- $\frac{\partial(\mathbf{a}^\top \mathbf{x})}{\partial \mathbf{x}} = \mathbf{a}$
- $\frac{\partial(\mathbf{x}^\top \mathbf{x})}{\partial \mathbf{x}} = 2\mathbf{x}$
- $\frac{\partial(A\mathbf{x})}{\partial \mathbf{x}^\top} = A$

9.2 행렬 미분

정의 9.2 행렬 미분

스칼라 함수 $f(X)$ ($X \in M_{m \times n}$)의 행렬 미분:

$$\frac{\partial f}{\partial X} := \left(\frac{\partial f}{\partial X_{ij}} \right)_{ij} \in M_{m \times n}.$$

연쇄법칙: $f(g(X))$ 에 대해 $\frac{\partial f}{\partial X} = \frac{\partial f}{\partial g} \cdot \frac{\partial g}{\partial X}$ (텐서 수축 형태).

9.3 핵심 공식

정리 9.1 행렬 미분 핵심 공식

- (i) $\frac{\partial(\mathbf{x}^\top A \mathbf{x})}{\partial \mathbf{x}} = (A + A^\top) \mathbf{x}$ 특히 $A = A^\top$ 이면 $= 2A \mathbf{x}$
- (ii) $\frac{\partial(\mathbf{a}^\top X \mathbf{b})}{\partial X} = \mathbf{a} \mathbf{b}^\top$
- (iii) $\frac{\partial \operatorname{tr}(AX)}{\partial X} = A^\top$
- (iv) $\frac{\partial \operatorname{tr}(X^\top AX)}{\partial X} = (A + A^\top) X$
- (v) $\frac{\partial \log |\det X|}{\partial X} = X^{-\top} = (X^{-1})^\top$ (X 가역)
- (vi) $\frac{\partial \operatorname{tr}(X^{-1}A)}{\partial X} = -(X^{-1}AX^{-1})^\top$

(i) 증명 스케치. $\frac{\partial}{\partial x_k}(\mathbf{x}^\top A \mathbf{x}) = \frac{\partial}{\partial x_k} \sum_{i,j} a_{ij} x_i x_j = \sum_j a_{kj} x_j + \sum_i a_{ik} x_i = (A \mathbf{x})_k + (A^\top \mathbf{x})_k$.
따라서 $\nabla_{\mathbf{x}}(\mathbf{x}^\top A \mathbf{x}) = (A + A^\top) \mathbf{x}$. A 대칭이면 $2A \mathbf{x}$. $\square$

(v) 직관. $\log |\det X| = \sum_i \log |\lambda_i|$ 이고 $\partial_X \log |\det X| = X^{-\top}$ 은 행렬 함수의 로그 미분이다.
이것은 $\frac{d}{dx} \log |x| = 1/x$ 의 행렬 버전이다.

9.4 응용: 최소제곱법과 Fisher 정보

예시 9.2 최소제곱법 — 행렬 미분

손실 함수 $L(\mathbf{w}) = \|\mathbf{A}\mathbf{w} - \mathbf{b}\|^2 = (\mathbf{A}\mathbf{w} - \mathbf{b})^\top (\mathbf{A}\mathbf{w} - \mathbf{b}) = \mathbf{w}^\top A^\top A \mathbf{w} - 2\mathbf{b}^\top A \mathbf{w} + \mathbf{b}^\top \mathbf{b}$.
정리 9.1 (i)와 기본 공식으로:

$$\frac{\partial L}{\partial \mathbf{w}} = 2A^\top A \mathbf{w} - 2A^\top \mathbf{b} = 0.$$

$\hat{\mathbf{w}} = (A^\top A)^{-1} A^\top \mathbf{b}$ (최소제곱 해).

Fisher 정보행렬과 행렬 미분

Fisher 정보행렬의 동치 표현:

$$I_{ij}(\theta) = \mathbb{E}_\theta[\partial_i \log p \cdot \partial_j \log p] = -\mathbb{E}_\theta[\partial_i \partial_j \log p].$$

행렬 언어로: $I(\theta) = \mathbb{E}[\nabla_\theta \log p (\nabla_\theta \log p)^\top] = -\mathbb{E}[H_{\log p}(\theta)]$.

Cramér–Rao 부등식의 행렬 버전:

$$\operatorname{Cov}_\theta[T] \succeq I(\theta)^{-1}.$$

즉 공분산 행렬과 Fisher 역행렬의 차이가 양의 반정치 — 이것이 정보기하학에서 Fisher 행렬이 거리의 역할을 하는 이유다.

정리 9.1 (v)는 Jeffreys prior $\pi(\theta) \propto |\det I(\theta)|^{1/2}$ 의 미분 계산에서도 등장한다.

A 트레이스와 유용한 행렬 등식

정의 A.1 트레이스

정방행렬 A 의 트레이스: $\text{tr}(A) := \sum_{i=1}^n a_{ii}$.

자주 쓰이는 트레이스·행렬 등식

트레이스:

$$\begin{aligned} \text{tr}(A+B) &= \text{tr} A + \text{tr} B, & \text{tr}(cA) &= c \text{tr} A, \\ \text{tr}(AB) &= \text{tr}(BA), & \text{tr}(A^\top) &= \text{tr} A, \\ \text{tr}(A) &= \sum_i \lambda_i(A), & \det(A) &= \prod_i \lambda_i(A). \end{aligned}$$

행렬 역행렬 공식:

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1} \quad (\text{Sherman-Morrison-Woodbury})$$

$$\det(I + AB) = \det(I + BA).$$

$$2 \times 2 \text{ 역행렬: } \begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

$$\text{전치 규칙: } (AB)^\top = B^\top A^\top, \quad (ABC)^\top = C^\top B^\top A^\top.$$

B 참고문헌

- [1] Strang, G. (2016). Introduction to Linear Algebra, 5th ed. Wellesley-Cambridge.
— 직관 중심의 선형대수 표준 교재.
- [2] Horn, R. A. & Johnson, C. R. (2013). Matrix Analysis, 2nd ed. Cambridge University Press.
— 이차형식·고유값·행렬 분석의 심화 참고서.
- [3] Boyd, S. & Vandenberghe, L. (2018). Introduction to Applied Linear Algebra. Cambridge University Press. 무료 공개.
— 응용 관점, VMLS라고도 불림.
- [4] Petersen, K. B. & Pedersen, M. S. (2012). The Matrix Cookbook. Technical University of Denmark.
— 행렬 미분·등식 레퍼런스 모음. 무료 공개.

- [5] Amari, S. (2016). Information Geometry and Its Applications. Springer.
— Fisher 행렬·이중선형 형식의 정보기하학적 맥락.