
확률론과 수리통계

확률 공간 · 분포 · 추정 · Fisher 정보 · KL 발산

정보기하학 기초 시리즈 Vol.4

2026년 6월 16일

차 례

서문	2
1 확률 공간	3
1.1 표본 공간과 사건	3
1.2 σ -대수	3
1.3 확률 측도의 공리	4
1.4 조건부 확률과 독립성	4
2 확률변수와 분포	5
2.1 확률변수의 정의	5
2.2 누적분포함수	5
2.3 확률질량함수 — 이산	5
2.4 확률밀도함수 — 연속	6
3 주요 분포족	7
3.1 이산 분포: Bernoulli · 이항 · Poisson	7
3.2 연속 분포: 균등 · 지수 · 정규	7
3.3 다변량 정규 분포	7
3.4 지수족 (Exponential Family)	8
4 기댓값과 적률	9
4.1 기댓값의 정의와 성질	9
4.2 분산과 공분산	9
4.3 적률과 적률 생성 함수	10
4.4 중요 부등식	10
5 다변량 분포	11
5.1 결합 분포와 주변 분포	11
5.2 조건부 분포와 조건부 기댓값	11
5.3 독립성	11


5.4	다변량 정규 분포의 기하	11
6	수렴과 극한 정리	13
6.1	수렴의 종류	13
6.2	대수의 법칙	13
6.3	중심 극한 정리	13
6.4	델타 방법	14
7	통계적 모델과 추정	15
7.1	통계적 모델	15
7.2	최대가능도 추정량 (MLE)	15
7.3	불편성·일치성·효율성	16
7.4	충분 통계량과 인수분해 정리	16
8	로그가능도와 Score 함수	17
8.1	로그가능도 함수	17
8.3	Fisher 정보행렬 — 두 가지 동치 표현	18
8.4	정규성 조건과 Leibniz 규칙	19
9	정보 이론적 기초	20
9.1	Shannon 엔트로피	20
9.2	KL 발산 — 정의와 성질	20
9.3	KL 발산의 Hessian = Fisher 행렬	21
9.4	Cramér – Rao 부등식 — 정보기하학적 재해석	22
A	Radon – Nikodym 정리 (개요)	23
B	참고문헌	23

서문

확률론은 불확실성을 수학적으로 기술하는 언어다. 주사위 결과처럼 무작위적인 현상을 측도(measure)라는 엄밀한 틀로 포착하고, 그 언어로 추정·검정·예측을 가능하게 한다.

정보기하학에서 확률론이 하는 역할은 두 층위에서 작동한다. 첫째, 통계적 모델 $S = \{p(x; \theta)\}$ 는 확률분포들의 집합이며, 이것이 매니폴드(Vol.3)의 점들이 된다. 둘째, Score 함수·Fisher 정보행렬·KL 발산은 그 매니폴드 위의 리만 계량을 정의하는 핵심 객체다.

이 노트는 그 객체들이 어디서 오는지를 추적한다. 확률 공간의 공리에서 출발하여, 분포족·추정론을 거쳐 Score와 Fisher 정보행렬까지 한 흐름으로 연결한다.



1 확률 공간

확률론의 출발점은 Kolmogorov가 1933년에 정립한 공리 체계다. 직관적인 "가능성"의 개념을 측도 이론의 언어로 엄밀하게 포착한다.

1.1 표본 공간과 사건

정의 1.1 표본 공간과 사건

표본 공간(sample space) Ω 는 실험의 가능한 모든 결과의 집합이다. 개별 결과 $\omega \in \Omega$ 를 표본점, Ω 의 부분집합 $A \subseteq \Omega$ 를 사건(event)이라 한다.

예시 1.1 표본 공간의 예

- 동전 던지기: $\Omega = \{H, T\}$ (이산, 유한)
- 주사위: $\Omega = \{1, 2, 3, 4, 5, 6\}$ (이산, 유한)
- 키 측정: $\Omega = (0, \infty)$ (연속)
- 가우시안 분포의 표본: $\Omega = \mathbb{R}$ (연속)

1.2 σ -대수

모든 부분집합이 "사건"이 되면 측도를 일관되게 정의하기 어렵다. σ -대수는 "측정 가능한 사건들"의 모임을 한정한다.

정의 1.2 σ -대수

$\mathcal{F} \subseteq 2^\Omega$ 가 σ -대수(σ -algebra)라 함은:

- (i) $\Omega \in \mathcal{F}$
- (ii) $A \in \mathcal{F} \Rightarrow A^c \in \mathcal{F}$ (여사건에 닫힘)
- (iii) $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ (가산 합집합에 닫힘)

쌍 $(\Omega, \mathcal{F})$ 을 가측 공간(measurable space)이라 한다.

예시 1.2 σ -대수의 예

- 이산 Ω : $\mathcal{F} = 2^\Omega$ (모든 부분집합).
- $\mathbb{R}$ 위의 보렐 σ -대수 $\mathcal{B}(\mathbb{R})$: $\mathbb{R}$ 의 열린 집합들이 생성하는 최소 σ -대수. 구간 (a, b) , $[a, b]$, $(-\infty, x]$ 등이 모두 포함된다.
- 가장 작은: $\{\emptyset, \Omega\}$. 가장 큰: 2^Ω .

1.3 확률 측도의 공리

정의 1.3 확률 측도와 확률 공간 (Kolmogorov)

$(\Omega, \mathcal{F})$ 위의 확률 측도(probability measure) $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ 은:

- (i) $\mathbb{P}(A) \geq 0$ (비음성)
 - (ii) $\mathbb{P}(\Omega) = 1$ (정규화)
 - (iii) 서로소인 $\{A_n\}$ 에 대해 $\mathbb{P}(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$ (가산 가법성)
- 트리플 $(\Omega, \mathcal{F}, \mathbb{P})$ 을 확률 공간이라 한다.

세 공리로부터 유도되는 성질:

$$\begin{aligned} \mathbb{P}(\emptyset) &= 0, & \mathbb{P}(A^c) &= 1 - \mathbb{P}(A), \\ A \subseteq B &\Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B), & \mathbb{P}(A \cup B) &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B). \end{aligned}$$

1.4 조건부 확률과 독립성

정의 1.4 조건부 확률

$\mathbb{P}(B) > 0$ 일 때, B 가 주어진 조건에서 A 의 조건부 확률:

$$\mathbb{P}(A | B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

정리 1.1 베이즈 정리

$\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$ 이면

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A) \mathbb{P}(A)}{\mathbb{P}(B)}.$$

베이즈 정리는 사전 확률 $\mathbb{P}(A)$ 를 데이터 B 로 업데이트하는 규칙이다. 정보기하학에서 베이즈 추론은 통계 매니폴드 위의 측지선으로 해석된다.

정의 1.5 독립성

두 사건 A, B 가 독립(independent)이라 함은

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \mathbb{P}(B).$$

$\mathbb{P}(B) > 0$ 이면 이것은 $\mathbb{P}(A | B) = \mathbb{P}(A)$ 와 동치다. 즉, B 가 A 에 대한 정보를 주지 않는다.

2 확률변수와 분포

확률변수는 실험 결과를 실수로 대응하는 함수다. 분포는 확률변수의 확률적 거동을 완전히 기술한다.

2.1 확률변수의 정의

정의 2.1 확률변수

확률 공간 $(\Omega, \mathcal{F}, \mathbb{P})$ 위의 확률변수 $X : \Omega \rightarrow \mathbb{R}$ 은 가측 함수다. 즉, $\forall x \in \mathbb{R} : \{\omega \in \Omega : X(\omega) \leq x\} \in \mathcal{F}$.

확률변수는 Ω 위에 정의된 함수지만, 실용적으로는 분포의 관점에서 다룬다. X 의 "확률적 거동"은 X 가 어떤 값을 얼마나 자주 취하는가로 기술된다.


2.2 누적분포함수

정의 2.2 누적분포함수 (CDF)

확률변수 X 의 누적분포함수(CDF):

$$F(x) := \mathbb{P}(X \leq x), \quad x \in \mathbb{R}.$$

CDF의 성질: (i) 단조 비감소, (ii) 우연속 ($\lim_{y \downarrow x} F(y) = F(x)$), (iii) $\lim_{x \rightarrow +\infty} F(x) = 1$, (iv) $\lim_{x \rightarrow -\infty} F(x) = 0$.



2.3 확률질량함수 — 이산

정의 2.3 확률질량함수 (pmf)

이산 확률변수 X (유한 또는 가산 범위)의 확률질량함수:

$$p(x) := \mathbb{P}(X = x) \geq 0, \quad \sum_x p(x) = 1.$$

2.4 확률밀도함수 — 연속

정의 2.4 확률밀도함수 (pdf)

연속 확률변수 X 의 확률밀도함수: $f(x) \geq 0$, $\int_{-\infty}^{\infty} f(x) dx = 1$, 그리고

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx.$$

CDF와 관계: $F(x) = \int_{-\infty}^x f(t) dt$, $F'(x) = f(x)$ (연속점).

두 경우를 통합하는 언어: Radon–Nikodym 정리 (부록 A). 기준 측도 μ 에 대해 $d\mathbb{P} = p d\mu$ 로 밀도 p 를 정의한다.

3 주요 분포족

3.1 이산 분포: Bernoulli·이항·Poisson


정의 3.1 이산 분포

- Bernoulli(p): $X \in \{0, 1\}$, $p(1) = p$, $p(0) = 1 - p$. $\mathbb{E}[X] = p$, $\text{Var}(X) = p(1 - p)$.
- 이항(n, p): X : n 번 독립 Bernoulli 시행에서의 성공 횟수. $p(k) = \binom{n}{k} p^k (1 - p)^{n-k}$. $\mathbb{E}[X] = np$, $\text{Var}(X) = np(1 - p)$.
- Poisson(λ): $p(k) = e^{-\lambda} \lambda^k / k!$, $k = 0, 1, 2, \dots$. $\mathbb{E}[X] = \text{Var}(X) = \lambda$. (n 크고 p 작을 때 이항 분포의 극한: $\lambda = np$ 고정.)

3.2 연속 분포: 균등·지수·정규

정의 3.2 연속 분포

- 균등 $U(a, b)$: $f(x) = \frac{1}{b-a}$ ($a \leq x \leq b$). $\mathbb{E}[X] = \frac{a+b}{2}$, $\text{Var}(X) = \frac{(b-a)^2}{12}$.
- 지수 $\text{Exp}(\lambda)$: $f(x) = \lambda e^{-\lambda x}$ ($x > 0$). $\mathbb{E}[X] = \frac{1}{\lambda}$, $\text{Var}(X) = \frac{1}{\lambda^2}$. 무기역성: $\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$.
- 정규 $\mathcal{N}(\mu, \sigma^2)$: $f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$. $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$.



3.3 다변량 정규 분포

정의 3.3 다변량 정규 분포

$X \in \mathbb{R}^n$ 이 다변량 정규 분포 $\mathcal{N}(\mu, \Sigma)$ 를 따른다는 것은 ($\Sigma \succ 0$):

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right\}.$$

$$\mathbb{E}[X] = \mu, \text{Cov}(X) = \Sigma.$$

등고선 $\{(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2\}$ 는 타원이다. Σ 의 고유벡터가 타원의 주축 방향이고, $\sqrt{\lambda_i}$ 에 비례한 길이이다.

명제 3.1 다변량 정규 분포의 성질

$\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$ 이면:

- (i) 선형 변환: $A\mathbf{X} + \mathbf{b} \sim \mathcal{N}(A\boldsymbol{\mu} + \mathbf{b}, A\Sigma A^\top)$.
- (ii) 주변 분포: $X_i \sim \mathcal{N}(\mu_i, \Sigma_{ii})$.
- (iii) 조건부 분포: $X_1 \mid X_2 = \mathbf{x}_2$ 도 정규 분포다.
- (iv) 독립성: $\Sigma_{12} = 0 \Leftrightarrow X_1 \perp\!\!\!\perp X_2$.

3.4 지수족 (Exponential Family)

지수족은 정보기하학의 핵심 예시이다.

정의 3.4 지수족

지수족(exponential family)은 다음 형태의 분포족이다:

$$p(x; \boldsymbol{\theta}) = h(x) \exp\{\langle \boldsymbol{\theta}, T(x) \rangle - \psi(\boldsymbol{\theta})\},$$

- $\boldsymbol{\theta} = (\theta^1, \dots, \theta^k)$: 자연 매개변수(natural parameters)
- $T(x) = (T_1(x), \dots, T_k(x))$: 충분 통계량(sufficient statistics)
- $h(x)$: 기준 측도의 밀도 (기저 함수)
- $\psi(\boldsymbol{\theta}) = \log \int h(x) e^{\langle \boldsymbol{\theta}, T(x) \rangle} dx$: 로그 분배함수(log-partition function), ψ 는 볼록 함수

정리 3.2 지수족의 핵심 성질

ψ 는 볼록 함수이고:

$$\begin{aligned}\mathbb{E}_{\boldsymbol{\theta}}[T(X)] &= \nabla \psi(\boldsymbol{\theta}), \\ \text{Cov}_{\boldsymbol{\theta}}[T(X)] &= \nabla^2 \psi(\boldsymbol{\theta}) = H_{\psi}(\boldsymbol{\theta}).\end{aligned}$$

더욱이 Fisher 정보행렬 $I(\boldsymbol{\theta}) = H_{\psi}(\boldsymbol{\theta})$ (Hessian of ψ).

예시 3.2 지수족의 예

- 정규: $\boldsymbol{\theta} = (\mu/\sigma^2, -1/(2\sigma^2))$, $T(x) = (x, x^2)$, $\psi(\boldsymbol{\theta}) = \mu^2/(2\sigma^2) + \log(\sqrt{2\pi}\sigma)$.
- Poisson: $\boldsymbol{\theta} = \log \lambda$, $T(x) = x$, $\psi(\boldsymbol{\theta}) = e^{\boldsymbol{\theta}} = \lambda$.
- 이항(n, p): $\boldsymbol{\theta} = \log(p/(1-p))$ (로짓), $T(x) = x$, $\psi(\boldsymbol{\theta}) = n \log(1 + e^{\boldsymbol{\theta}})$.

4 기댓값과 적률

기댓값은 확률변수의 "평균적 값"이다. 분산·공분산·적률은 분포의 형태를 다양한 각도로 요약한다.

4.1 기댓값의 정의와 성질

정의 4.1 기댓값

$$\mathbb{E}[X] := \begin{cases} \sum x p(x) & (\text{이산}) \\ \int_{-\infty}^{\infty} x f(x) dx & (\text{연속}) \end{cases}$$

함수의 기댓값 (LOTUS): $\mathbb{E}[g(X)] = \int g(x)f(x) dx$.

명제 4.1 기댓값의 기본 성질

- (i) 선형성: $\mathbb{E}[\alpha X + \beta Y] = \alpha \mathbb{E}[X] + \beta \mathbb{E}[Y]$
- (ii) 단조성: $X \leq Y \text{ a.s.} \Rightarrow \mathbb{E}[X] \leq \mathbb{E}[Y]$
- (iii) 독립성: $X \perp\!\!\!\perp Y \Rightarrow \mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$

4.2 분산과 공분산

정의 4.2 분산·공분산·상관계수

$$\begin{aligned} \text{Var}(X) &:= \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2, \quad \mu = \mathbb{E}[X] \\ \text{Cov}(X, Y) &:= \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}[XY] - \mu_X \mu_Y \\ \text{Corr}(X, Y) &:= \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} \in [-1, 1] \end{aligned}$$

명제 4.2 분산의 성질

- $\text{Var}(\alpha X + \beta) = \alpha^2 \text{Var}(X)$
- $\text{Var}(X + Y) = \text{Var}(X) + 2\text{Cov}(X, Y) + \text{Var}(Y)$
- $X \perp\!\!\!\perp Y \Rightarrow \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

공분산 행렬 $\Sigma_{ij} = \text{Cov}(X_i, X_j)$ 은 대칭·양의 반정치다.

4.3 적률과 적률 생성 함수

정의 4.3 적률 생성 함수 (MGF)

$$M_X(t) := \mathbb{E}[e^{tX}], \quad t \in (-\delta, \delta) \text{ (존재 구간)}.$$

k 차 적률: $\mathbb{E}[X^k] = M_X^{(k)}(0)$ (k 번 미분 후 $t=0$).

누울 생성 함수(CGF): $K_X(t) := \log M_X(t)$. $K_X'(0) = \mathbb{E}[X]$, $K_X''(0) = \text{Var}(X)$.

MGF는 분포를 유일하게 결정한다 (존재할 때). 독립 합의 MGF: $M_{X+Y}(t) = M_X(t)M_Y(t)$ ($X \perp\!\!\!\perp Y$).

4.4 중요 부등식

정리 4.3 주요 부등식

Jensen 부등식: φ 가 볼록이면 $\mathbb{E}[\varphi(X)] \geq \varphi(\mathbb{E}[X])$.

Markov 부등식: $X \geq 0$ 이면 $\mathbb{P}(X \geq a) \leq \mathbb{E}[X]/a$.

Chebyshev 부등식: $\mathbb{P}(|X - \mu| \geq k\sigma) \leq 1/k^2$.

Cauchy-Schwarz: $(\mathbb{E}[XY])^2 \leq \mathbb{E}[X^2] \mathbb{E}[Y^2]$.

Jensen 부등식과 KL 발산

$-\log$ 가 볼록함수이므로, Jensen 부등식으로:

$$D_{\text{KL}}[P : Q] = \mathbb{E}_P \left[-\log \frac{q(X)}{p(X)} \right] \geq -\log \mathbb{E}_P \left[\frac{q(X)}{p(X)} \right] = -\log 1 = 0.$$

KL 발산의 비음성이 Jensen 부등식의 직접 귀결이다.

5 다변량 분포

5.1 결합 분포와 주변 분포

정의 5.1 결합 분포와 주변 분포

(X, Y) 의 결합 pdf: $f_{X,Y}(x, y) \geq 0$, $\iint f_{X,Y} dx dy = 1$.

주변 pdf:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx.$$

5.2 조건부 분포와 조건부 기댓값

정의 5.2 조건부 분포

$f_X(x) > 0$ 일 때,

$$f_{Y|X}(y | x) := \frac{f_{X,Y}(x, y)}{f_X(x)}, \quad \mathbb{E}[Y | X = x] := \int y f_{Y|X}(y | x) dy.$$

정리 5.1 전기댓값 공식 (Tower Property)

$$\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y | X]].$$

5.3 독립성

정의 5.3 독립 확률변수

X 와 Y 가 독립($X \perp Y$)이라 함은 $f_{X,Y}(x, y) = f_X(x) f_Y(y)$.

일반적으로: $f_{Y|X}(y|x) = f_Y(y)$ — X 를 알아도 Y 에 대한 정보가 없다.

독립이면 $\text{Cov}(X, Y) = 0$ 이지만, 역은 일반적으로 성립하지 않는다.

5.4 다변량 정규 분포의 기하

다변량 정규 분포의 기하는 공분산 행렬 Σ 로 완전히 결정된다.

정의 5.4 Mahalanobis 거리

$\mathbf{x}$ 와 $\boldsymbol{\mu}$ 사이의 Mahalanobis 거리:

$$d_{\Sigma}(\mathbf{x}, \boldsymbol{\mu}) := \sqrt{(\mathbf{x} - \boldsymbol{\mu})^{\top} \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})}.$$

등고선 $\{d_{\Sigma}(\mathbf{x}, \boldsymbol{\mu}) = c\}$ 는 타원이다. Σ^{-1} 이 내적으로 작동하는 리만 계량이다. 표준화 $\mathbf{z} = \Sigma^{-1/2}(\mathbf{x} - \boldsymbol{\mu})$ 로 $d_{\Sigma} = \|\mathbf{z}\|$ (유클리드 거리).

정보기하학의 Fisher-Rao 거리는 이 아이디어를 통계 매니폴드 위에서 일반화한 것이다.

6 수렴과 극한 정리

확률론에서 극한 정리들은 통계 추정량의 점근적 행동을 기술한다. 큰 표본에서 추정량이 어떻게 거동하는지가 통계 이론의 핵심이다.

6.1 수렴의 종류

정의 6.1 확률 수렴의 종류

수열 $\{X_n\}$ 이 X 로 수렴하는 네 가지 방식:

- 거의 확실한 수렴 (a.s.): $\mathbb{P}(\lim_{n \rightarrow \infty} X_n = X) = 1$.
- 확률 수렴 ($\xrightarrow{\mathbb{P}}$): $\forall \varepsilon > 0: \mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0$.
- L^2 수렴 (평균제곱 수렴): $\mathbb{E}[(X_n - X)^2] \rightarrow 0$.
- 분포 수렴 ($\xrightarrow{d}$): $F_{X_n}(x) \rightarrow F_X(x)$ (F_X 의 모든 연속점 x 에서).

수렴의 강도 관계:

$$\text{a.s.} \Rightarrow \xrightarrow{\mathbb{P}} \Leftarrow L^2 \quad \text{그리고} \quad \xrightarrow{\mathbb{P}} \Rightarrow \xrightarrow{d}.$$

6.2 대수의 법칙

정리 6.1 대수의 법칙 (LLN)

$X_1, X_2, \dots \stackrel{\text{iid}}{\sim}, \mathbb{E}[|X_1|] < \infty, \mu = \mathbb{E}[X_1]$.

약 대수의 법칙 (WLLN): $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} \mu$.

강 대수의 법칙 (SLLN): $\bar{X}_n \rightarrow \mu$ a.s.

직관: 충분히 많은 독립 관측을 평균하면 반드시 기댓값으로 수렴한다. 통계적 추정의 일관성 (consistency)이 WLLN에서 나온다.

6.3 중심 극한 정리

정리 6.2 중심 극한 정리 (CLT)

$X_1, X_2, \dots \stackrel{\text{iid}}{\sim}, \mathbb{E}[X_i] = \mu, \text{Var}(X_i) = \sigma^2 < \infty$.

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} = \frac{\sum_{i=1}^n (X_i - \mu)}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1).$$

CLT는 분포와 무관하게 표본평균의 분포가 정규 분포로 수렴함을 말한다. n 이 충분히 크면 $\bar{X}_n \approx \mathcal{N}(\mu, \sigma^2/n)$.

6.4 델타 방법

정리 6.3 델타 방법

$\sqrt{n}(T_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ 이고 g 가 μ 에서 미분가능하면,

$$\sqrt{n}(g(T_n) - g(\mu)) \xrightarrow{d} \mathcal{N}(0, [g'(\mu)]^2 \sigma^2).$$

직관: $g(T_n) \approx g(\mu) + g'(\mu)(T_n - \mu)$ 의 선형 근사를 CLT에 적용한다.

예시 6.1 분산 안정화 변환

$\hat{p} = \bar{X}_n$ (Bernoulli 표본, $\text{Var}(\hat{p}) = p(1-p)/n$)에서 $g(p) = \arcsin(\sqrt{p})$ (분산 안정화)를 적용하면: $\sqrt{n}(g(\hat{p}) - g(p)) \xrightarrow{d} \mathcal{N}(0, 1/4)$ — 분산이 p 에 무관해진다.

7 통계적 모델과 추정

통계 추론은 관측 데이터로부터 미지의 매개변수를 추정하는 과정이다.

7.1 통계적 모델

정의 7.1 통계적 모델 (매개변수족)

통계적 모델은 같은 표본공간 위의 확률분포 집합:

$$S = \{p(x; \theta) : \theta = (\theta^1, \dots, \theta^n) \in \Theta\}, \quad \Theta \subseteq \mathbb{R}^n \text{ (열린 집합)}.$$

동일화 조건: $\theta \neq \theta' \Rightarrow p(\cdot; \theta) \neq p(\cdot; \theta')$.

동일화 조건이 없으면 매개변수와 분포의 대응이 일대일이 아니어서 통계적 추론이 불가능하다.

7.2 최대가능도 추정량 (MLE)

정의 7.2 가능도와 MLE

관측값 $x_1, \dots, x_n$ (i.i.d.)에 대해:

가능도 함수: $L(\theta) = \prod_{i=1}^n p(x_i; \theta)$.

로그 가능도: $\ell(\theta) = \sum_{i=1}^n \log p(x_i; \theta)$.

최대가능도 추정량 (MLE): $\hat{\theta}_{\text{MLE}} = \arg\max_{\theta \in \Theta} \ell(\theta)$.

내부 극솟값이면 Score 방정식 (§ 8.2)이 필요조건이다.

예시 7.1 정규 분포의 MLE

$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$:

$$\ell(\mu, \sigma) = -n \log(\sqrt{2\pi}\sigma) - \frac{1}{2\sigma^2} \sum_i (x_i - \mu)^2.$$

$$\partial_\mu \ell = 0: \hat{\mu} = \bar{x} = \frac{1}{n} \sum x_i. \quad \partial_\sigma \ell = 0: \hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2.$$

7.3 불편성·일치성·효율성

정의 7.3 추정량의 성질

추정량 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 에 대해:

- 불편성: $\mathbb{E}_{\theta}[\hat{\theta}] = \theta \quad (\forall \theta)$
- 일치성: $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta \quad (n \rightarrow \infty)$
- 효율성: $\text{Var}(\hat{\theta}) = [I(\theta)]^{-1}$ (하한 달성)

MLE는 regularity 조건 하에서:

- 일치추정량이다.
- 점근 불편: $\sqrt{n}(\hat{\theta}_{\text{MLE}} - \theta) \xrightarrow{d} \mathcal{N}(0, I(\theta)^{-1})$.
- 점근 효율: Cramér-Rao 하한을 점근적으로 달성.

7.4 충분 통계량과 인수분해 정리

정의 7.4 충분 통계량

통계량 $T(X)$ 가 θ 에 대해 충분(sufficient)이라 함은, $T(X) = t$ 가 주어진 조건에서 X 의 조건부 분포가 θ 에 무관함을 뜻한다.

정리 7.2 Fisher 인수분해 정리

$T(\mathbf{x})$ 가 θ 에 대해 충분 $\Leftrightarrow$

$$p(\mathbf{x}; \theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$$

인 함수 g, h 가 존재한다 (h 는 θ 에 무관).

지수족에서 $T(x)$ 가 자연스러운 충분 통계량이다: $p(x; \theta) = h(x) \exp\{\langle \theta, T(x) \rangle - \psi(\theta)\}$ 의 인수분해 구조.

8 로그가능도와 Score 함수

이 장은 정보기하학의 직접적 기반이다. Score 함수와 Fisher 정보행렬은 통계 모델을 리만 매니폴드로 만드는 핵심 객체다.


8.1 로그가능도 함수

정의 8.1 로그가능도

단일 관측 x 에 대한 로그가능도:

$$\ell(\theta; x) := \log p(x; \theta).$$

로그가능도는 "매개변수 θ 에서 데이터 x 가 얼마나 그럴듯한가"를 나타낸다. θ 의 함수로 보면, 가능도 지형(likelihood landscape)을 형성한다.



8.2 Score 함수와 기댓값 = 0

정의 8.2 Score 함수

Score 함수:

$$s_i(\theta; x) := \frac{\partial \ell}{\partial \theta^i}(\theta; x) = \frac{\partial \log p(x; \theta)}{\partial \theta^i} = \frac{\partial_i p(x; \theta)}{p(x; \theta)}.$$

벡터 형식: $\mathbf{s}(\theta; x) = \nabla_{\theta} \ell(\theta; x)$.

Score는 로그가능도의 기울기 벡터다. MLE는 Score 방정식 $\sum_i \mathbf{s}(\theta; x_i) = 0$ 의 해다.

정리 8.1 Score의 기댓값

정규성 조건이 성립하면:

$$\mathbb{E}_{\theta}[\mathbf{s}(\theta; X)] = 0.$$

증명. $\int p(x; \theta) dx = 1$ 을 θ^i 로 미분 (Leibniz 규칙):

$$0 = \partial_i \int p(x; \theta) dx = \int \partial_i p(x; \theta) dx = \int p(x; \theta) \cdot \frac{\partial_i p}{p} dx = \mathbb{E}_\theta[s_i(\theta; X)]. \quad \square \quad (1)$$

Score의 기댓값이 0이라는 사실이 다음 장 Fisher 정보행렬의 두 동치 표현을 연결하는 핵심이다.

8.3 Fisher 정보행렬 — 두 가지 동치 표현

정의 8.3 Fisher 정보행렬

$$I_{ij}(\theta) := \mathbb{E}_\theta[s_i(\theta; X) s_j(\theta; X)] = \mathbb{E}_\theta \left[\frac{\partial \log p}{\partial \theta^i} \cdot \frac{\partial \log p}{\partial \theta^j} \right].$$

행렬 형식: $I(\theta) = \mathbb{E}_\theta[\mathbf{s} \mathbf{s}^\top]$.

정리 8.2 Fisher 정보의 동치 표현

정규성 조건 하에서:

$$I_{ij}(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2 \log p(X; \theta)}{\partial \theta^i \partial \theta^j} \right] = -\mathbb{E}_\theta[H_\ell(\theta; X)]_{ij}.$$

즉 $I(\theta) = -\mathbb{E}_\theta[H_\ell(\theta; X)]$ (로그가능도 Hessian의 기댓값의 음수).

증명. $\mathbb{E}_\theta[s_j] = 0$ 을 θ^i 로 미분:

$$\begin{aligned} 0 &= \partial_i \int p s_j dx = \int (\partial_i p) s_j dx + \int p (\partial_i s_j) dx \\ &= \int p s_i s_j dx + \int p \partial_i \partial_j \log p dx = I_{ij} + \mathbb{E}_\theta[\partial_i \partial_j \log p]. \end{aligned} \quad (2)$$

따라서 $I_{ij} = -\mathbb{E}_\theta[\partial_i \partial_j \log p]$. □

명제 8.3 Fisher 행렬의 양의 정칙성

동일화 조건이 성립하면 $I(\theta) \succ 0$.

증명 스케치. $\mathbf{v}^\top I(\theta) \mathbf{v} = \mathbb{E}_\theta[(\mathbf{v} \cdot \mathbf{s})^2] = \text{Var}_\theta[\mathbf{v} \cdot \mathbf{s}] \geq 0$. 등호는 $\mathbf{v} \cdot \mathbf{s} = 0$ a.s. 이때 동일화 조건으로 $\mathbf{v} = 0$. □

예시 8.1 가우시안 분포의 Fisher 행렬

$$p(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right):$$

$$\partial_\mu \log p = \frac{x - \mu}{\sigma^2}, \quad \partial_\sigma \log p = -\frac{1}{\sigma} + \frac{(x - \mu)^2}{\sigma^3}.$$

$\mathbb{E}[(X - \mu)^4] = 3\sigma^4$ 를 이용하면:

$$I(\mu, \sigma) = \begin{pmatrix} 1/\sigma^2 & 0 \\ 0 & 2/\sigma^2 \end{pmatrix}.$$

이것이 가우시안 매니폴드의 Fisher-Rao 계량 $g_{ij} = I_{ij}$ 다 (Vol.3).

8.4 정규성 조건과 Leibniz 규칙

Fisher 정보의 두 동치 표현이 유효하려면 미분과 적분의 순서 교환이 필요하다.

정리 8.4 Leibniz 적분법칙 (정규성 조건)

$|\partial_i \log p(x; \theta) \cdot p(x; \theta)| \leq g(x)$, $\int g \, dx < \infty$ 인 우세함수 g 가 존재하면:

$$\partial_i \int p(x; \theta) \, dx = \int \partial_i p(x; \theta) \, dx.$$

이 조건을 정규성 조건(regularity condition)이라 한다. 지수족에서는 항상 성립한다.

9 정보 이론적 기초

정보 이론은 불확실성을 정량화한다. Shannon 엔트로피와 KL 발산은 분포들 사이의 "정보 거리"를 측정하며, 이것이 리만 계량으로 이어진다.

9.1 Shannon 엔트로피

정의 9.1 Shannon 엔트로피

확률분포 P (밀도 p)의 Shannon 엔트로피:

$$H(P) := -\mathbb{E}_P[\log p(X)] = -\int p(x) \log p(x) dx.$$

이산의 경우: $H(P) = -\sum_x p_x \log p_x \geq 0$.

엔트로피는 불확실성의 척도다. 분포가 집중될수록 H 가 작고, 균등분포에서 H 가 최대다.

명제 9.1 최대 엔트로피

유한 $|\Omega| = n$ 인 이산 경우: $H(P) \leq \log n$, 등호는 균등분포 $p_x = 1/n$ 일 때.

9.2 KL 발산 — 정의와 성질

정의 9.2 KL 발산

두 분포 P, Q (밀도 p, q)에 대해:

$$D_{\text{KL}}[P : Q] := \mathbb{E}_P \left[\log \frac{p(X)}{q(X)} \right] = \int p(x) \log \frac{p(x)}{q(x)} dx.$$

정리 9.2 KL 발산의 기본 성질

- (i) 비음성: $D_{\text{KL}}[P : Q] \geq 0$, 등호 $\Leftrightarrow P = Q$.
- (ii) 비대칭성: 일반적으로 $D_{\text{KL}}[P : Q] \neq D_{\text{KL}}[Q : P]$.
- (iii) 삼각 부등식 불성립: D_{KL} 은 거리가 아니다.
- (iv) 분해: $D_{\text{KL}}[P : Q] = H(P, Q) - H(P)$ ($H(P, Q) = -\mathbb{E}_P[\log q]$: 교차 엔트로피).

(i) 증명 (Jensen). $-\log$ 가 볼록이므로: $D_{\text{KL}}[P : Q] = \mathbb{E}_P[-\log(q/p)] \geq -\log \mathbb{E}_P[q/p] = -\log 1 = 0$. $\square$

예시 9.1 가우시안 KL 발산

$\mathcal{N}(\mu, \sigma^2)$ 과 $\mathcal{N}(\mu', \sigma'^2)$ 사이:

$$D_{\text{KL}}[\mathcal{N}(\mu, \sigma^2) : \mathcal{N}(\mu', \sigma'^2)] = \log \frac{\sigma'}{\sigma} + \frac{\sigma^2 + (\mu - \mu')^2}{2\sigma'^2} - \frac{1}{2}.$$

$\mu \leftrightarrow \mu', \sigma \leftrightarrow \sigma'$ 로 교환하면 다른 값이 나온다.

9.3 KL 발산의 Hessian = Fisher 행렬

이것이 정보기하학에서 가장 핵심적인 연결이다.

정리 9.3 KL 발산의 Taylor 전개 — Fisher 계량의 기원

$D_{\text{KL}}[\theta : \theta'] := D_{\text{KL}}[p(\cdot; \theta) : p(\cdot; \theta')]$ 로 쓰면:

$$\frac{\partial^2}{\partial \theta'^i \partial \theta'^j} D_{\text{KL}}[\theta : \theta'] \Big|_{\theta'=\theta} = I_{ij}(\theta).$$

또한 $\theta' \rightarrow \theta$ 극한에서:

$$D_{\text{KL}}[\theta : \theta + d\theta] = \frac{1}{2} \sum_{i,j} I_{ij}(\theta) d\theta^i d\theta^j + O(|d\theta|^3).$$

증명. $D_{\text{KL}}[\theta : \theta'] = \int p(x; \theta) [\log p(x; \theta) - \log p(x; \theta')] dx$.

θ' 에 대해 두 번 미분 (θ 고정):

$$\partial_{j'} D_{\text{KL}} = - \int p(x; \theta) \partial_{j'} \log p(x; \theta') dx, \quad (3)$$

$$\partial_{i'} \partial_{j'} D_{\text{KL}} = - \int p(x; \theta) \partial_{i'} \partial_{j'} \log p(x; \theta') dx. \quad (4)$$

$\theta' = \theta$ 로 놓으면: $= -\mathbb{E}_{\theta}[\partial_i \partial_j \log p(X; \theta)] = I_{ij}(\theta)$. □

계량 추출의 전체 그림

$$\underbrace{D_{\text{KL}}[\theta : \theta + d\theta]}_{\text{KL 발산 (정보 이론)}} = \frac{1}{2} \sum_{i,j} \underbrace{I_{ij}(\theta)}_{\text{Fisher 정보 (통계)}} d\theta^i d\theta^j + O(|d\theta|^3) \longleftrightarrow \underbrace{ds^2 = g_{ij} d\theta^i d\theta^j}_{\text{리만 계량 (기하)}}.$$

KL 발산의 "작은 분리"를 Taylor 전개하면 이차형식이 나오고, 그 계수 행렬이 Fisher 정보행렬이며, 이것이 리만 계량이 된다. 확률론(분포)·통계(추정)·기하(매니폴드)가 이 한 등식으로 수렴한다.

9.4 Cramér–Rao 부등식 — 정보기하학적 재해석

정리 9.4 Cramér–Rao 부등식

$T(X)$ 가 θ (스칼라)의 비편향 추정량이면:

$$\text{Var}_\theta[T(X)] \geq \frac{1}{I(\theta)}.$$

행렬 버전: $T(X)$ 가 θ (벡터)의 비편향 추정량이면: $\text{Cov}_\theta[T] \succeq I(\theta)^{-1}$.

증명 스케치 (Cauchy–Schwarz). 비편향 조건 $\mathbb{E}_\theta[T] = \theta$ 를 미분: $\text{Cov}_\theta(T, s) = 1$. Cauchy–Schwarz: $1 = \text{Cov}^2 \leq \text{Var}[T] \cdot \text{Var}[s] = \text{Var}[T] \cdot I(\theta)$. $\Rightarrow \text{Var}[T] \geq 1/I(\theta)$. $\square$

Fisher 계량의 기하학적 의미

$I(\theta)$ 는 통계 매니폴드 S 위의 리만 계량이다. Cramér–Rao 부등식을 기하학적으로 읽으면:

$$\underbrace{I(\theta)}_{\text{리만 계량}} \text{ 이 클수록} \Leftrightarrow \underbrace{I(\theta)^{-1}}_{\text{분산 하한}} \text{ 이 작다} \Leftrightarrow \text{추정이 쉽다.}$$

리만 계량이 클다는 것은 (§ 6 Vol.3) 그 방향으로 분포가 빠르게 변함을 뜻한다. 분포가 빠르게 변하면 근처 분포들을 잘 구별할 수 있으므로, 해당 방향의 매개변수를 정밀하게 추정할 수 있다.

효율적 추정량 T^* (등호 달성): $T^*(X) - \theta = c(\theta) \cdot s(\theta; X)$ (Score의 선형 함수)일 때. 지수족에서 충분 통계량 $T(X)$ 가 이 조건을 만족한다.

A Radon – Nikodym 정리 (개요)

이산 pmf와 연속 pdf를 통합하는 수학적 언어다.

정의 A.1 절대 연속

측도 ν 가 측도 μ 에 대해 절대 연속(absolutely continuous) ($\nu \ll \mu$)이라 함은: $\mu(A) = 0 \Rightarrow \nu(A) = 0$.

정리 A.1 Radon – Nikodym

σ -유한 측도 공간 $(\Omega, \mathcal{F}, \mu)$ 위에서 $\nu \ll \mu$ 이면, 가측 함수 $p : \Omega \rightarrow [0, \infty)$ 가 유일하게 존재하여

$$\nu(A) = \int_A p \, d\mu \quad \forall A \in \mathcal{F}.$$

p 를 Radon – Nikodym 도함수 $\frac{d\nu}{d\mu}$ 라 한다.

이산 분포: $\mu =$ 계수 측도, $p =$ pmf. 연속 분포: $\mu =$ Lebesgue 측도, $p =$ pdf. 두 경우를 통합하면 $p(x; \theta)$ 가 항상 동일한 언어로 다루어진다.

KL 발산의 일반형: $\nu \ll \mu$ 이면 $D_{\text{KL}}[\nu : \mu] = \int \frac{d\nu}{d\mu} \log \frac{d\nu}{d\mu} \, d\mu$.

B 참고문헌

- [1] Casella, G. & Berger, R. L. (2002). Statistical Inference, 2nd ed. Duxbury.
— 통계적 추론의 표준 교재. 추정·검정의 고전.
- [2] Billingsley, P. (1995). Probability and Measure, 3rd ed. Wiley.
— 측도론적 확률론의 엄밀한 전개.
- [3] Cover, T. M. & Thomas, J. A. (2006). Elements of Information Theory, 2nd ed. Wiley.
— Shannon 엔트로피·KL 발산의 정보 이론 표준 교재.
- [4] Lehmann, E. L. & Casella, G. (1998). Theory of Point Estimation, 2nd ed. Springer.
— Cramér – Rao 한계·충분성·완전성의 심화 이론.
- [5] Amari, S. (2016). Information Geometry and Its Applications. Springer.
— Score·Fisher·KL의 기하학적 통합.