
연결

통계적 매니폴드로

Fisher 계량 · 지수족 기하 · α -접속 · 쌍대 평탄 구조 · 자연 기울기

정보기하학 기초 시리즈 Vol.5

2026년 6월 16일

차 례

서문	3
1 통계적 매니폴드의 구성	4
1.1 확률분포족이 매니폴드가 되는 조건	4
1.2 매개변수 공간과 차트	4
1.3 매니폴드로서의 통계 모델 — 예시들	4
1.4 매끄러운 함수와 접공간의 통계적 해석	5
2 Fisher – Rao 계량의 도출	6
2.1 발산도에서 리만 계량으로	6
2.2 KL 발산의 Hessian = Fisher 행렬 — 완전 증명	6
2.3 Fisher – Rao 계량의 정의와 좌표 무관성	6
2.4 가우시안 매니폴드의 계량과 쌍곡 구조	7
3 지수족의 기하	8
3.1 자연 매개변수 θ 와 기댓값 매개변수 η	8
3.2 Legendre 변환과 쌍대 좌표계	9
3.3 Bregman 발산과 쌍대 구조	9
3.4 쌍대 Bregman 발산과 정보 구조	10
4 Amari의 α -접속	11
4.1 왜 Levi-Civita 접속만으로는 부족한가	11
4.2 α -접속의 정의와 기하 구조	11
4.3 e -접속 ($\alpha = 1$)과 m -접속 ($\alpha = -1$)	11
4.4 쌍대 접속의 구조	12
5 쌍대 평탄 구조	13
5.1 평탄 접속이란	13
5.2 쌍대 측지선과 피타고라스 정리	13
5.3 정보 사영 (Information Projection)	14

5.4	최대 엔트로피 원리의 기하	14
6	측지선과 통계 추론	15
6.1	e -측지선과 m -측지선	15
6.2	MLE와 m -사영	15
6.3	충분 통계량과 e -평탄 부분 다양체	16
6.4	혼합 측지 삼각형	16
7	곡률과 통계	17
7.1	통계 모델의 곡률 텐서	17
7.2	가우시안 매니폴드의 곡률 $K = -\frac{1}{2}$	17
7.3	α -곡률과 점근 이론	17
7.4	편평한 통계 모델 — 지수족	18
8	Cramér–Rao 부등식의 기하학적 재해석	19
8.1	Fisher 계량과 추정 정밀도	19
8.2	분산 하한의 기하: 직교 분해	19
8.3	효율적 추정량과 측지선	20
8.4	비편향 추정이 불가능한 경우 — 곡률의 역할	20
9	전망 — 정보기하학의 응용	21
9.1	자연 기울기와 뉴럴 네트워크	21
9.2	베이지스 추론의 기하	21
9.3	통계 물리와 열역학적 기하	22
9.4	다음 단계 — 심화 학습 로드맵	22
A	Christoffel 기호 명시적 계산	23
B	참고문헌	23

서문


Vol.1부터 Vol.4는 각각 독립된 수학적 언어를 다루었다. 미적분(Vol.1)은 Taylor 전개와 점근 표기법을, 선형대수(Vol.2)는 이차형식과 양의 정치행렬을, 미분기하학(Vol.3)은 매니폴드와 리만 계량을, 확률론(Vol.4)은 Score 함수와 Fisher 정보행렬을.

이 노트는 그 모든 흐름이 하나로 합류하는 지점이다.

핵심 명제는 단 하나다.

확률분포들의 집합은 Fisher 정보행렬을 리만 계량으로 갖는 매니폴드다.

이것을 “통계적 매니폴드”라 한다. 이 구조 위에는 두 종류의 접속(Amari의 e -접속과 m -접속)이 공존하고, 그 쌍대 구조가 통계 추론의 기하학 — MLE의 사영 해석, Cramér–Rao 부등식의 기하적 증명, 자연 기울기 하강법 — 을 낳는다.



1 통계적 매니폴드의 구성

1.1 확률분포족이 매니폴드가 되는 조건

통계 모델 $S = \{p(x; \theta) : \theta \in \Theta\}$ 가 매니폴드가 되려면 두 조건이 필요하다.

정의 1.1 통계적 매니폴드의 조건

- (i) **동일화 조건**: $\theta \neq \theta' \Rightarrow p(\cdot; \theta) \neq p(\cdot; \theta')$. (매개변수와 분포가 일대일 대응)
- (ii) **매끄러움**: $p(x; \theta)$ 가 θ 에 대해 C^∞ 이고, Fisher 정보행렬 $I(\theta) = (I_{ij}(\theta))$ 가 θ 에서 C^∞ 이며 $I(\theta) \succ 0$.

이 두 조건이 성립하면 S 는 n -차원 리만 매니폴드가 된다. ($n = \dim \Theta$)

동일화 조건은 "다른 매개변수 = 다른 분포"를 보장한다. 이것이 없으면 매개변수 공간이 매니폴드의 좌표계 역할을 할 수 없다. 매끄러움 조건은 접공간과 텐서 계산이 잘 정의되도록 한다.

1.2 매개변수 공간과 차트

$\Theta \subseteq \mathbb{R}^n$ 이 열린 집합이면, (Θ, id) 가 단일 차트를 이룬다. 아틀라스는 이 하나의 차트만으로 충분하다.

정의 1.2 통계적 매니폴드의 접공간

통계 모델 S 위의 점 $p = p(\cdot; \theta)$ 에서의 접공간 $T_p S$ 의 자연스러운 기저는 Score 함수들이 제공한다:

$$\partial_i := \frac{\partial \log p(x; \theta)}{\partial \theta^i} = s_i(\theta; x).$$

두 접벡터 $u = \sum u^i \partial_i, v = \sum v^j \partial_j$ 의 내적:

$$g_p(u, v) = \mathbb{E}_\theta \left[\left(\sum_i u^i s_i \right) \left(\sum_j v^j s_j \right) \right] = \sum_{i,j} u^i v^j I_{ij}(\theta).$$

접벡터 = Score의 선형 결합. 이것이 "통계적 방향"의 의미를 갖는다.

1.3 매니폴드로서의 통계 모델 — 예시들

예시 1.1 가우시안 매니폴드

$S_G = \{\mathcal{N}(\mu, \sigma^2) : \mu \in \mathbb{R}, \sigma > 0\}$. $\Theta = \mathbb{R} \times \mathbb{R}_{>0} : \mathbb{R}^2$ 의 열린 부분집합 $\rightarrow$ 2차원 매니폴드.
Fisher 정보행렬 (Vol.4 § 8.3): $I(\mu, \sigma) = \begin{pmatrix} 1/\sigma^2 & 0 \\ 0 & 2/\sigma^2 \end{pmatrix}$.

Fisher-Rao 계량: $ds^2 = \frac{d\mu^2}{\sigma^2} + \frac{2d\sigma^2}{\sigma^2}$.

예시 1.2 이산 분포 — 단체(simplex)

$X = \{0, 1, \dots, n\}$ 위의 분포: $\Theta_n = \{(p_1, \dots, p_n) : p_i > 0, \sum p_i < 1\}$. (Vol.4 § 7.1)

Fisher 정보행렬: $I_{ij}(\theta) = \frac{\delta_{ij}}{p_i} + \frac{1}{p_0}$.

이것이 단체의 내부에 부여되는 자연스러운 리만 계량이다.

예시 1.3 지수족

$p(x; \theta) = h(x) \exp\{\langle \theta, T(x) \rangle - \psi(\theta)\}$.

Fisher 정보행렬 = ψ 의 Hessian (Vol.4 § 3.4): $I_{ij}(\theta) = \partial_i \partial_j \psi(\theta)$.

ψ 가 볼록이므로 $I(\theta) \succ 0$ — 자동으로 양의 정치.

1.4 매끄러운 함수와 접공간의 통계적 해석

통계적 매니폴드 위에서 가장 자연스러운 매끄러운 함수는 로그가능도 $\ell(\theta; x)$ 다.

접공간의 원소 $v = \sum_i v^i \partial_i$ 가 함수 $f(\theta)$ 에 작용하는 방식: $v(f) = \sum_i v^i \partial_i f(\theta)$ — 표준 방향 미분.

기하학적으로, 로그가능도는 통계 매니폴드 위에서 "높이 함수" 역할을 한다. MLE는 이 높이 함수의 최댓값 점이다.

2 Fisher – Rao 계량의 도출

2.1 발산도에서 리만 계량으로

Vol.1 § 1.2에서 정의한 발산도(divergence)의 세 조건을 상기한다. $D[P : Q] \geq 0$, $D[P : Q] = 0 \Leftrightarrow P = Q$, 그리고 $D[\theta_P : \theta_P + d\theta] = \frac{1}{2} \sum_{i,j} g_{ij} d\theta_i d\theta_j + O(|d\theta|^3)$.

KL 발산이 이 세 조건을 만족함을 Vol.4 § 9.2에서 확인했다. 이제 KL 발산의 Hessian이 정확히 Fisher 정보행렬임을 보인다.

2.2 KL 발산의 Hessian = Fisher 행렬 — 완전 증명

정리 2.1 Fisher – Rao 계량의 도출

$D_{\text{KL}}[\theta : \theta'] := D_{\text{KL}}[p(\cdot; \theta) : p(\cdot; \theta')]$ 으로 정의하면,

$$\frac{\partial^2}{\partial \theta'^i \partial \theta'^j} D_{\text{KL}}[\theta : \theta'] \Big|_{\theta'=\theta} = I_{ij}(\theta).$$

증명 (완전). $D_{\text{KL}}[\theta : \theta'] = \int p(x; \theta) [\log p(x; \theta) - \log p(x; \theta')] dx$.

θ 를 고정하고 θ' 에 대해 미분한다.

1차 미분:

$$\partial_{j'} D_{\text{KL}}[\theta : \theta'] = - \int p(x; \theta) \cdot \partial_{j'} \log p(x; \theta') dx = -\mathbb{E}_{\theta}[s_j(\theta'; X)].$$

$\theta' = \theta$ 에서: $= -\mathbb{E}_{\theta}[s_j(\theta; X)] = 0$ (Score 기댓값 = 0, Vol.4 § 8.2).

2차 미분:

$$\partial_{i'} \partial_{j'} D_{\text{KL}}[\theta : \theta'] = - \int p(x; \theta) \cdot \partial_{i'} \partial_{j'} \log p(x; \theta') dx.$$

$\theta' = \theta$ 에서:

$$= -\mathbb{E}_{\theta}[\partial_i \partial_j \log p(X; \theta)] = I_{ij}(\theta)$$

(Fisher 정보의 동치 표현, Vol.4 § 8.3). □

2.3 Fisher – Rao 계량의 정의와 좌표 무관성

정의 2.1 Fisher – Rao 계량

통계적 매니폴드 S 위의 Fisher – Rao 계량은 $(0, 2)$ -텐서장 g 로:

$$g_{ij}(\theta) := I_{ij}(\theta) = \mathbb{E}_{\theta} \left[\frac{\partial \log p}{\partial \theta^i} \cdot \frac{\partial \log p}{\partial \theta^j} \right].$$

g 가 좌표에 무관한 텐서인 이유: I_{ij} 는 텐서 변환 법칙(Vol.3 § 5.3)을 만족한다. 좌표 $\theta \rightarrow \tilde{\theta}$ 에서: $\tilde{g}_{kl} = g_{ij} \frac{\partial \theta^i}{\partial \tilde{\theta}^k} \frac{\partial \theta^j}{\partial \tilde{\theta}^l}$.

두 관점의 일치

Fisher–Rao 계량은 두 방향에서 동시에 도달한다.

- 통계 방향: Fisher 정보행렬 $I_{ij} = \mathbb{E}[s_i s_j]$ — 추정 정밀도의 한계.
- 기하 방향: KL 발산의 Taylor 전개 2차 계수 — 분포 공간의 “거리감”.
- 결론: 두 개념이 동일한 수학적 객체다.

2.4 가우시안 매니폴드의 계량과 쌍곡 구조

가우시안 매니폴드 $(\mathbb{R} \times \mathbb{R}_{>0}, g)$ 에서 (Vol.4 § 8.3):

$$ds^2 = \frac{d\mu^2}{\sigma^2} + \frac{2 d\sigma^2}{\sigma^2}.$$


변수 치환 $\eta = \sqrt{2}\sigma$:

$$ds^2 = \frac{2}{\eta^2}(d\mu^2 + d\eta^2) = 2 \cdot \frac{d\mu^2 + d\eta^2}{\eta^2}.$$

표준 Poincaré 상반평면 계량 $\frac{d\mu^2 + d\eta^2}{\eta^2}$ 의 2배. 계량의 상수 배는 곡률을 역수 배한다 (Vol.3 § 9.4):

$$K = -\frac{1}{2}.$$

가우시안 매니폴드 (μ, σ) : 쌍곡 기하



3 지수족의 기하

지수족은 정보기하학의 핵심 예시다. 자연 매개변수 θ 와 기댓값 매개변수 η 라는 두 좌표계가 공존하며, 이 쌍대 구조가 정보기하학의 풍요로움을 낳는다.

3.1 자연 매개변수 θ 와 기댓값 매개변수 η

지수족 $p(x; \theta) = h(x) \exp\{\langle \theta, T(x) \rangle - \psi(\theta)\}$ 에서:

정의 3.1 두 가지 매개변수

- 자연 매개변수(natural parameters): $\theta = (\theta^1, \dots, \theta^n)$.
- 기댓값 매개변수(expectation parameters): $\eta_i := \mathbb{E}_\theta[T_i(X)] = \partial_i \psi(\theta)$.

두 매개변수 사이의 관계:

$$\eta = \nabla \psi(\theta), \quad \theta = \nabla \psi^*(\eta).$$

여기서 ψ^* 는 ψ 의 Legendre 변환 (Vol.1 § 9.4, Vol.2 § 9.4).

정리 3.1 지수족의 두 매개변수 성질

- (i) $\nabla \psi(\theta) = \eta$ (기댓값 매개변수는 ψ 의 기울기)
- (ii) $H_\psi(\theta) = I(\theta)$ (Fisher 정보 = ψ 의 Hessian)
- (iii) $\nabla \psi^*(\eta) = \theta$ (역사상: $\eta \rightarrow \theta$)
- (iv) $H_{\psi^*}(\eta) = I(\eta)^{-1}$ (ψ^* 의 Hessian = Fisher 역행렬)

예시 3.1 가우시안의 자연 매개변수

$\mathcal{N}(\mu, \sigma^2)$ 을 지수족으로 쓰면:

자연 매개변수: $\theta^1 = \mu/\sigma^2, \theta^2 = -1/(2\sigma^2)$.

기댓값 매개변수: $\eta_1 = \mathbb{E}[X] = \mu, \eta_2 = \mathbb{E}[X^2] = \mu^2 + \sigma^2$.

로그 분배함수: $\psi(\theta) = -(\theta^1)^2/(4\theta^2) - \frac{1}{2} \log(-2\theta^2) + \frac{1}{2} \log \pi$.

3.2 Legendre 변환과 쌍대 좌표계

정의 3.2 Legendre 변환 (복습)

볼록함수 ψ 의 켈레:

$$\psi^*(\eta) := \sup_{\theta} [\langle \theta, \eta \rangle - \psi(\theta)] = \langle \theta(\eta), \eta \rangle - \psi(\theta(\eta)).$$

정리 3.2 (θ, η) 쌍대 좌표의 관계

- (i) $\langle \theta, \eta \rangle = \psi(\theta) + \psi^*(\eta)$ (Fenchel 등호 조건)
- (ii) $d\psi = \eta \cdot d\theta, d\psi^* = \theta \cdot d\eta$ (미분 관계)
- (iii) $g_{ij}(\theta) = \partial_i \partial_j \psi(\theta)$ (θ 좌표에서 Fisher 계량)
- (iv) $g^{ij}(\eta) = \partial^i \partial^j \psi^*(\eta)$ (η 좌표에서 역 계량)

3.3 Bregman 발산과 쌍대 구조

정의 3.3 Bregman 발산

볼록함수 ψ 에 대한 Bregman 발산:

$$D_{\psi}[\theta : \theta'] := \psi(\theta) - \psi(\theta') - \langle \theta - \theta', \nabla \psi(\theta') \rangle = \psi(\theta) - \psi(\theta') - \langle \theta - \theta', \eta' \rangle.$$

항상 $D_{\psi}[\theta : \theta'] \geq 0$ 이고 $= 0 \Leftrightarrow \theta = \theta'$.

정리 3.3 KL 발산 = Bregman 발산 (지수족)


지수족에서 ψ 를 로그 분배함수로 잡으면:

$$D_{\psi}[\theta : \theta'] = D_{\text{KL}}[p(\cdot; \theta) : p(\cdot; \theta')].$$

쌍대 Bregman 발산 (ψ^* 사용):

$$D_{\psi^*}[\eta : \eta'] = D_{\text{KL}}[p(\cdot; \theta') : p(\cdot; \theta)].$$

$\theta \leftrightarrow \theta'$ 가 교환될 때 KL의 방향이 뒤집힌다.



3.4 쌍대 Bregman 발산과 정보 구조

지수족에서 다음의 아름다운 쌍대성이 성립한다.

정리 3.4 Bregman 발산의 쌍대성

지수족에서:

$$D_\psi[\theta : \theta'] + D_{\psi^*}[\eta' : \eta] = \langle \theta - \theta', \eta - \eta' \rangle \geq 0.$$

등호: $\theta = \theta'$ (또는 $\eta = \eta'$).

기하학적으로:

- $D_\psi[\theta : \theta'] = D_{\text{KL}}[p(\cdot; \theta) : p(\cdot; \theta')]$: " θ 에서 θ' 로의 정보 거리"
- $D_{\psi^*}[\eta' : \eta] = D_{\text{KL}}[p(\cdot; \theta') : p(\cdot; \theta)]$: "반대 방향 정보 거리"

4 Amari의 α -접속

리만 매니폴드에는 표준 접속(Levi-Civita)이 하나 있다. 그런데 통계적 매니폴드에는 통계 추론에 자연스럽게 등장하는 또 다른 접속들이 있다. Amari가 1985년에 도입한 α -접속이 그것이다.

4.1 왜 Levi-Civita 접속만으로는 부족한가

Levi-Civita 접속은 계량 g 로부터 유일하게 결정된다 (Vol.3 § 7.3). 그런데 통계에서는 두 가지 서로 다른 "최직선" 개념이 자연스럽게 등장한다.

- **지수족의 자연 매개변수 직선:** $\theta(t) = (1-t)\theta_0 + t\theta_1$. 이것은 지수족 분포들의 "혼합"이 아니라 "지수족 내 직선 경로"다.
- **분포들의 혼합 직선:** $p(x;t) = (1-t)p_0(x) + tp_1(x)$. 이것은 밀도 함수 수준에서의 선형 보간이다.

두 "직선"이 일치하는 경우는 매우 드물다. 이 두 개념을 각각 포착하는 접속이 e -접속과 m -접속이다.

4.2 α -접속의 정의와 기하 구조

정의 4.1 α -접속

통계적 매니폴드 (S, g) 위의 α -접속 ($\alpha \in \mathbb{R}$)의 Christoffel 기호 (제1종):

$$\Gamma_{ij,k}^{(\alpha)} := \mathbb{E}_{\theta} \left[\left(\partial_i \partial_j \ell + \frac{1-\alpha}{2} \partial_i \ell \partial_j \ell \right) \partial_k \ell \right]$$

여기서 $\ell = \log p(x; \theta)$.

세 항의 의미: $\Gamma_{ij,k}^{(\alpha)} = -\frac{1+\alpha}{2} T_{ijk} + (\text{계량 항})$ 여기서 $T_{ijk} = \mathbb{E}[\partial_i \ell \partial_j \ell \partial_k \ell]$ 은 왜도 텐서.

$\alpha = 0$ 이면 Levi-Civita 접속. $\alpha = \pm 1$ 이 가장 중요하다.

4.3 e -접속 ($\alpha = 1$)과 m -접속 ($\alpha = -1$)

정의 4.2 e -접속과 m -접속

e -접속 (지수 접속, $\alpha = 1$): $\Gamma_{ij,k}^{(e)} = \mathbb{E}_{\theta}[\partial_i \partial_j \ell \cdot \partial_k \ell]$.

m -접속 (혼합 접속, $\alpha = -1$): $\Gamma_{ij,k}^{(m)} = \mathbb{E}_{\theta}[\partial_i \ell \partial_j \ell \partial_k \ell] = T_{ijk}$.

지수족 $p(x; \theta) = h(x) \exp\{\langle \theta, T \rangle - \psi(\theta)\}$ 에서:

- θ -좌표에서: $\Gamma_{ij,k}^{(e)} = 0$ — e -접속이 평탄(flat).

- η -좌표에서: $\Gamma_{ij,k}^{(m)} = 0$ — m -접속이 평탄(flat).

4.4 쌍대 접속의 구조


정리 4.1 쌍대성

α -접속과 $(-\alpha)$ -접속은 계량 g 에 대해 쌍대(dual)다:

$$X g(Y, Z) = g(\nabla_X^{(\alpha)} Y, Z) + g(Y, \nabla_X^{(-\alpha)} Z).$$

특히 e -접속과 m -접속은 서로 쌍대 접속 쌍이다.

이 쌍대 구조가 Bregman 발산의 두 방향 ($D_{\text{KL}}[P : Q]$ 와 $D_{\text{KL}}[Q : P]$)에 대응한다.



같은 두 점을 잇는 e -측지선과 m -측지선은 일반적으로 다르다

5 쌍대 평탄 구조

지수족에서 e -접속과 m -접속이 각각 평탄하다는 사실이 "쌍대 평탄 구조(dually flat structure)"다. 이 구조에서 피타고라스 정리의 일반화가 성립한다.

5.1 평탄 접속이란

정의 5.1 평탄 접속

접속 ∇ 이 평탄(flat)이라 함은 곡률 텐서가 0임을 뜻한다: $R^{(\nabla)}(X, Y)Z = 0$. 이 경우 전역 좌표계 $\{x^i\}$ (아핀 좌표)에서 Christoffel 기호가 모두 0: $\Gamma_{ij}^k = 0$.

정리 5.1 지수족의 쌍대 평탄성

지수족 $S = \{p(x; \theta)\}$ 에서:

- e -접속은 평탄. 아핀 좌표: 자연 매개변수 θ .
- m -접속은 평탄. 아핀 좌표: 기댓값 매개변수 $\eta = \nabla \psi(\theta)$.

직관: θ -좌표에서 e -측지선은 직선이고, η -좌표에서 m -측지선은 직선이다.


5.2 쌍대 측지선과 피타고라스 정리

정리 5.2 정보기하학의 피타고라스 정리

세 분포 $P, Q, R \in S$ (지수족)에 대해, Q 와 R 을 잇는 e -측지선에 P 에서 m -직교 (m -orthogonal)로 내린 발이 Q 이면:

$$D_{\text{KL}}[P : R] = D_{\text{KL}}[P : Q] + D_{\text{KL}}[Q : R].$$

두 KL 발산의 합이 된다.



$$D_{\text{KL}}[P : R] = D_{\text{KL}}[P : Q] + D_{\text{KL}}[Q : R] \text{ (정보 피타고라스)}$$

5.3 정보 사영 (Information Projection)

정의 5.2 두 종류의 정보 사영

부분 매니폴드 $M \subseteq S$ 와 분포 $P \in S$ 에 대해:

- m -사영: $\hat{Q}_m = \operatorname{argmin}_{Q \in M} D_{\text{KL}}[P : Q]$. P 를 M 위에 "앞방향 KL"로 사영.
- e -사영: $\hat{Q}_e = \operatorname{argmin}_{Q \in M} D_{\text{KL}}[Q : P]$. P 를 M 위에 "역방향 KL"로 사영.

MLE는 m -사영이다: 표본 분포 $\hat{p}_n$ 을 모델 S 위에 m -사영.

정리 5.3 MLE = m -사영

n 개의 i.i.d. 관측 $x_1, \dots, x_n$ 의 경험적 분포를 $\hat{p}_n = \frac{1}{n} \sum_i \delta_{x_i}$ 라 하면,

$$\hat{\theta}_{\text{MLE}} = \operatorname{argmax}_{\theta \in \Theta} \ell(\theta) = \operatorname{argmin}_{\theta \in \Theta} D_{\text{KL}}[\hat{p}_n : p(\cdot; \theta)].$$

즉 MLE는 경험적 분포를 모델 위에 m -사영한 것이다.

5.4 최대 엔트로피 원리의 기하

최대 엔트로피(MaxEnt) 원리는 e -사영으로 해석된다.

정리 5.4 최대 엔트로피의 기하

제약 $\mathbb{E}_Q[T_i(X)] = \eta_i^0$ ($i = 1, \dots, k$)를 만족하는 분포 중 Shannon 엔트로피 $H(Q)$ 를 최대화하는 Q^* 는, 모든 분포의 집합 위에서 제약 다양체 M_η 로의 e -사영이다:

$$Q^* = \operatorname{argmin}_{Q \in M_\eta} D_{\text{KL}}[Q : U]$$

여기서 U 는 균등분포 (또는 기준 측도). Q^* 는 지수족 분포의 형태를 가진다.

이것이 "최대 엔트로피 원리는 항상 지수족을 낳는다"는 유명한 결과의 기하학적 설명이다.

6 측지선과 통계 추론

e -측지선과 m -측지선은 각각 다른 종류의 통계적 추론에 대응한다. 이 장은 그 구체적인 연결을 다룬다.

6.1 e -측지선과 m -측지선

정의 6.1 e -측지선과 m -측지선

e -측지선(지수 측지선): e -접속에 대한 측지선. 지수족에서 θ -좌표의 직선:

$$\theta(t) = (1-t)\theta_0 + t\theta_1.$$

m -측지선(혼합 측지선): m -접속에 대한 측지선. 지수족에서 η -좌표의 직선:

$$\eta(t) = (1-t)\eta_0 + t\eta_1,$$

즉 밀도 함수의 볼록 결합: $p(x;t) = (1-t)p_0(x) + tp_1(x)$ (혼합 분포).

예시 6.1 가우시안 매니폴드에서의 두 측지선


$P = \mathcal{N}(\mu_0, \sigma_0^2)$, $Q = \mathcal{N}(\mu_1, \sigma_1^2)$.

e -측지선 (θ -직선): $\theta^1(t) = (1-t)\frac{\mu_0}{\sigma_0^2} + t\frac{\mu_1}{\sigma_1^2}$, $\theta^2(t) = -(1-t)\frac{1}{2\sigma_0^2} - t\frac{1}{2\sigma_1^2}$. 이것은 일반적으로 정규분포족 안에 머문다.

m -측지선 (η -직선): $\mu(t) = (1-t)\mu_0 + t\mu_1$, $\sigma^2(t) + \mu(t)^2 = (1-t)(\sigma_0^2 + \mu_0^2) + t(\sigma_1^2 + \mu_1^2)$. 이것도 정규분포족 안에 머문다 (가우시안의 특수성).

6.2 MLE와 m -사영

정리 5.3의 MLE = m -사영을 더 구체적으로 살펴본다.



6.3 충분 통계량과 e -평탄 부분 다양체정리 6.1 충분 통계량과 e -평탄성

지수족 S 에서 $T(x)$ 의 부분 성분이 고정되어 얻는 부분 다양체는 e -평탄(e -flat)이다.
반대로: 모든 e -평탄 부분 다양체는 충분 통계량의 어떤 부분 성분을 고정하여 얻는다.

이것이 "충분 통계량은 e -평탄 구조를 정의한다"는 기하학적 의미다. 추정 이론의 Rao-Blackwell 정리(충분 통계량을 이용하면 분산을 줄일 수 있다)가 이 기하학적 사실의 확률론적 표현이다.

6.4 혼합 측지 삼각형

정리 6.2 혼합 측지 삼각형 (일반화 피타고라스)

e -평탄 다양체 E 와 m -평탄 다양체 M 이 점 Q 에서 교차하고 $P \in E$, $R \in M$ 이면:

$$D_{\text{KL}}[P : R] = D_{\text{KL}}[P : Q] + D_{\text{KL}}[Q : R].$$

삼각형 P - Q - R 에서 Q 에서의 e -접선과 m -접선이 g -직교한다.

이 정리는 통계 추론에서 "모델 축소"의 정보 손실을 정량화한다. P 에서 R 로 직접 가는 정보 비용 = $P \rightarrow Q$ (모델로 사영) + $Q \rightarrow R$ (모델 내 이동).

7 곡률과 통계

7.1 통계 모델의 곡률 텐서

리만 곡률 텐서 (Vol.3 § 9.1): $R^{(\alpha)}(X, Y)Z = \nabla_X^{(\alpha)} \nabla_Y^{(\alpha)} Z - \nabla_Y^{(\alpha)} \nabla_X^{(\alpha)} Z - \nabla_{[X, Y]}^{(\alpha)} Z$.

정의 7.1 α -곡률 텐서

α -접속 $\nabla^{(\alpha)}$ 에 대한 곡률 텐서를 α -곡률이라 한다.

성질:

- $R^{(0)}$: Levi-Civita (Fisher-Rao 계량)의 곡률.
- $R^{(1)} = R^{(-1)} = 0$: 지수족에서 e, m -접속 모두 평탄.
- $R^{(\alpha)}$ 와 $R^{(-\alpha)}$: 쌍대 관계.

7.2 가우시안 매니폴드의 곡률 $K = -\frac{1}{2}$

Vol.3 § 9.4에서 증명한 결과를 통계적 관점에서 재해석한다.

정리 7.2 가우시안 매니폴드의 단면 곡률

Fisher-Rao 계량 $g = d\mu^2/\sigma^2 + 2d\sigma^2/\sigma^2$ 에 대해 Levi-Civita 접속의 단면 곡률:

$$K = -\frac{1}{2}.$$

통계적 해석: $K < 0$ (음의 곡률)은 측지선이 발산함을 의미한다. 가우시안 매니폴드에서 "처음에 가까운" 두 분포도 측지선을 따라 이동하면 점점 멀어진다. 이것은 통계 추론에서 분포 구별의 누적 어려움으로 나타난다.

7.3 α -곡률과 점근 이론

정리 7.3 Efron의 통계 곡률

통계 모델 S 에서 MLE의 2차 편향(bias)은 α -곡률과 직접 연결된다. 구체적으로, n 표본에서 MLE의 편향:

$$\mathbb{E}_\theta[\hat{\theta}_n^i] - \theta^i = \frac{1}{2n} \sum_{j,k} I^{ij} \Gamma_{jk}^{(m)k} + O(n^{-2}).$$

m -접속의 Christoffel 기호 $\Gamma^{(m)}$ 이 편향을 결정한다.

Efron (1975)이 발견한 이 결과가 정보기하학 발전의 중요한 자극이 되었다.

7.4 편평한 통계 모델 — 지수족

지수족에서는 e -접속과 m -접속이 각각 하나의 좌표에서 평탄하므로, 그 좌표들이 "정보기하학적으로 자연스러운" 기저 역할을 한다.

정리 7.4 지수족의 쌍대 평탄성

지수족 S 는 쌍대 평탄 리만 매니폴드다: $(S, g, \nabla^{(e)}, \nabla^{(m)})$.

이 구조에서:

- (i) θ -좌표: e -아핀 ($\text{Christoffel}^{(e)} = 0$)
- (ii) η -좌표: m -아핀 ($\text{Christoffel}^{(m)} = 0$)
- (iii) $g(\partial_i^{(\theta)}, \partial_j^{(\eta)}) = \delta_{ij}$ (쌍대 기저 직교)
- (iv) 피타고라스 정리 성립 (정리 5.2)

8 Cramér – Rao 부등식의 기하학적 재해석

Cramér – Rao 부등식 (Vol.4 § 9.4)을 정보기하학의 언어로 다시 읽는다. 분산 하한은 Fisher 계량이 정의하는 "분해능 한계"의 기하학적 표현이다.

8.1 Fisher 계량과 추정 정밀도

Fisher 정보행렬 $I(\theta)$ 는 통계 매니폴드의 리만 계량이다. 계량이 클다 = 이 방향으로 분포가 빠르게 변한다 = 분포들을 잘 구별할 수 있다 = 매개변수를 정밀하게 추정할 수 있다.

정리 8.1 Cramér – Rao (기하적 형식)

점 θ 에서의 비편향 추정량 $T(X)$ (벡터값)에 대해:

$$\text{Cov}_\theta[T] \succeq I(\theta)^{-1} = g(\theta)^{-1}.$$

등호 달성: T 가 효율적 추정량일 때.

$I(\theta)^{-1}$: "Fisher 계량의 역행렬" = 분산의 최소 한계. 계량이 작은 방향(분포가 느리게 변하는 방향)은 추정이 어렵고, 분산 하한이 크다.

8.2 분산 하한의 기하: 직교 분해

정리 8.2 Cramér – Rao의 기하학적 증명

비편향 추정량 T 의 기울기(Score와의 공분산 벡터)는 접공간 $T_\theta S$ 의 원소다.

Cauchy – Schwarz 부등식 (= 리만 계량의 부등식):

$$\text{Cov}(T, s)^2 \leq \text{Var}(T) \cdot \text{Var}(s).$$

비편향 조건: $\text{Cov}(T, s_i) = 1$ (각 방향으로).

따라서 $1 \leq \text{Var}(T) \cdot I(\theta)$, 즉 $\text{Var}(T) \geq I(\theta)^{-1}$.

기하학적으로: 비편향 추정량의 "기울기 벡터"가 접공간에 놓이고, 그 기울기 벡터의 리만 길이 제곱이 분산 하한을 준다.

8.3 효율적 추정량과 측지선

정리 8.3 효율적 추정량의 특성

Cramér–Rao 등호를 달성하는 효율적 추정량 T 는:

$$T(X) - \theta = c(\theta) \cdot s(\theta; X) \quad (\text{a.s.}).$$

즉 $T(X) - \theta$ 가 Score의 선형 함수일 때 등호 성립.

지수족에서: 충분 통계량 $T(X)$ 의 표본평균 $\bar{T}$ 가 $\eta = \mathbb{E}[T(X)]$ 의 효율적 추정량이다.

8.4 비편향 추정이 불가능한 경우 — 곡률의 역할

일반 곡면 통계 모델에서는 비편향 효율적 추정량이 존재하지 않을 수 있다.

정리 8.4 곡률과 추정 한계 (Amari)

통계 모델의 m -곡률이 0이 아니면, 표준 Cramér–Rao 하한보다 엄격히 큰 분산 하한이 존재한다:

$$\text{Var}_\theta[T] \geq \frac{1}{I(\theta)} + O(n^{-2}) \cdot C(\theta)$$

여기서 $C(\theta)$ 는 m -곡률에 의존하는 양이다.

지수족 (m -곡률 = 0): 표준 Cramér–Rao 하한이 정확히 달성 가능.

지수족이 아닌 통계 모델에서 곡률이 추정의 한계를 더 엄격하게 만든다. 이것이 정보기하학이 점근 통계 이론에 기여하는 핵심 통찰이다.

9 전망 — 정보기하학의 응용

9.1 자연 기울기와 뉴럴 네트워크

뉴럴 네트워크의 매개변수 $\theta \in \mathbb{R}^n$ 도 하나의 통계 모델 $p(y|x;\theta)$ 로 볼 수 있다. 이때 Fisher 정보행렬 $I(\theta)$ 가 정의되고, 자연 기울기가 의미를 가진다.

정의 9.1 자연 기울기 하강법

손실함수 $L(\theta)$ 에 대해:

표준 기울기 하강: $\theta \leftarrow \theta - \varepsilon \nabla_{\theta} L(\theta)$.


자연 기울기 하강: $\theta \leftarrow \theta - \varepsilon I(\theta)^{-1} \nabla_{\theta} L(\theta)$.

$\tilde{\nabla} L(\theta) := I(\theta)^{-1} \nabla L(\theta)$ 를 자연 기울기라 한다.

정리 9.1 자연 기울기의 핵심 성질

- (i) 좌표 불변성: 어떤 매개변수와 $\tilde{\theta}(\theta)$ 를 써도 자연 기울기 방향은 동일하다.
- (ii) 최급강하: Fisher 계량 g 하에서 L 의 최급강하 방향이 $-\tilde{\nabla} L$.
- (iii) 효율성: 표준 기울기보다 수렴이 빠른 경우가 많다 (곡률을 보상하기 때문).

자연 기울기 vs 표준 기울기



계산 비용: $I(\theta)^{-1}$ 는 $O(n^2)$ 매개변수에서 저장·역행렬 비용이 크다. 실용적 근사: K-FAC(Kronecker-Factored Approximate Curvature), EK-FAC 등.

9.2 베이지 추론의 기하

사전 분포 $\pi(\theta)$ 와 가능도 $p(x|\theta)$ 로부터 사후 분포: $\pi(\theta|x) \propto p(x|\theta)\pi(\theta)$.

정보기하학적 관점:

- 사후 분포는 모든 분포의 공간에서 "가능도 곡면"과 "사전 곡면"의 교점이다.
- Laplace 근사: 사후를 MAP 추정량 주변의 다변량 정규분포로 근사. Fisher 행렬 $I(\hat{\theta})$ 가 사후 공분산의 역행렬로 등장.

- 변분 추론(variational inference): $KL[q : \pi(\cdot|x)]$ 를 최소화하는 $q \in \mathcal{Q}$ ($\mathcal{Q}$: 근사 분포족) = e -사영.

9.3 통계 물리와 열역학적 기하

정보기하학과 통계 물리는 같은 수학적 구조를 공유한다.

정보기하학		통계 물리
자연 매개변수 θ	$\leftrightarrow$	역온도, 화학 퍼텐셜
기댓값 매개변수 η	$\leftrightarrow$	에너지, 입자 수
로그 분배함수 $\psi(\theta)$	$\leftrightarrow$	Helmholtz 자유 에너지
Legendre 변환 $\psi^*(\eta)$	$\leftrightarrow$	엔트로피 (Massieu 함수)
Bregman 발산	$\leftrightarrow$	상대 자유 에너지
Fisher 정보행렬	$\leftrightarrow$	응답 함수 행렬

열역학의 기본 관계식 $dU = TdS - PdV + \mu dN$ 은 쌍대 좌표계 (U, V, N) 과 (T, P, μ) 의 Legendre 변환 관계다.

9.4 다음 단계 — 심화 학습 로드맵

더 나아가기

수학적 심화:

- Amari–Nagaoka (2000): Methods of Information Geometry — 이 시리즈의 완전한 수학적 전개.
- Ay et al. (2017): Information Geometry — 측도 이론적 접근, 무한 차원 확장.

응용 방면:

- 자연 기울기: Amari (1998) "Natural gradient works efficiently in learning", Martens & Grosse (2015) "Optimizing Neural Networks with Kronecker-factored Approximate Curvature".
- 변분 추론: Hoffman et al. (2013) "Stochastic Variational Inference".
- 최적 이동: Villani (2009) Optimal Transport — Wasserstein 거리.
- 양자 정보: Petz (1996) "Monotone metrics on matrix spaces".

이 시리즈 복습 순서: Vol.1(Taylor)→Vol.2(이 차 형 식)→Vol.3(리 만 계 량)→Vol.4(Fisher)→Vol.5(종합).

A Christoffel 기호 명시적 계산

A.1 가우시안 매니폴드의 Levi-Civita Christoffel 기호

좌표 $(x^1, x^2) = (\mu, \sigma)$, $g_{11} = \sigma^{-2}$, $g_{22} = 2\sigma^{-2}$, $g_{12} = 0$. 역계량: $g^{11} = \sigma^2$, $g^{22} = \sigma^2/2$.

공식 $\Gamma_{ij}^k = \frac{1}{2}g^{kl}(\partial_i g_{jl} + \partial_j g_{il} - \partial_l g_{ij})$ 에서 ($\partial_1 = \partial_\mu$, $\partial_2 = \partial_\sigma$):

0이 아닌 성분:

$$\Gamma_{12}^1 = \Gamma_{21}^1 = -\frac{1}{\sigma}, \quad \Gamma_{11}^2 = \frac{1}{2\sigma}, \quad \Gamma_{22}^2 = -\frac{1}{\sigma}.$$

측지선 방정식:

$$\begin{aligned} \ddot{\mu} - \frac{2}{\sigma}\dot{\mu}\dot{\sigma} &= 0, \\ \ddot{\sigma} + \frac{1}{2\sigma}\dot{\mu}^2 - \frac{1}{\sigma}\dot{\sigma}^2 &= 0. \end{aligned}$$

A.2 이산 분포 단체의 Christoffel 기호

$X = \{0, 1, \dots, n\}$, 자연 매개변수 $\theta^i = \log(p_i/p_0)$, $p_0 = 1/(1 + \sum e^{\theta^j})$.

e -접속: θ -좌표에서 $\Gamma_{ij,k}^{(e)} = 0$ (평탄).

m -접속 ($\eta^i = p_i$ 좌표에서 평탄): Levi-Civita에서 Fisher 계량 $g_{ij} = \delta_{ij}/p_i + 1/p_0$ 의 Christoffel 기호를 직접 계산한다.

$n = 1$ (Bernoulli, $p_1 = \eta$): $g = 1/(\eta(1 - \eta))$, Christoffel $\Gamma = \frac{1-2\eta}{2\eta(1-\eta)}$. Fisher-Rao 거리: $d_{\text{FR}}(\eta_1, \eta_2) = 2|\arcsin \sqrt{\eta_1} - \arcsin \sqrt{\eta_2}|$.

B 참고문헌

- [1] Amari, S. (2016). Information Geometry and Its Applications. Springer.
— 이 노트의 핵심 참고서. α -접속·쌍대 평탄·자연 기울기의 표준 교재.
- [2] Amari, S. & Nagaoka, H. (2000). Methods of Information Geometry. AMS / Oxford.
— 수학적으로 엄밀한 전개. 텐서·접속·곡률의 완전한 이론.
- [3] Ay, N., Jost, J., Van Le, H. & Schwachhofer, L. (2017). Information Geometry. Springer.
— 측도론 기반의 현대적 정보기하학.
- [4] Nielsen, F. (2020). An elementary introduction to information geometry. Entropy, 22(10), 1100.
— 무료 공개 입문 논문. 이 시리즈의 연장선.

- [5] Amari, S. (1998). Natural gradient works efficiently in learning. *Neural Computation*, 10(2), 251 – 276.
— 자연 기울기 하강법의 원 논문.
- [6] Rao, C. R. (1945). Information and the accuracy attainable in the estimation of statistical parameters. *Bull. Calcutta Math. Soc.*, 37, 81 – 91.
— Fisher – Rao 계량의 기원.
- [7] Efron, B. (1975). Defining the curvature of a statistical problem. *Ann. Statist.*, 3(6), 1189 – 1242.
— 통계 모델의 곡률 개념 도입, 정보기하학 발전의 촉매.